



西南财经大学

SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

硕士学位论文

MASTER'S DISSERTATION

一种新的时空变点检测方法及其在空气质量监测中的应用

A New Spatio-temporal Change Point Detection Method and its
Application in Air Quality Monitoring

学位申请人 文杭

指导教师 郭斌 副教授

学科专业 统计学

学位类别 经济学

分类号 _____ 密级 _____

U.D.C _____

一种新的时空变点检测方法及其在空气质量监测中的应用

A New Spatio-temporal Change Point Detection Method and its Application
in Air Quality Monitoring

学位申请人: _____ 文杭 _____

学 号: _____ 218020208029 _____

学 科 专 业: _____ 统计学 _____

研 究 方 向: _____ 大数据统计分析 _____

指 导 教 师: _____ 郭斌 副教授 _____

定 稿 时 间: _____ 2021 年 5 月 23 日 _____

摘要

近些年来,空气质量倍受国家的重视。为了保证空气质量监测站点收集到的数据的有效性和准确性,我们需要对空气质量数据进行自动且精细的复核,从而及时、有效地发现仪器异常的情况,以便获得高质量的空气污染监测数据。本文将来源于仪器故障的空气污染物监测数据存在的变点称为“异常变点”,将时间、气象等因素导致的空气污染物监测数据正常变化导致的变点称为“正常变点”,上述两种变点构成了本文变点检测研究的主要内容。本文通过整理已有的研究发现,一方面,现有传统的变点检测方法能够在一定程度上发现数据的变化状况,可以检测到时间序列的变点,但这仅限于检测出时间维度上的“时间变点”;另一方面,仪器故障导致的数据变化与监测对象的自然变化单独来看是相似的,现有变点分析方法并不能判断空气质量数据的异常是来自于仪器故障还是检测对象的自然变化。因此仅考虑时间上的变化是不够的,考虑到空气污染物监测数据属于时空数据,利用空间上的相关性可以区分仪器故障与检测对象自然变化。于是,针对现如今监测数据的审核主要依赖于人工,效率比较低的现状,为了能更好地检测分析空气监测数据的质量问题,本文对空气质量数据异常情况进行详细分析,并且在传统变点分析方法的基础上,利用空气质量这种时空数据的时间、空间相关性提出了一种以空气质量为研究对象的时空变点自动检测的新方法。

本文提出了一种新的时空变点检测算法,用以自动识别空气污染物监测仪器的故障情形,该方法基于累计和(Cumulative Sum, CUSUM)变点检测方法构造时空数据异常变化的统计量,并且利用块抽样(Block Bootstrap)方法进行假设检验,从而验证数据是否异常,以此确保空气污染物监测数据的真实、有效性。文章对空气污染物监测数据在仪器故障和非故障的不同情况下产生的异常变点问题进行了详细的介绍与分析,并基于此设计了不同情形下的异常数据识别算法。对于本文针对空气质量数据提出的新的空气质量监测分析方

法，其在数值模拟和实际数据上均显示出较高的有效性。模拟结果显示，对于均值单变点情形而言，本文提出的时空均值变点(Spatio-Temporal Mean Change-Point, STMC)方法和稳健的时空均值变点(Spatio-Temporal Mean Change-Point with median, STMC-median)方法分别达到了 89%和 92%的检验准确率，高于 CUSUM 方法的 48%；对于方差单变点情形，本文提出的时空方差变点(Spatio-Temporal Variance Change-Point, STVC)方法达到了 92%的准确率，而 CUSUM 方法只有 45%。在均值多变点的模拟中，STMC-median 方法准确地检测到了均值变点的微小异常，同时方差多变点的模拟实验也表明，STVC 方法在不同类型的方差多变点数据上具有较强的异常方差变点检测能力。此外，PM_{2.5}的实际数据分析显示，本文设计的方法能够很好地识别 PM_{2.5}真实数据的异常和正常状况，说明该方法在此类时空数据变点检测问题中具有一定的适用性。

关键词：变点检测；CUSUM；时空数据；PM_{2.5} 质量分析

Abstract

In recent years, air quality has been paid much attention by the country. In order to ensure the validity and accuracy of the data collected by the air quality monitoring site, we need to automatically and finely review the air quality data, so as to detect abnormalities in the instrument in a timely and effective manner, and finally obtain high-quality air pollution monitoring data. In the paper, the abnormality of air pollutant monitoring data originating from the malfunctioning instrument is called "abnormal change point", and the normal change of air pollutant monitoring data caused by time, weather and other factors is called "normal change point". The above two change points constitute the main content of the change point detection research in the article. The paper summarizes the existing research and found that, on the one hand, the existing traditional change-point detection methods can detect the change of the data to a certain extent, and can detect the change points of the time series, but this is only limited to detecting the "time change point" in the time dimension. On the other hand, the data change caused by the instrument failure is similar to the natural change of the monitored object. The existing change point analysis method cannot judge whether the abnormality of the air quality data comes from the instrument failure or the natural change of the detected object. Therefore, it is not enough to only consider changes in time. Considering that air pollutant monitoring data belongs to spatio-temporal data, spatial correlation can be used to distinguish between instrument failures and natural changes in the detection object. Therefore, in view of the current situation that the review of monitoring data mainly relies on manual labor and is relatively inefficient, in order to better detect and analyze the quality of air monitoring data, the article analyzes the abnormalities of air quality data in detail. Based on the traditional change-point analysis method, the paper proposes a new method for automatic detection of spatio-temporal change points based on air quality by using the temporal and spatial correlation of air quality.

The paper proposes a new spatio-temporal change point detection algorithm to automatically identify the failure of air pollutant monitoring instruments. This method uses the Cumulative Sum (CUSUM) change point detection method to construct statistics of abnormal changes in spatio-temporal data, and uses the Block Bootstrap method to conduct hypothesis testing to verify whether the data is abnormal, so as to ensure the authenticity and validity of the air pollutant monitoring data. The article introduces and analyzes the abnormal change point of air pollutant monitoring data under different conditions of instrument failure and non-failure. Based on this, the abnormal data recognition algorithm under different conditions is designed. The new air quality monitoring and analysis method proposed in the paper for air quality data shows high effectiveness in both numerical simulation and actual data. The simulation results show that for the case of mean single change point, the Spatio-Temporal Mean Change-Point (STMC) method proposed in the paper and the robust Spatio-Temporal Mean Change-Point with median (STMC-median) method achieves 89% and 92% test accuracy, which are higher than the 48% of the CUSUM method. For the single change point of variance, the Spatio-Temporal Variance Change-Point (STVC) method proposed in the paper achieves an accuracy of 92%, while the CUSUM method only has 45%. In the simulation of the double mean change points, the STMC-median method accurately detects the slight abnormality of the mean change points. Simultaneously, the simulation experiment of the variance change points also shows that the STVC method has strong ability to detect abnormal variance change points on different types of variance change point data. In addition, the actual data analysis of PM_{2.5} shows that the method designed in the paper can well identify the abnormal and normal conditions of the real data of PM_{2.5}, which indicates that the method has a certain applicability in this kind of spatiotemporal data change point detection problem.

Key words: Change Point Detection; CUSUM; Spatio-temporal Data; PM_{2.5} Quality Analysis

目录

1 绪论..... 1

1.1 研究背景与意义 1

1.1.1 研究背景 1

1.1.2 研究意义 2

1.2 研究内容与组织结构 3

1.3 本文创新点与贡献 4

2 文献综述..... 5

2.1 无监督方法 5

2.2 有监督方法 9

3 变点方法介绍..... 11

3.1 变点问题的产生 11

3.2 变点问题介绍 11

3.3 变点检测方法介绍 13

3.3.1CUSUM..... 13

3.3.2 极大似然估计与似然比检验 15

3.3.3 移动平均控制图 16

3.4 单变点和多变点的检测 17

4 时空变点检测..... 19

4.1 问题背景 19

4.1.1 时空均值变点 21

4.1.2 时空方差变点 24

4.2 算法 26

4.2.1 异常均值变点算法 26

4.2.2 异常方差变点算法 31

5 数值模拟	37
5.1 单变点	37
5.1.1 均值单变点	37
5.1.2 方差单变点	43
5.2 多变点	46
5.2.1 均值多变点	46
5.2.2 方差多变点	48
6 实际数据分析	50
6.1 均值变点分析	50
6.1.1 正常均值变点检测	50
6.1.2 异常均值变点检测	52
6.2 方差变点分析	52
6.2.1 正常方差变点检测	52
6.2.2 异常方差变点检测	53
7 总结与展望	54
7.1 工作总结	54
7.2 研究展望	55
参考文献	56
致谢	62
附录	59

1 绪论

1.1 研究背景与意义

1.1.1 研究背景

如今我国主要矛盾转化为人民日益增长的美好生活需要和不平衡不充分的发展之间的矛盾，人民对良好生活环境的需求也更加迫切，而空气质量的好坏是影响一个地区人民生活质量的重要因素之一。空气质量会随着季节更替、人类生活生产而变化，近年来，由于工业发展和城市化，中国也面临严峻的空气质量问题。习近平总书记于 2005 年在浙江安吉村时提出了“绿水青山就是金山银山”的理论，党的十八大上，以习近平同志为核心的党中央把生态文明建设纳入中国特设社会主义事业的建设中。渐渐地，社会各界开始调整生活生产方式以改善被破坏的环境，人们逐渐关注起了环境质量，这一点尤其体现在地方监测站点发布的空气污染物浓度监测数据上。

空气监测数据的质量对于空气质量的评估和研究至关重要。质量不好的监测数据是指，收集到的数据并不是气候真实变化反应。然而，由于机器故障、记录员操作失误抑或人为刻意修改了数据等等，会对实际观测到的数据有很大影响。通常情况下，我们对监测数据的质量进行人工审核分析，当观察到监测数据异常变化后，我们会去寻找原因，判断是因为气象等会影响空气污染物浓度的自然因素还是其他非自然因素所导致的，并及时调整，但是不得不承认，人工审核的效率还是比较低的，这使得空气污染物的变点检测成本过高。在当下生态文明建设的方针下，部分企业、地方政府仍然没有转变以环境换经济的理念，还在刻意破坏环境，包括人为修改环境监测数据。为了有效遏制自动监测数据的弄虚作假行为，自 2017 年 1 月 1 日开始施行的由最高人民法院、最高人民检察院颁布的《关于办理环境污染刑事案件适用

法律若干问题的解释》规定中指出：对重点排污单位篡改、伪造自动监测数据或者干扰自动监测设施，排放重点污染物的，认定为“严重污染环境”，将根据《刑法》的相应条目依法处置。2017年，西安长安区、阎良区环境监测站点数据造假案开庭处理，案件中监测站点工作人员在几年时间里一直通过人为干扰监测仪器使得收集到的污染物浓度数据远低于真实值，这一案件在当时备受社会关注，可以预见地，空气质量监测数据的准确、真实性在这之后会受到社会更广泛的关注。因此很有必要对站点监测得到的数据进行质量分析，从而识别由于机器故障产生的异常数据。

鉴于当前的空气质量数据是人工审核分析，因此设计更加高效的空气质量数据异常变化自动识别算法就很有必要。空气监测数据的异常变化与正常变化在变化形式上是相同的，因此可以使用变点检测方法来识别数据的变化，变点分析方法通常是去判断一段历史数据有没有改变，并且推断在什么时刻改变是显著的。现有关于空气污染数据变点的研究，无论是时间序列还是面板数据的都有很多，但是这些研究仅仅只是利用空气污染数据时间层面的信息，分析得到污染物浓度的大概变化情况，却没有利用变点检测等方法去分析数据质量的好坏，对于污染监测站点的空间相关性信息利用不足，因此，本文认为，现已有的方法对于污染物监测数据质量监控不适用。显而易见的是，对于同一区域的不同监测站点，监测到的数据是有空间相关性的，因此利用其它站点监测污染物数据去辅助研究某一站点的监测污染物数据是否异常变化是有用的，并且探索有效的方法分析判断污染物浓度数据的真实性、有效性十分有必要。

1.1.2 研究意义

现有变点检测方法主要针对时间序列，这些方法可以检测 $PM_{2.5}$ 时间序列的变化，可是并不能单凭有变点就判断仪器出现故障，因为正常的气候变化也会导致 $PM_{2.5}$ 的变化。单个站点监测的 $PM_{2.5}$ 污染数据属于时间序列数据，利用变点检测方法检验数据有变点至少可以判断数据是有变化的，而多个临近站点的监测数据具有空间相关性，在变化趋势上，是高度相关的，因此可以利用临近站点的数据去辅助分析单个站点变点前后数据变化是否一致，从

而判断数据变化是否异常——异常的数据变化可以推断出仪器故障。现实生
活里是通过人工肉眼观测对污染物浓度数据进行质量审核，这不仅繁琐并且
效率低下。本文通过建立空气污染时空数据质量检测算法，在数值模拟上得
到了良好的表现，拓展了变点检测方法在空气监测数据质量分析上的应用，
对空气污染物浓度数据的质量审核有借鉴意义。

1.2 研究内容与组织结构

本文基于 CUSUM 变点检测和 Bootstrap 抽样设计出一种新的时空数据变
点检测算法，用于对空气质量数据的检测分析，以便查找出空气质量数据的
异常变化。算法先使用 CUSUM 均值变点检测方法获得数据均值变点的估计
值，再借助空间上临近的站点数据进行差异分析，最后使用针对具有时间相
关性数据的抽样方法——Block Bootstrap 抽样方法对估计变点时间前后的差
异数据进行重采样，从采样数据中获得统计量的经验分布，然后去做原假设
为仪器正常的假设检验。本文不仅设计出了均值单变点、方差单变点检测算
法，还推广到了均值多变点、方差多变点情形，同样的到相应算法。并且本
文从模拟数据分析得到以下结论：新提出的算法比 CUSUM 算法能更好的检
测数据是否存在异常均值、方差变点。实际数据分析也表明了算法的实际合
理、有效性。本文的章节及内容如下。

第一章：绪论。介绍本文的研究背景与意义、研究内容与组织结构，以
及本文的创新点。

第二章：文献综述。从有监督、无监督视角归纳总结了国内外关于变点
的文献资料的，综述变点问题的研究结果以及现状、当今变点分析方法的应
用领域。

第三章：介绍变点问题由来，同时，对变点分析方法里的 CUSUM（累计
和方法）和极大似然方法以及移动平均控制图法做详细介绍。

第四章：详细介绍、分析了空气污染物监测仪器故障导致的数据异常状
况与正常状况，以及两者的差别，提出了针对污染物浓度异常均值、方差变
点的时空变点检测算法。

第五章：设计合理的模拟数据，运用新提出的算法进行分析，并与已有

的变点检测方法进行比较。从而验证了本文算法的合理性、有效性。

第六章：实证研究部分，利用提出的方法研究北京市 $\text{PM}_{2.5}$ 数据，算法成功识别数据中没有异常均值、方差变点存在，并且在稍作微调的实际数据上算法发现了数据的异常变化，识别到了异常变点。

第七章：总结与展望：回顾了设计时空数据变点检测算法的背景、目的，总结了本文设计的变点检测算法，并且分析、评价了在模拟数据分析以及实证分析中算法的表现；分析了本文算法的不足、局限性，并指出了本文在算法以及研究思路可以改进的地方和方向。

1.3 本文创新点与贡献

本文的创新点与贡献有：

(1) 本文提出了基于 CUSUM 方法、利用 Block Bootstrap 抽样方法的针对空气质量监测数据的时空数据均值变点检测、时空数据方差变点检测新方法，该方法利用了空气质量数据的时间与空间信息：在时间序列数据寻找变到点后利用空间信息去识别变点的状态，根据变点状态来判断数据质量。同时在模拟数据与实际数据上均获得了不错的效果。

(2) 本文提出的新的时空变点检测方法可以自动识别空气污染监测数据的异常、正常状况，对于判断数据质量、识别仪器是否故障等问题十分有用。并且相比人工审核数据而言，本文提出的方法更加自动、高效。

(3) 本文根据提出的算法设计了检验时空数据正常与异常状态的 R 函数包，以供大众使用。

2 文献综述

已有的变点研究起始于统计控制过程(Statistical Process Control, SPC), 从被提出到如今, 不管是基于传统的无标签的时间序列数据变点研究还是如今使用机器学习方法中的有监督和无监督方法研究变点问题, 它们已经不断被很多学者完善和拓展。监督学习和无监督学习是机器学习算法中根据使用的数据有无类别标签产生的一种分类, 下面将引用这两个术语, 从有监督方法和无监督方法两方面分别介绍变点问题中一些具有代表性的方法。

2.1 无监督方法

无监督学习算法通常用于发现未标记数据中的模式。在变点检测问题中, 此类算法可用于对时间序列数据进行分段, 从而根据数据的统计特征查找变点。无监督分割针对时间序列数据的变点问题是十分有用的, 因为它可以处理各种不同的情况, 而无需对每种情况进行事先训练。下面介绍似然比检验、子空间模型、概率模型、核方法、基于图的方法和分类算法等基于无监督学习的变点检测方法及其对应的文献。

似然比检验是变点检测里无监督学习中应用很广泛的方法。变点检测的一种典型统计公式是分析候选变点之前后的数据概率分布, 如果两个分布明显不同, 则将候选者识别为变点。因此似然比检验通过直观的监视时间序列数据中两个连续间隔之间的似然比的对数, 以检测变点。以下介绍似然比检验下的变点检测方法。

Page(1954)首次提出了变点方法里经典的累计和(Cumulative Sum, CUSUM)控制图, 这是与之前的参数是否变化的检验方法不相同的。之前的方法是根据当前采样得到的统计量去判断参数是否变化, 以及通过现在的采样合并之前的样本统计得到统计量去判断参数是否变化, 将统计量画在图上,

如果超过控制线就认为参数发生变化,然后采取措施。但有时候,即便参数没有变化,统计量会以一定概率超过统计线,并且,控制线的位置很依赖参数。Page(1954)为了解决当时变点检测方法的问题,发明的一种新的方法,称为CUSUM方法,通过计算CUSUM统计量,检验过程是否有变点。该方法既利用了当前抽样的样本计算统计量,又利用了之前抽样样本计算得到的统计量,使得可以检验过程中微小的变化。Page(1954)对参数的CUSUM检验做了详细理论推导,给出了单边检验和双边检验下的统计量以及其性质。

Hinkley(1970)首次从极大似然角度出发研究变点问题,推导得出了变点的极大似然估计值来自两个独立的随机游走结论,并给出了估计参数的形式、渐近分布等性质,给出了单边、双边检验下的似然比检验,由此提出了研究变点问题的极大似然方法和似然比检验理论。同时从极大似然方法出发,推导出了CUSUM方法的一般形式,说明了CUSUM方法也是一种极大似然方法。由此,似然比检验方法在变点检测问题上被广泛应用。

另一种常用的似然比检验方法是Change Finder,它可以将变点检测的问题简化为基于时间序列的离群值检测。此方法将自回归(AR)模型拟合到数据上以表示时间序列的统计行为,并逐步更新其参数估计值,以便逐渐消除过去示例的影响。Yamanishi 和 Takeuchi(2002)首先提出了时间序列数据的自回归模型在线折扣学习算法Change Finder方法,该方法可以统一处理离群值检测和变点检测两个问题。用自回归模型以表示生成时间序列数据的基本机制,并提出了一种在线折价学习AR模型的新算法从时间序列数据中检测离群值,并将变点检测的问题简化为根据移动平均分数的时间序列进行的离群值检测。

由于Change Finder依赖于预先设计的参数模型,并且在现实世界中的变点检测方案中灵活性较差,因此一些最新研究通过直接估算概率密度的比率而引入了更为灵活的非参数变化,而无需执行密度估算。密度比估计思想的基本原理是:知道两个密度意味着知道密度比,但是,反之则不成立。虽然知道这种比率并不一定意味着知道两种密度,但是,直接密度比估计实质上比密度估计简单。Kawahara 和 Sugiyama(2009)首次提出了直接密度比估计(Direct Density Ratio Estimation)方法,该方法将变点检测问题表述为比较生成时间序列数据的两个连续时间间隔内的概率分布的问题,从而估计概率密度的比率,而不是概率密度本身为目的。这种表述使其能够避免非参数密度估

计。Kawahara 和 Sugiyama(2009)设计了基于直接密度比估算的变点检测算法,该算法可以在线高效地进行计算。子空间模型是对时间序列受约束的子空间的分析来进行变点检测。这种方法与控制理论领域里的系统识别方法密切相关。其中一种子空间模型叫子空间识别(Subspace Identification, SI)。Kawahara 等(2007)首先提出 SI 模型,该方法考虑了噪声项,且基于扩展的可观察性矩阵的列跨越的子空间大约等于时序数据的子序列所跨越的子空间的原则,并通过估算时间序列数据的 SSM 扩展可观察性矩阵的列空间来执行变点检测,并基于该子空间评估新样本。另一个子空间模型方法称为奇异谱变换(Singular Spectrum Transformation, SST),Moskvina 和 Zhigljavsky(2003)首先提出了 SST 方法,将奇异谱分析应用于时间序列变点的检测,提出并研究了基于奇异谱分析的时间序列变点检测算法,与 SI 模型不同,它不考虑系统噪声。

变点检测的概率方法代表有贝叶斯方法和高斯过程。Chernoff 和 Zacks(1964)首次引入了贝叶斯方法来得出变点检验统计量,同时派生了单侧统计量以测试独立正态随机变量序列的平均值中的变点。该方法首先假定与零假设和替代假设相关联的未知参数的先验分布。然后,通过推导无条件似然来消除额外的参数,并通过考虑似然比来获得贝叶斯型统计量。不过很长时间,贝叶斯方法都只用在了离线数据的变点检测中,Adams 和 MacKay(2007)是其中一批最早的利用贝叶斯方法研究在线数据变点检测的学者。Adams 和 MacKay(2007)研究了在线贝叶斯变点监测(Online Bayesian Change Point Detection, BCPD)。与仅考虑成对连续样本的先前方法相比,BCPD 将新的滑动窗口特征与基于相同状态的所有先前间隔的估计值进行比较。BCPD 通过定义一个辅助变量游程长度变量来估算后验分布,游程长度表示自上一个变点以来经过的时间。给定时刻 t 的行程长度,如果此时产生变点,则下一个时间点的行程长度重置为 0,否则(没有产生变点)增加 1。高斯过程是另一个用于平稳时间序列分析和预测的概率方法。陈杰(2020)从非贝叶斯和贝叶斯角度出发,分别研究了并行数据流中多变点检测问题。Chandola 和 Vatsavai(2010)采用高斯过程回归方法以在线方式检测遥感数据时间序列中的变化。尽管高斯过程(GP)已被广泛用作基于核的回归和分类学习方法,但由于涉及高昂的计算成本,其在大规模时空数据集(如遥感数据)中的适用性受到限制。Chandola 和 Vatsavai(2010)将基于 Toeplitz 矩阵的解决方案应用到基于 GP 的

变点检测算法中，而且证明了算法在识别归一化植被指数(NDVI)数据变化中的有效性。

尽管核方法被广泛应用于有监督学习，但是也被应用到没有标签的时间序列变点检测。Harchaoui 等(2009)提出了基于最大核 Fisher 判别比作为分段之间同质性度量的统计量，并在零假设下（没有发生变化）导出其极限分布，在备选假设下（发生变化）建立一致性。以此建立统计假设检验程序测试数据是否有变点存在，当检测到有变点时估计变点位置，并且在大样本下，达到规定的错误警报概率和以概率趋向于 1 的检测概率效果。但 Kernel 方法有严重缺陷：基于核的方法严重依赖核和参数的选择，并且在高维数据下此问题更加严重。

基于图的变点检测框架是一种非参数方法，该方法将两样本测试应用于等效图，以发现观察值中是否存在变点。Chen 和 Zhang(2014)提出了一种基于扫描统计的新方法，该方法利用表示观察值之间相似度的图表，构建基于图的两样本检验，来检测和估计变点。虽然基于图的方法是非参数的，并且可以应用于任何数据集，只要可以定义样本空间上的信息相似性度量即可。然而，基于图的变点检测方法并不能利用时间序列观测本身的大量信息，而不是依赖于定义适当的图结构。

变点检测的问题也可以被视为具有已知或未知数目类别的聚类问题，这样的话，类内的观测具有相同分布，而相邻类之间的观测则具有不同分布，因此可以使用聚类方法分析变点问题。如果 t 处的数据与 $t+1$ 处的数据点属于不同的类，则在这两个时刻的观测值之间会出现一个变点。第一种用于变点检测的聚类方法由 Keogh 等(2001)提出，这种方法是将滑动窗口和自下而上的方法进行组合，称这一种变点检测方法为 SWAB(Sliding Window And Bottom-up)。第二种基于聚类的变点检测方法是利用最小描述长度对子序列进行分组 (Rakthanmanon 等, 2011)。第三种通过对时间序列聚类寻找变点的方法是 Shapelets 方法, Zakaria 等(2012)将 Shapelets 概念加入到时间序列数据的聚类中，并首次证明了该方法可以从未标记的时间序列数据中学习到不明显的变点。还有一种基于时间序列聚类方法的变点检测方法是模型拟合进行的，Tran(2013)提出了多变量数据流的自动变点检测和反应性聚类算法，当新数据不适合任何现有集群时，可以认为有变点产生。彭娜(2019)通过构建基

于 SOM 算法和 Mini Batch K-means 算法的两层聚类模型来对激进驾驶行为进行检测分析,检测行车的急加速、急减速、急转弯、急加速转弯、急减速转弯 5 种激进行为,检测准确率达 94.68%。

2.2 有监督方法

传统的变点检测方法是基于无标签的时间序列数据来分析、估计时间序列数据的变点问题,有监督的变点检测方法则使用有标签的时间序列数据,将变点检测问题转换为分类问题,然后通过监督方法或者半监督方法来进行分类。有监督的变点检测方法是学者们将变点问题应用到标签数据的重要尝试,其中一个较为经典的应用场景就是对行为数据的变点检测。当移动设备普及之后,收集个人的行为数据(位置、速度、状态等)就更加容易,分析和识别个人的行为数据对于监控个人健康等问题就越发重要,因此广大学者将变点检测应用到行为识别(Activity Recognition, AR)等领域。变点检测的监督学习方法包括决策树、支持向量机、隐马尔可夫模型(Hidden Markov Model, HMM)与高斯混合模型(Gaussian Mixture Model, GMM)等。

Marmasse(2004)等首先提到了使用 GPS 和加速度计传感器进行运输模式推断的方法,运输模式包括:静止、步行、跑步、骑自行车、机动。Zheng 等(2008)从原始 GPS 数据中挖掘用户运输模式知识从而改进 Web 上的应用程序并增强其连接性。Zheng 等(2008)研究了基于变点的分割方法、推理模型和基于条件概率的后处理算法在用户运输模式识别里的应用。将基于变点的细分方法与两个基线进行了比较,包括基于统一持续时间和基于统一长度的方法。同时,在实验中研究了四种不同的推理模型,包括决策树,贝叶斯网络,支持向量机(SVM)和条件随机场(CRF)。在收集到的六个月内 45 位用户的 GPS 数据上评估了以上方法。结果表示,除其他两种分割方法外,基于变点的方法在预测运输方式和检测运输方式之间的转换方面具有更高的准确性。在基于变更点的分割方法上,决策树的表现优于其他推理模型。

Reddy 等(2010)创建了由决策树(Decision tree, DT)和一个一阶离散隐马尔可夫模型(DHMM)组成一个简便(无特定位置和方向设置)分类系统,该系统使用具有内置 GPS 接收器和加速度计的手机,确定的运输方式包括个人是

静止的、步行的、跑步的、骑自行车的还是机动的。Reddy 等(2010)训练 DT 用以对数据进行初始分类,再用 DHMM 推理出不同运输方式的连续部分,并得出最终的分类边界,返回推理出的运输模式起始时间、位置、类型,基于来自 16 个用户的 120 个小时数据的数据集,该系统对用户没有严格的位置和方向要求,同时仍达到 93.6%的高精度水平。

Wei 和 Keogh(2006)提出了一种基于最近邻(Nearest Neighbor)方法构建时间序列数据分类模型的半监督技术,该文章通过对包括心电图、手写文档和视频数据集在内的各种数据进行全面的实验来评估该方法,并且验证了该方法仅需要少量带标签的数据即可构建准确的分类模型并自动识别变点。Cleland 等(2014)讨论了基于移动工具的行为识别(Activity Recognition, AR)问题,他们使用高斯混合模型(Gaussian Mixture Model, GMM)作为分类算法从而进行行为识别,达到可以识别从一组特定活动(例如,步行和跑步)到静止活动的状态转换的变点,在结构化模拟中可以达到 100%的准确性。Desobry 等(2005)针对变点检测问题提出了一种新颖的机器学习方法来对音乐数据进行分割以识别变点,该变点检测方法是使用特征空间中新定义的相异性度量来实现的,而该相异性度量是使用支持向量机的核(Kernel)技巧在输入空间中进行计算的。这种方法对于异常值是十分稳健的,并且不需要建立已知基础分布的统计模型。该方法的模拟结果表明,Desobry 等(2005)提出的核变点检测(Kernel Change Detection, KCD)算法在音乐分割中的应用显示出良好的效果,而且 KCD 算法优于标准的广义似然比(Generalized Likelihood Ratio, GLR)方法。也是因为这篇文章,KCD 算法被广泛应用到音乐和语音信号分割的研究中。Feuz 等(2014)根据人类活动的活动方式过渡进行变点的检测,当人类从一个活动转变到另一个活动时,设计的算法会对基于传感器收集到的数据进行分析,并在活动过渡期间识别出活动的转变,从而记录检测出的变点以及提醒当事人正在发生的活动的转变。该研究方法可以对认知障碍人群的活动进行实时的活动过渡识别,并在活动过渡期间对其进行提醒与干预。Feuz 等(2014)在该文章中尝试了支持向量机、朴素贝叶斯、逻辑回归等方法来检测活动过渡的变点,并且取得了较好的结果。

3 变点方法介绍

3.1 变点问题的产生

控制图亦称“质量管理图”、“质量评估图”，是根据假设检验原理构造的一种图，用于监测生产过程是否处于控制状态，是统计质量管理的重要手段和工具。

世界上第一个控制图是 Shewhart X 控制图，它首先由 Shewart 于 1925 年基于原理提出，其适合检验生产过程中的较大偏移，这个方法利用的样本信息仅仅是当前抽样信息，而丢弃了之前抽取的样本，因此效率比较低。Page(1945)提出了 CUSUM(Cumulative Sum)检验程序，目的就是改进 Shewhart X 控制图没有利用之前样本信息的低效率，使用累计和统计量来构造控制程序。之后 Robert(1959)发明了 EWMA(Exponentially Weighted Moving Average)控制图。控制图的内容也不断被充实填补、丰富、完善，控制图理论虽然最开始用在检测生活生产中是否有异常变化，但其本质还是利用样本信息对样本的分布做推断。控制图的一个重要应用就是变点检测。

3.2 变点问题介绍

假设有一段序列数据， $x_{1:n} = (x_1, \dots, x_n)'$ 。如果存在变点，那么以变点发生时间为分割线得到的前后样本序列在某种程度上是不同的，通常指的不同是样本来自相同分布族下、参数不同的分布，即：

$$\begin{aligned} x_i &\in F(x, \theta), 1 < i < \tau_1. \\ x_i &\in F(x, \theta'), \tau_1 \leq i < T, \theta \neq \theta'. \end{aligned}$$

其中 F 是样本的分布函数， θ 和 θ' 是不同的参数， τ_1 是变点发生的时间。

变点检测问题是检测序列数据在某个指标上是否有变点、变点出现时刻，

以及根据变点分割数据后来自不同分布的参数进行估计，通常情况下可以分为两个步骤：有无变点的假设检验和变点的参数估计。

变点按照数量可以分为：单变点和多变点。设变点数量是 ω ，那么 $\omega \in \{1, \dots, n-1\}$ 。如果 $\omega = 1$ ，那么就是单变点，那么 $\{x_1, \dots, x_{\tau}\}$ 和 $\{x_{\tau+1}, \dots, x_n\}$ 的分布就不同。图 1 和图 2 是模拟的正态分布的单变点（变点时刻为 τ_1 ）情况下均值变点（变点前后数据服从均值不同方差相同的正态分布）和方差变点（变点前后数据服从方差不同均值相同的正态分布）情况。




图 1 均值变点




图 2 方差变点

假设数据分布为 $F(x, \theta)$, $\theta \in \Theta$, Θ 为参数空间, 对单变点的假设检验如下:

$$H_0: x_{1:n} \in F(x, \theta).$$

$$H_1: x_{1:i} \in F(x, \theta), x_{i+1:n} \in F(x, \theta').$$

原假设 H_0 意味着, 序列 $x_{1:n}$ 是来自同一分布 $F(x, \theta)$, H_1 意味着 $x_{1:i}$ 和 $x_{i+1:n}$ 分别来自参数不同的分布 $F(x, \theta)$ 、 $F(x, \theta')$, 其中 θ 与 θ' 不同。变点检测的第一步就是要检验 H_0 是否显著。

H_0 的显著性检验与参数的估计执行步骤因方法不同而有所差异, 参数的估计包括分布函数的参数与变点时间的估计。不同检验方法理论下, 有各自的参数、变点时间的估计, 比如累计和检验是在检验程序结束时计算得到参数的估计, 而似然比检验则是在最大似然的方法估计参数与变点时间后再进行。

如果 $\tau = m$, $1 < m < n$, 变点检测就对应多变点问题。将变点按照顺序进行标记 $\tau_{1:m} = (\tau_1, \dots, \tau_m)$, 其中 $\tau_i < \tau_j$ 当且仅当 $i < j$, 并假定 $\tau_0 = 0, \tau_{m+1} = n$ 。在多变点情况下, 样本序列按照 m 个变点划分为 $m+1$ 段子样本, 第 i 个样本段 $y_{(\tau_{i-1}+1):\tau_i} = \{y_{\tau_{i-1}+1}, \dots, y_{\tau_i}\}$, 多变点假设检验如下:

$$H_0: x_{1:n} \in F(x, \theta).$$

$$H_1: x_{\tau_{i-1}+1:\tau_i} \in F(x, \theta_i), 1 < i < n.$$

其中 $i \neq j$ 时, $\theta_i \neq \theta_j$ 。而多变点下的参数估计就更加复杂, 文章后面会详细介绍。

3.3 变点检测方法介绍

控制图领域的方法都可以在一定程度上检测变点, 而 CUSUM 方法的优势就在于, 其利用了之前每一步的判断信息, 通过信息累加的形式, 可以做到对参数微小变化的检测。以下主要介绍 CUSUM 方法以及极大似然估计。以上三种方法都是无监督学习方法。

3.3.1 CUSUM

CUSUM (累计和检验) 由 Page(1954)基于序贯分析原理中的序贯概率比

检验(Sequential Probability Ratio Test, SPRT)理论提出,该方法提出目的是改善以往变点检测方法的缺陷,在此之前的生产过程变化的检验主要有两种方式,(1)每次抽样后根据样本计算统计量,如果统计量超过控制范围,认为过程出现变点(Shewhart X 控制图)。(2)每次抽样后,利用之前的数据一起得到统计量,判断是否产生变点。CUSUM 方法是这两者的过渡方法,它既没有第一种方法武断也没有第二种方法计算的无效率,并且 CUSUM 方法可以检测参数的微小变化。

Page(1954)给出了单边检验程序,单边检验就是指检验参数在一个方向的变化,比如以下的单边假设检验:

$$H_0: \alpha_0 = a, H_1: \alpha_0 > a.$$

针对该单边检验问题,记第 j 次抽样得到的样本得分是 x_j ,第 j 次抽样的累计和是 S_j , $S_j = \sum_{k=1}^j x_k$ ($j = 1, \dots, n$),其中 x_k 并不是样本,而是样本计算得到的统计量,定义 $S_0 = 0$,如果在第 j 次抽样有

$$g_j = S_j - \min_{0 \leq i < j} S_i \geq h,$$

那么就认为有变点产生,对于变点时间的估计如下:

$$\tau_1 = \min(j: g_j \geq h).$$

通常情况下,需要在数据中检验参数是否变化,即既要检验参数显著变大或者显著变小的检验——双边检验。双边检验程序如下:

$$g_j^+ = S_j - \min_{0 \leq i < j} S_i \geq h^+, \text{ or } g_j^- = \max_{0 \leq i < j} S_i - S_n \geq h^-.$$

其中 $S_j = \sum_{k=1}^j x_k$ ($j = 1, \dots, n$),双边检验下的变点估计时间如下:

$$\tau_1 = \min(j: (g_j^+ \geq h^+) \cup (g_j^- \geq h^-)).$$

累计和的单边检验程序等价于 Wald 序贯检验。其中 Wald 检验程序边界是 h ,初始得分是0。因此 CUSUM 检验的控制线 h 、 h^+ 、 h^- 可以通过设计 Wald 序贯检验获得。具体可以参考 Page(1954)。

3.3.2 极大似然估计与似然比检验

Hinkley(1970)首次提出了使用基于似然方法来检测变点的思想, 得出了正态分布观测值中均值变化的似然比检验统计量的渐近分布。考虑以下模型:

$$X_t = \theta(t) + \varepsilon_t (t = 1, \dots, T).$$

其中 ε_t 是均值为0且不相干的误差项, $\theta(t)$ 是连续的均值函数, 文章考虑 $\theta(t)$ 是常数的情况, 当有变点发生时, 有如下所示的变点模型:

$$X_t = \theta_0(t) + \varepsilon_t (t = 1, \dots, \tau).$$

$$X_t = \theta_1(t) + \varepsilon_t (t = \tau + 1, \dots, T).$$

计算样本下的对数似然函数 $L(t)$, 其中 f 是概率密度函数:

$$L(t) = V_t + \sum_{j=1}^T \log f(x_j, \theta_1),$$

$$U_j = \log f(x_j, \theta_0) - \log f(x_j, \theta_1), \quad V_t = \sum_{j=1}^t u_j (t = 1, \dots, T-1).$$

因 $L(t)$ 第二项不变, 故最大化似然函数 $L(t)$ 等价于最大化 V_t , 从而得到变点 τ 的似然估计量 $\hat{\tau}$ 。得到似然估计量后, 做假设检验。由 $V_t - V_\tau$ 得到以下两个随机游走:

$$W = \left\{ 0, Y_1, Y_1 + Y_2, \dots, \sum_{j=1}^{\tau-1} Y_j \right\}.$$

$$W' = \left\{ 0, Y'_1, Y'_1 + Y'_2, \dots, \sum_{j=1}^{T-\tau-1} Y'_j \right\}.$$

其中, $Y_j = -U_{\tau-j+1}$ 和 $Y'_j = U_{\tau+j}$ ($j=1, 2, \dots$)。记 $\max(W) = M, \max(W') = M'$, 根据 W' 和 W 关系刻画 $\hat{\tau}$ 与 τ 的关系如下

$$\hat{\tau} = \tau \equiv M = M' = 0.$$

$$\hat{\tau} = \tau + k \equiv M' > M, M' > 0.$$

$$\hat{\tau} = \tau - k \equiv M > M', M > 0.$$

记 M 、 M' 的分布函数以及相关符号如下：

$$\begin{aligned}\alpha(x) &= pr(M \leq x), \alpha'(x) = pr(M' \leq x). \\ I &= \sup \left(k, M = \sum_{j=1}^k Y_j \right), I = 0 \text{ if } M = 0. \\ I' &= \sup \left(k, M = \sum_{j=1}^k Y'_j \right), I = 0 \text{ if } M' = 0. \\ \beta_k(x) dx &= pr(I = k, x \leq M < x + dx). \\ \beta'_k(x) dx &= pr(I' = k, x \leq M' < x + dx).\end{aligned}$$

利用上面的符号，可以推导出最大似然估计 $\hat{\tau}$ 与 τ 差异的渐近分布

$$\begin{aligned}pr(\hat{\tau} = \tau) &= \alpha(0) * \alpha'(0). \\ pr(\hat{\tau} = \tau - k) &= \int_0^\infty \beta_k(x) * \alpha'(x) dx. \\ pr(\hat{\tau} = \tau + k) &= \int_0^\infty \beta'_k(x) * \alpha(x) dx.\end{aligned}$$

对于双边检验 $H_0: \tau = \tau_0, H_2: \tau \neq \tau_0$ ，在参数 θ_0 和 θ_1 已知情况下，根据以上推导可以得到双边检验的似然比统计量以及其渐进分布：

$$\Lambda_2 = \max(M, M') \quad P_2(x) = pr(\Lambda_2 \leq x) = \alpha(x)\alpha'(x).$$

对于单边检验 $H_0: \tau = \tau_0, H_1: \tau > \tau_0$ ，在参数 θ_0 和 θ_1 已知情况下，根据以上推导可以得到单边检验的似然比统计量以及其渐进分布：

$$\Lambda_1 = \max_{t \geq \tau_0} \sum_{i=1}^t U_i - \sum_{i=1}^{\tau_0} U_i \quad P_1(x) = pr(\Lambda_1 \leq x) = \alpha'(x).$$

以上的推导对 X_t 分布未作任何假设，从而得到了参数的似然比检验，对于参数 θ_0 和 θ_1 未知情况下，Hinkley(1970)并未给出变点发生时间的似然估计量与真实值间差异的渐近分布。但是具体给出了 X_t 服从正态分布下，参数已知和未知时的渐近分布，具体可参考 Hinkley(1970)。

3.3.3 移动平均控制图

考虑参数 θ 的假设检验问题：

$$H_0: \theta = \theta_0,$$

$$H_1: \theta = \theta_1.$$

利用似然方法的思想，如果对数似然 $\log \prod_{i=1}^k (p_{\theta_1}(x_{k-i})/p_{\theta_0}(x_{k-i}))$ 过大，那么没有理由拒绝原假设，反之则拒绝原假设。对于时间序列数据，某一时刻的样本距离当前时间点越近，其重要程度应该越高，基于这种思想，对第 i 个时间点的样本 x_i 赋予不同权重 γ_i ，从而得到以下的检验统计量：

$$g_k = \sum_{i=0}^l \gamma_i \ln \left(\frac{p_{\theta_1}(x_{k-i})}{p_{\theta_0}(x_{k-i})} \right).$$

如果

$$g_k \geq h,$$

则拒绝原假设，认为参数 θ 发生了变化，程序发出警告的时间点由以下等式给出：

$$t_a = \min\{k: g_k \geq h\}.$$

因为固定窗口大小为 l ，只使用前 l 个样本点来计算检验计量，因此该方法被称为有限移动平均法。

在 1959 年以前，大多数学者大多在均值变化的变点检测方法研究上使用移动平均法，学者 Roberts(1959)受之前学者所做研究的启发，首次在 $\bar{X}$ 控制图方法上加入几何移动平均方法来检测变点，从而提出变点检测的几何移动平均法，并证明了其检测变点问题的相关性质。相对于有限移动平均法而言，该方法使用了所有可以利用的历史样本，并且对于权重的选择更为简便规范。在其之后，Hines(1976)又对几何移动平均法在变点识别上的应用做出了改进。

变点检测中的几何移动平均法使用以下检验统计量：

$$g_k = \sum_{i=0}^{\infty} \gamma_i \ln \left(\frac{p_{\theta_1}(x_{k-i})}{p_{\theta_0}(x_{k-i})} \right),$$

其中 $\gamma_i = \alpha(1 - \alpha)^i, 0 < \alpha < 1$ ，程序的停止时间则由以下等式给出：

$$t_a = \min\{k: g_k \geq h\}.$$

3.4 单变点和多变点的检测

假设观测序列为 $x_{1:n} = (x_1, \dots, x_n)$ ，如 2.1 节变点问题的介绍，单变点指的是针对序列中只有一个变点情况做分析处理，可以使用 CUSUM、极大似然和

似然比检验等方法去检验变点、估计参数，此时每一个样本都可能是变点，因此可以在 $O(n)$ 的时间下检测并得到变点的估计值；但对于多变点而言就比较复杂。

CUSUM 检验的检验步骤，是每次从样本中获得连贯的时间序列数据，基于该批次数据计算得到 CUSUM 统计量，通过累计和与警戒上线 h^+ 、下线 h^- 的比较可以知道样本是否出现变点。因此，对于一段历史数据的多变点检测，CUSUM 检验只需有序的获得连续时间样本，并做单变点的 CUSUM 检验，如果统计量未超过警戒线则继续抽取样本做检验，如果超过警戒线就标记变点时间，对于剩下的数据重新获取样本、重复单变点检测过程即可。

似然比检验在多变点检测上比CUSUM检验复杂。这是因为似然比检验一次性获得所有样本，并在所有样本上根据候选变点来分割数据计算似然函数，就单变点情况而言，计算 n 个候选变点的时间复杂度是 $O(n)$ ，但是对于2个变点，这种分割计算似然函数的时间复杂度就是 $O(n^2)$ ，正是因为似然比检验的时间复杂度随变点个数呈现幂级数增长的特点，才有许多学者提出优化方法来解决这个问题。Edwards和Cavalli-Sforza(1965)，Scott和Knott(1974)以及Sen和SrivasTava(1975)先后提出完善多变点检测的二进制分割检测，达到 $O(n \log n)$ 的时间复杂度。Auger和Lawrence(1989)，Bai和Perron(1998)先后提出完善了分段邻居算法，该算法使用动态编程技术寻找最佳分割点，在最大变点数是 Q 的情形下，算法时间复杂度是 $O(Qn^2)$ ，但是比二分检测算法更为准确。Killick等(2012)提出了PELT算法，由于PELT的特殊构造以及其使用了动态编程技术和自动修剪技术，因此算法计算效率更加高效，达到了 $O(n)$ 的时间复杂度，并且其准确率也很高。

4 时空变点检测

4.1 问题背景

在现实生活中，人们通过气象监测站发布的空气质量数据来了解空气质量状况，比如空气污染物 $\text{PM}_{2.5}$ 、 PM_{10} 等的浓度数据，以及空气质量综合指标，这里的综合指标是通过部分污染物浓度计算得到的该区域的空气质量得分。由于机器故障导致的异常状况，会使得仪器测量到的污染物浓度出现偏差。这就需要时刻注意监测数据是否出现异常情况，在观察到异常情况时，比如浓度突然的升高、下降等情况，就要排查仪器是否出现故障，从而确保测量到的污染物浓度数据是真实可靠的。分析监测数据是否异常，通常是通过观察数据是否有大的起伏，或者观察员凭经验判断当此刻的数据变化与之前的一般规律有大的出入，这些分辨方法是基于人的主观判断，所以对观察员的能力有较高的要求。本文以空气质量数据的变点为研究对象，考虑在仪器出现异常时会导致数据分布异常（均值和方差改变）的情况下，提出一种新的变点检测方法。通常基于单序列变点检测方法在这里并不适用，因为基于传统时间序列变点可能将正常变化的点，比如重污染过程或者降雨等过程判定为变点，在这些情况下，这种正常的变点并不是我们关心的。这里我们将由于检测对象自然变化而产生的变点称作**正常变点**，而仪器故障产生的变点称作**异常变点**。利用监测站点间的空间信息，可以综合归纳监测对象的气候变化特点，从而得到共同的变化趋势，以此对正常、异常变点做进一步判别。

本文使用的实际大气污染物浓度数据来源于京津冀地区 68 个国控站点的历史监测数据，现对站点、数据的选取以及数据的处理进行介绍。图 3 与图 4 分别是京津冀地区 13 个城市中 68 个站点（红色圆点）的位置分布地图以及站点数量的条形图。我们以 $\text{PM}_{2.5}$ 检测数据作为研究对象，数据时间单位是小

时，从 2010 开始到 2020 年共 600 多万条数据。比较数据的缺失比例发现，所有年份中 2017 年缺失相对较少，2017 年全年中 11 月的缺失比例相对最少，只有 1%，因此选取 2017 年 11 月数据作为研究对象，对于缺失值，使用后向填充的方法进行填充。

介绍完问题背景后，接下来根据均值和方差变点的正常、异常情形分别予以分析。




图 3 京津冀地区 13 个城市及其空气质量监测站点（红色圆点）分布




图 4 京津冀地区站点数量

4.1.1 时空均值变点

空气质量监测对象变化和仪器故障引起的均值变点有两种情况，如图：




图 5 均值单变点跳跃（左图）和非跳跃（右图）情形

左图是跳跃型均值变点的示例，数据的分布在变点时刻立刻改变。右图是非跳跃型均值变点的示例，数据的分布在变点前后缓慢变化。无论是否是跳跃型变点，都可以通过均值变点检验分析，来监测、估计是否有均值变点。跳跃型和非跳跃型均值变点在仪器故障情况下都可能产生，因此检测到序列均值变点后，表示仪器可能出现异常，但是仅仅凭借是否有均值变点是无法推断仪器的状态，因为这两种情况在监测对象里也会发生。在检测对象里面，后者更为常见，这是因为监测对象的变化通常是缓慢的，比如，该区域刮风会导致 $\text{PM}_{2.5}$ 浓度下降，但是风的产生是缓慢的，而且 $\text{PM}_{2.5}$ 的扩散也是缓慢的，这就会产生 $\text{PM}_{2.5}$ 缓慢下降的情况。但也不排除极端的自然现象，可能在极短时间内使污染物浓度产生跳跃型变点。

本文称仪器故障下产生的变点为异常变点，正是因为均值变点可能是因为仪器故障也可能是因为对象自然变化导致的，所以有必要对监测对象数据做是否存在异常均值变点的分析，通过有效识别异常均值变点，来及时发现仪器异常，保证数据质量。

针对实际情况，我们用模拟数据介绍了异常均值变点和正常均值变点这两种情形，并且通过结合多个站点的空间数据信息进一步分析变点是否正常。

情形 1：单序列异常均值变点，即单序列有变点，其他序列没有变点。




图 6 异常均值变点

对于站点 1 而言，无论是跳跃型还是非跳跃型均值变点，仅仅通过变点分析检测其有均值变点是无法直接判断是否为异常均值。这就需要通过额外数据去判断：站点 2、3 与站点 1 在空间上临近，因此，空气质量检测对象的变化很大程度上是同步的，比如：区域性刮风，会使得站点 1、2、3 的 $PM_{2.5}$ 浓度都下降。这种空间相关性引起的同步变化能被使用来检测均值变点是否异常：上图可见，只有站点 1 产生均值变点，数据分布发生变化，但是站点 2、3 却没有明显变化，这说明该区域并没有导致检测对象浓度明显变化的自然因素，站点 1 的均值变点是异常均值变点，需要立即检查仪器、排除故障。

情形 2：单序列正常均值变点，即所有序列都有变点。




图 7 正常均值变点

这种情形下,如图 7 所示,同样检测到站点 1 均值在 τ_1 处变化,但站点 2、3 在 τ_1 处也出现了类似变化,站点 2、3 数据反应了发生均值变化是普遍现象,也就是说共同原因导致了三个仪器的监测数据变化,跳跃型正常均值变点的发生可能是因为极端的自然现象导致的,而右图的非跳跃型正常均值变点,往往因为自然因素,比如该区域出现强风、沙尘暴等有利于 $\text{PM}_{2.5}$ 产生或者扩散的气候,浓度的变化是一个渐变的过程。因此可以排除机器故障情况发生。我们认为这种变点是正常的。站点 1 的数据是可靠的,监测仪器正常。

以上两种情况实际中也常遇到,图 8 截取北京所有站点 2017 年 11 月 6 日 18 时至 11 月 8 日 12 时的 $\text{PM}_{2.5}$ 数据,得到图 5,其中 11 条不同颜色的线代表 11 个站点的数据,横轴代表时间,纵轴代表 $\text{PM}_{2.5}$ 浓度,可以看到在 2017 年 11 月 7 日至 9 日,所有站点的 $\text{PM}_{2.5}$ 数据均有大幅下降。如果我们只考虑单个序列的变点检测,那么在这一点都会有变点产生,但是这个变点是由气象的变化所引起的(图 9),而不是由于仪器故障,这就对应于上诉的情形 2。




图 8 北京监测站点 2017 年 11 月 6 日 18 时至 11 月 8 日 12 时 $\text{PM}_{2.5}$ 小时数据

以上是北京市国控站点监测的 $\text{PM}_{2.5}$ 数据的正常变化情况,为了说明正常均值变点在现实生活中存在的普遍、合理性,接下来具体分析北京 2017 年 11 月 7 日的气象变化,从而给出正常均值变点出现的可能原因。从 11 月 7 日 9 时开始,所有站点仪器监测浓度都下降了,直到 11 月 8 日 12 时,都保持一个稳定的水平。截取时间段 2017 年 11 月 7 日 9 时至 2017 年 11 月 8 日 0 时,与 $\text{PM}_{2.5}$ 相关度高的几个数值型气象变量: HUMI (湿度), Iws (风速), PRES (压强), TEMP (气温), 在此期间的变化图如下:




图9 北京 2017 年 11 月 7 日 9 时至 8 日 0 时 HUMI、Iws、PRES 与 TEMP 的变化

2017 年 11 月 7 日 9 时至 16 时，所有监测站点的湿度、气压下降，气温风速上升，其中 $PM_{2.5}$ 与风速的关系最为直接，风速明显的上升导致 $PM_{2.5}$ 极速扩散，从而降低了空气中 $PM_{2.5}$ 浓度。因此，图 8 中的变点并非由于仪器故障，而是气象的变化照成的，如果只是基于单个时间序列数据的变点检测，可能会造成误判（仪器出现故障），因此我们需要利用其它站点的观测信息，来对改变点进行进一步诊断。2017 年 11 月 7 日 16 时至 8 日 0 时，湿度上升、气压上升，但是温度下降、风速减小，此时促使 $PM_{2.5}$ 扩散与不扩散的影响大小基本一致，该时间段 $PM_{2.5}$ 浓度基本无变化。

由于站点位置的空间相关性，使得站点间的相同气象变量在很大程度上同步变化，距离越近，这种关系就越强烈。而气象关系的变化会导致 $PM_{2.5}$ 浓度的变化，因此实际中站点间监测到的 $PM_{2.5}$ 浓度不是独立的，而是有很强的空间相关性，这就会产生之前的第二种情况。在 4.2 节中，我们利用站点的空间相关性，给出了时空异常变点探测的具体算法。

4.1.2 时空方差变点

类似于空气质量监测数据的均值变点，我们在实际中对于方差变点也感兴趣。方差变点也可能由仪器故障或者自然现象引发。然而，例如在下图中，我们可以检测到站点 1 观测数据的方差在 τ_1 时刻变化，而其它站点在 τ_1 时刻，方差并没有出现明显变化。

情形 1：单序列异常方差变点，即单序列有变点，其他序列没有变点




图 10 异常方差单变点

因为站点 1-3 在地理位置上非常接近，三个站点的空气质量数据之间就有很强的相速度。通过观察站点 2、3 的数据我们不难发现，数据总体变化走势并无大的改变，更未表现出均值和方差变点发生的迹象。因此我们可以得出结论：站点 1 的数据在 τ_1 处产生异常的方差变点，该变化可能是因为仪器故障、人为干扰等不正常因素导致机器异常产生的。因此需要对站点 1 尽快检查设备找到原因。

情形 2：单序列正常方差变点，即所有序列都有变点




图 11 正常方差单变点

如上图 11 正常方差单变点情形，在这种情况下，我们同样检测到站点 1 数据的方差在 τ_1 处变化，但是站点 2、3 的数据在 τ_1 之后也出现了大幅度震荡的情形，站点 2、3 数据反应了发生方差变化是普遍现象，也就是说共同原因导致了三个仪器的监测数据变化由此，可以断定站点设备正常。

下一节本文将给出具体算法，该算法利用站点间的空间相关性，可以自动识别正常和异常的均值和方差变点，从而为实际工作提供高效的监测工具。

4.2 算法

上一节说明了利用临近站点分析单站点数据变点是否异常，而直观借助图形判断没有严格统一的标准，图形判断在许多情况下不准确，因此需要算法进行自动识别。对此，本文将计算的其余站点数据的加权和作为辅助数据，利用辅助数据去比较分析目标站点的数据变化。这里的逆距离加权是考虑到站点之间的空间相关性，距离越近，相关性越强，权重也越大，反之，权重越小，相关性越弱。这一节给出针对异常均值、方差变点的时空变点检测算法。

4.2.1 异常均值变点算法

4.2.1.1 均值单变点算法

利用站点 2、3 的逆距离加权数据去判断站点 1 的变化，从图 12 的左右两幅图可以看到加权重数据与站点 1 数据的差值在 τ_1 时刻出现巨大变化，可以得出站点 1 均值变点异常的结论；图 13 左右两图可见，均值数据与站点 1 数据的变化一致，两者之差随时间没有明显的变化，因此断定站点 1 均值变点正常。由此可见，利用附近站点数据的加权和作为辅助数据去分析站点的变点，会使得对异常变点的检测更为简单有效。




图 12 站点 1 异常均值变点数据与站点 2、3 逆距离加权数据




图 13 站点 1 正常均值变点数据与站点 2、3 逆距离加权数据

在这节给出基于以上思想的具体算法。假设有 n 个站点，第 i 个站点观测到时间长度为 T 的监测数据 $X_i = (x_{i1}, x_{i2}, \dots, x_{iT})$ ，其中 x_{it} 表示第 i 站点在 t 时刻的观测值。我们考虑下面的假设检验过程。

H_0 : 仪器不存在异常均值变点;

H_1 : 仪器存在一个异常均值变点。

假设第 i 站点的变点时刻 $t = \tau_1$ ，其余站点仪器正常、没有受到非自然因素的干扰。假设该城市一共 K 个站点，首先我们计算其余 $K - 1$ 个站点数据的加权

$$\hat{x}_{it} = \sum_{j \neq i} x_{jt} * w_j, \quad (1)$$

其中 $w_j > 0$ 为权重，且满足 $\sum_{j \neq i} w_j = 1$ 。考虑到空间相关性，与 i 站点临近站点的数据应该和 i 站点数据相关性最高，因此，我们选择权重 w_j 与 i 站点和 j 站点之间的距离成反比，即

$$w_j = \frac{\frac{1}{d_{ij}}}{\sum_{l \neq i} \left(\frac{1}{d_{il}} \right)} \quad (2)$$

这里， d_{ij} 是 i 、 j 站点的距离。因此，我们在 (1) 式中计算的 $\hat{x}_{it}$ 表示的是如果第 i 个站点的仪器正常情况下所有 $K - 1$ 个站点对站点 i 观测数据的逆距离加权估计值，这个估计值刻画了在第 i 个站点仪器正常下其观测数据的大致变化。

接下来我们计算实际数据与逆距离加权值 $\hat{x}_{it}$ 的差异,

$$\Delta x_{it} = x_{it} - \hat{x}_{it} \quad (3)$$

如果站点 i 仪器正常,则 Δx_{it} 在 τ_1 前后变化不大,否则 Δx_{it} 在 τ_1 前后变化较大(参看图 12、13)。

记 τ_1 前后的数据

$$\begin{cases} a_t = x_{i(t)} - \hat{x}_{i(t)} (1 \leq t \leq \tau_1 - 1) \\ b_t = x_{i(t+\tau_1-1)} - \hat{x}_{i(t+\tau_1-1)} (1 \leq t \leq T - \tau_1 + 1) \end{cases} \quad (4) \quad (5)$$

因为是检验均值变化,所以计算 a_t 、 b_t 的均值作为统计量,

$$\begin{cases} diff_1 = \bar{a}_t \\ diff_2 = \bar{b}_t \end{cases} \quad (6) \quad (7)$$

$$\Delta diff = diff_1 - diff_2 \quad (8)$$

因此,如果 $\Delta diff$ 较大,即

$$\Delta diff \gg 0,$$

我们有理由相信第 i 站点仪器不正常,为了得到 $\Delta diff$ 的分布,我们采用 Bootstrap 抽样。

然后做假设检验。注意到,抽样应该是在 H_0 下进行的,但是 τ_1 时刻之后的数据可能出现异常。对于仪器异常情况下, H_0 不成立无法直接抽样检验,因此我们需要对 τ_1 之后的数据做变换,使得变换后的数据满足原假设,记

$$\Delta = \bar{a}_t - \bar{b}_t. \quad (9)$$

Δ 刻画的是数据不满足 H_0 的程度,对 b_t 做调整得到 b_t^* ,

$$b_t^* = b_t + \Delta. \quad (10)$$

这个调整可以使得 a_t 、 b_t^* 接近 H_0 下的分布,注意到,如果仪器是正常的,此时 Δ 小, b_t 和 b_t^* 接近,不会影响数据的分布。由于数据是小时数据,在时间上具有相关性,所以对 a_t 和 b_t^* 使用 Block Bootstrap 抽样:设置块的长度为 k ,从 $t = 1$ 开始,将 a_t 和 b_t^* 以大小为 k ($k \leq T$)的时间间隔进行连续切割,分别得到 $\tau_1 - k + 1$ 和 $T - \tau_1 - k$ 个子序列,记为 $\tilde{a}_t$ ($1 \leq t \leq \tau_1 - k + 1$)和 $\tilde{b}_t$ ($1 \leq t \leq T - \tau_1 - k$),每个 $\tilde{a}_t$ 和 $\tilde{b}_t$ 包含 k 个时间连续数据。每次抽样,分别从 $\tilde{a}_t$ 里有放回抽取 $(\tau_1 - k + 1)/k$ 个子序列、从 $\tilde{b}_t$ 里有放回抽取 $(T - \tau_1 - k)/k$ 个子序列。

在对 $\tilde{a}_t$ 、 $\tilde{b}_t$ 进行 M 次有放回 Block Bootstrap 抽样时,记第 m 次得到的样本是 $\tilde{a}_t^m$ 、 $\tilde{b}_t^m$,类似原始数据的处理,对 $\tilde{a}_t^m$ 和 $\tilde{b}_t^m$ 分别计算 $diff_1^{(m)}$ 、 $diff_2^{(m)}$,最

后计算 $\Delta diff^{(m)} = diff_1^{(m)} - diff_2^{(m)}$ 。

根据 M 次 Block Bootstrap 抽样样本计算得到的统计量 $\Delta diff^{(m)}$ 与原始数据计算得到的统计量 $\Delta diff$ 比较判断：给定置信水平 α ，记 $\Delta diff^{(m)}$ 的上 $\alpha/2$ 分位点和下 $1 - \alpha/2$ 分位点位置数据是 $\Delta diff^{*[\alpha/2]}$ 、 $\Delta diff^{*[1-\alpha/2]}$ ，

若 $\Delta diff^{*[\alpha/2]} \leq \Delta diff$ 或 $\Delta diff \geq \Delta diff^{*[1-\alpha/2]}$ ，则拒绝原假设，否则不拒绝原假设。因设计的算法用于时空数据的异常均值变点检测，因此取名叫 STMC(基于 CUSUM 算法的时空数据异常均值变点检测方法)，具体算法如下所示。

Algorithm: STMC

Input: 站点空气污染物的时空数据 $X_j = \{x_{j,1}, \dots, x_{j,T}\}$, $j = 1, \dots, n$, Block Bootstrap 块长: k , 置信水平: α , i, j 两站点距离: $d_{i,j}$.

Result: 输出 τ_1 : 拒绝 H_0 ，给出异常均值变点估计值 τ_1 ，输出 0: 不拒绝 H_0 .

1. 利用 CUSUM 方法估计 X_i 的均值单变点时间 τ_1 .
 2. 计算 $\hat{x}_{i,t} = \sum_{j \neq i} x_{j,t} \frac{d_{i,j}^{-1}}{\sum_{j \neq i} d_{i,j}^{-1}}$,
 $a_i = (x_{i,1} - \hat{x}_{i,1}, \dots, x_{i,\tau_1-1} - \hat{x}_{i,\tau_1-1})$,
 $b_i = (x_{i,\tau_1} - \hat{x}_{i,\tau_1}, \dots, x_{i,T} - \hat{x}_{i,T})$
 3. for $l \leftarrow 1$ to M do
 if $l = 1$ then
 计算 $diff_1 = \text{mean}(a_i)$, $diff_2 = \text{mean}(b_i)$,
 $\Delta diff = diff_1 - diff_2$,
 $\Delta = \text{mean}(a_i) - \text{mean}(b_i)$,
 $b_i = b_i + \Delta$,
 else
 对 a_i, b_i 做块长度为 k 的 Block Bootstrap 抽样，得到样本 a_i^{*l}, b_i^{*l} ,
 计算 $diff_1^{(l)} = \text{mean}(a_i^{*l})$, $diff_2^{(l)} = \text{mean}(b_i^{*l})$,
 $\Delta diff^{(l)} = diff_1^{(l)} - diff_2^{(l)}$,
 end
 end
 - 4. 将 $\Delta diff^{(1)}, \dots, \Delta diff^{(M)}$ 按照升序排列的到 $\Delta diff^{*(1)}, \dots, \Delta diff^{*(M)}$.
 - 5. if $\Delta diff < \Delta diff^{*[\alpha/2]}$ | $\Delta diff > \Delta diff^{*[1-\alpha/2]}$ then
 返回 τ_1 .
 else
 返回 0.
 end
-

以上是使用均值统计量设计均值变点的检验算法，本文也考虑了使用中位数达到观察数据均值异常变化的算法，对公式(6)、(7)、(8)做调整如下：

$$\begin{cases} diff_1 = a_{\lfloor \frac{\tau_1-1}{2} \rfloor} & (11) \\ diff_2 = b_{\lfloor \frac{T-\tau_1+1}{2} \rfloor} & (12) \\ \Delta diff = diff_1 - diff_2 & (13) \end{cases}$$

这里, (11)、(12)是将(6)、(7)里的中位数代替成了均值。

使用中位数做差来当作统计量有两个原因: (1)当只考虑均值变化时, 分布的中位数也是在改变, 因此使用中位数的差值作为统计量也是合理的。(2)均值由于易受极端值的影响, 而中位数更加稳定, 而有放回的 Bootstrap 抽样后可能会因为抽到更多极端值而严重影响均值, 特别是当数据方差较大的, 这种影响更为严重, 但是中位数就很稳健。(3)当数据量大时, 许多分布都是近似正态分布的, 此时分布的中位数可以近似均值。因为在 STMC 的基础山将均值差替换为中位数的差值, 故将该算法取名为 STMC-median, STMC-median 的算法如下。

Algorithm: STMC-median

Input: 站点空气污染物的时空数据 $X_j = \{x_{j,1}, \dots, x_{j,T}\}$, $j = 1, \dots, n$, Block Bootstrap 块长: k , 置信水平: α , i 、 j 两站点距离: $d_{i,j}$.

Result: 输出 τ_1 : 拒绝 H_0 , 给出异常均值变点估计值 τ_1 , 输出 0: 不拒绝 H_0 .

1. 利用 CUSUM 方法估计 X_i 的均值单变点时间 τ_1 .
 2. 计算 $\hat{x}_{i,t} = \sum_{j \neq i} x_{j,t} \frac{d_{i,j}^{-1}}{\sum_{j \neq i} d_{i,j}^{-1}}$,
 $a_i = (x_{i,1} - \hat{x}_{i,1}, \dots, x_{i,\tau_1-1} - \hat{x}_{i,\tau_1-1})$,
 $b_i = (x_{i,\tau_1} - \hat{x}_{i,\tau_1}, \dots, x_{i,T} - \hat{x}_{i,T})$
 3. for $l \leftarrow 1$ to M do
 if $l = 1$ then
 计算 $diff_1 = median(a_i)$, $diff_2 = median(b_i)$,
 $\Delta diff = diff_1 - diff_2$,
 $\Delta = mean(a_i) - mean(b_i)$,
 $b_i = b_i + \Delta$,
 else
 对 a_i, b_i 做块长度为 k 的 Block Bootstrap 抽样, 得到样本 a_i^{*l}, b_i^{*l} ,
 计算 $diff_1^{(l)} = median(a_i^{*l})$, $diff_2^{(l)} = median(b_i^{*l})$,
 $\Delta diff^{(l)} = diff_1^{(l)} - diff_2^{(l)}$
 end
 end
 - 4. 将 $\Delta diff^{(1)}, \dots, \Delta diff^{(M)}$ 按照升序排列的到 $\Delta diff^{*(1)}, \dots, \Delta diff^{*(M)}$.
 - 5. if $\Delta diff < \Delta diff^{*[\alpha/2]} \mid \Delta diff > \Delta diff^{*[1-\alpha/2]}$ then
 返回 τ_1 .
 else
 返回 0.
 end
-

4.2.1.2 均值多变点算法

为方便起见,记原始数据为 $X_i^{0,T} = \{x_{i(t)}\}, 1 \leq t \leq T$, 对于其有多个均值变点, 并要检测其多个均值变点时, 一个简单的多变点检测思路是使用二进制分割方法: 依次对数据 $X_i^{0,T}$ 做均值单变点检测, 如果估计到单变点时刻 τ_1 , 那么根据估计的变点时刻分割数据得到: $X_i^{0,\tau_1-1} = \{x_{i(t)}\}, 1 \leq t \leq \tau_1 - 1$; $X_i^{\tau_1,T} = \{x_{i(t)}\}, \tau_1 \leq t \leq T$, 对分割后的 X_i^{0,τ_1-1} 和 $X_i^{\tau_1,T}$ 再做单变点检验, 如果检测到均值变点则继续分割, 直到没有检测到均值变点, 总共得到估计的均值变点时刻 $\tau_1 \dots \tau_N$ 。

因此, 对于多变点的异常均值变点检测, 首先可以利用上面的思路检测估计得到多个均值变点, 同样也可以使用 R 软件中的 `cpt.mean` 函数, 该函数可以返回检测到的所有均值变点的时间。然后根据估计的均值变点 τ_n 对数据进行切分从而得到 $X_i^{\tau_{n-1}, \tau_{n+1}}$, 再对 $X_i^{\tau_{n-1}, \tau_{n+1}}$ 使用均值单变点的 STMC 或者 STMC-median 算法检测 τ_n 是否是异常均值变点。以下给出多均值变点的异常均值变点检测算法。

Algorithm: 均值多变点-异常均值变点检测算法

Input: 站点空气污染物的时空数据 $X_j = \{x_{j,1}, \dots, x_{j,T}\}, j = 1, \dots, n$, Block Bootstrap 块长: k , 置信水平: α , i, j 两站点距离: $d_{i,j}$.

Result: 输出估计得到的异常均值变点发生时间; 输出 0: 无异常均值变点.

1. 利用 CUSUM 方法检测并返回 X_i 的均值多变点时间 $\tau_1, \dots, \tau_N$, 根据变点时刻切分 X_i , 得:

$$X_i^{\tau_{n-1}, \tau_{n+1}} = (x_{j, \tau_{n-1}}, \dots, x_{j, \tau_{n+1}}), n = 0, \dots, N, \tau_0 = 1, \tau_{N+1} = T,$$
 2. for $n \leftarrow 1$ to N do
 对 $X_i^{\tau_{n-1}, \tau_{n+1}} = (x_{j, \tau_{n-1}}, \dots, x_{j, \tau_{n+1}})$ 应用异常均值单变点检测算法: STMC-median
 算法, 得到返回值 y_{τ_n} .
 if $y_{\tau_n} \neq 0$ then
 返回 τ_n
 end
 end
-

4.2.2 异常方差变点算法

4.2.2.1 方差单变点算法

对于仪器故障导致的异常方差变点的检测, 我们考虑下面的假设检验过

程。

H_0 : 仪器不存在异常方差变点;

H_1 : 仪器存在一个异常方差变点。

假设第 i 站点的方差变点时刻 $t = \tau_1$, 其余站点仪器正常、没有受到非自然因素的干扰。假设该城市一共有 K 个站点, 记 $\sigma_{k,1}^2$ 是第 k 站点在 τ 前的方差, $\sigma_{k,2}^2$ 是第 k 站点在 τ 后的方差, $k = 1, 2, \dots, K$, $\Delta\sigma$ 是一常数。

如果 H_0 为真, 站点 i 仪器正常, 此方差变点的合理解释就是该区域出现大规模自然气象变化, 从而导致空气污染物浓度分布发生剧烈变化, 也就是分布的方差变大, 那么, 该区域所有站点在 τ_1 前后数据分布的方差辩护说基本相同, 即

$$\sigma_{k,1}^2 - \sigma_{k,2}^2 = \Delta\sigma_k, 1 \leq k \leq K. \quad (1)$$

$$\Delta\sigma_i - \Delta\sigma_j = \Delta\sigma_{ij} \cong 0, 1 \leq i \neq j \leq K. \quad (2)$$

其中 $\Delta\sigma_{ij}$ 是一接近 0 的小数。相反, H_0 为假时, $\Delta\sigma_i$ 是一个明显大于 0 的数, 而 $\Delta\sigma_j \approx 0$, 因此 $\Delta\sigma_{ij}$ 不是一个小数。

基于 4.1.2 讨论的方差变点问题, 以及 4.2.1 分析的异常均值单变点算法, 对于异常方差变点检测, 仍然需要在站点 i 的方差变点检测基础上, 利用其余站点的监测数据来辅助分析站点 i 的方差变点是否异常。计算:

$$\Delta\sigma_i - \sum_{j \neq i} \Delta\sigma_{ij} * w_j = \Delta diff. \quad (3)$$

这里, 权重 w_j 同样也是使用逆距离计算得到的:

$$w_j = \frac{\frac{1}{d_{ij}}}{\sum_{l \neq i} \left(\frac{1}{d_{il}} \right)}.$$

其中, d_{ij} 是 i 、 j 站点的距离。当站点 i 仪器正常时, 有

$$(\sigma_{i,1}^2 - \sigma_{i,2}^2) - \sum_{j \neq i} (\sigma_{j,1}^2 - \sigma_{j,2}^2) * w_j \cong 0.$$

将(3)稍作变换得到:

$$\begin{aligned} \left(\sigma_{i,1}^2 - \sum_{j \neq i} \sigma_{j,1}^2 * w_j \right) - \left(\sigma_{i,2}^2 - \sum_{j \neq i} \sigma_{j,2}^2 * w_j \right) &= \nabla_1 - \nabla_2 = \Delta diff \cong 0, \\ \nabla_1 &= \sigma_{i,1}^2 - \sum_{j \neq i} \sigma_{j,1}^2 * w_j. \end{aligned}$$

$$\nabla_2 = \sigma_{i,2}^2 - \sum_{j \neq i} \sigma_{j,2}^2 * w_j.$$

因此当站点*i*没有异常方差变点时， ∇_1 与 ∇_2 的差值 $\Delta diff$ 就是接近 0 的小数。反之， ∇_1 与 ∇_2 差值就显著大于 0，所以，可以构造 ∇_1 与 ∇_2 的差值 $\Delta diff$ 作为统计量，检验 $\Delta diff$ 是否显著大于 0，如果是，就拒绝 H_0 ，否则就接受 H_0 。但是， $\sigma_{i,1}^2$ 与 $\sigma_{i,2}^2$ 是未知的，故用样本方差代替，从而检验 H_0 ，

$$\begin{aligned}\nabla_1 &= \hat{\sigma}_{i,1}^2 - \sum_{j \neq i} \hat{\sigma}_{j,1}^2 * w_j. \\ \nabla_2 &= \hat{\sigma}_{i,2}^2 - \sum_{j \neq i} \hat{\sigma}_{j,2}^2 * w_j. \\ \Delta diff &= \nabla_1 - \nabla_2.\end{aligned}$$

对原始数据 $x_{i,t}$ 做以下变换：

$$x_{k,t}^* = \begin{cases} (x_{k,t} - \hat{\mu}_{k,1})^2, & t < \tau_1 \\ (x_{k,t} - \hat{\mu}_{k,2})^2, & t \geq \tau_1 \end{cases}.$$

其中， $\hat{\mu}_{k,1} = \frac{\sum_{t=1}^{\tau_1-1} x_{k,t}}{\tau_1-1}$ ， $\hat{\mu}_{k,2} = \frac{\sum_{t=\tau_1}^T x_{k,t}}{T-\tau_1+1}$ ， $k = 1, \dots, K$ ， $t = 1, \dots, T$ 。基于调整过后的数据 $x_{k,t}^*$ ，得到：

$$\begin{aligned}\frac{\tau_1-1}{\tau_1-2} * \sum_{t=1}^{\tau_1-1} \frac{x_{k,t}^*}{\tau_1-1} &= \hat{\sigma}_{k,1}^2 = \frac{\tau_1-1}{\tau_1-2} * \mu_{k,1}^*. \\ \frac{T-\tau_1+1}{T-\tau_1} * \sum_{t=\tau_1}^T \frac{x_{k,t}^*}{T-\tau_1+1} &= \hat{\sigma}_{k,2}^2 = \frac{T-\tau_1+1}{T-\tau_1} * \mu_{k,2}^*.\end{aligned}$$

$\mu_{k,1}^*$ 是 $x_{k,t}^*$ 在 $t \leq \tau_1 - 1$ 时的样本均值。可以看到，在 $t \leq \tau_1 - 1$ 时， $x_{k,t}^*$ 的均值 $\mu_{k,1}^*$ 与原始数据 $x_{k,t}$ 的样本方差 $\hat{\sigma}_{i,1}^2$ 只存在一个倍数 $\frac{\tau_1-1}{\tau_1-2}$ 的关系，这意味着可以使用均值变点检验方法去检验方差变点的检验统计量。

对 $x_{i,t}^*$ 使用以下稍作修改的 STMC 算法，并利用 $x_{j,t}^* (j \neq i)$ 做辅助数据，计算 $x_{j,t}^*$ 逆距离加权值 $\hat{x}_{i,t}^*$ ：

$$\hat{x}_{i,t}^* = \sum_{j \neq i} x_{j,t}^* * w_j.$$

计算 $x_{i,t}^*$ 与 $\hat{x}_{i,t}^*$ 的差值，并根据变点时刻 τ_1 划分数据，得到：

$$\begin{aligned}a_t &= (x_{i,t}^* - \hat{x}_{i,t}^*) \quad 0 < t < \tau_1 \\ b_t &= (x_{i,t}^* - \hat{x}_{i,t}^*) \quad \tau_1 \leq t \leq T\end{aligned}$$

计算 a_t 与 b_t 的均值：

$$\mu_a = \sum_{t=1}^{\tau_1-1} \frac{a_t}{\tau_1 - 1}$$

$$\mu_b = \sum_{t=\tau_1}^T b_t / (T - \tau_1 + 1)$$

计算 $\frac{\tau_1-1}{\tau_1-2} * \mu_a$ 和 $\frac{T-\tau_1+1}{T-\tau_1} * \mu_b$ 的差:

$$\begin{aligned} & \frac{\tau_1-1}{\tau_1-2} * \mu_a - \frac{T-\tau_1+1}{T-\tau_1} * \mu_b \\ &= \frac{\tau_1-1}{\tau_1-2} \sum_{t=1}^{\tau_1-1} a_t / (\tau_1 - 1) - \frac{T-\tau_1+1}{T-\tau_1} \sum_{t=\tau_1}^{T-\tau_1} b_t / (T - \tau_1) \\ &= \frac{\tau_1-1}{\tau_1-2} \left(\mu_{i,1}^* - \sum_{j \neq i} \mu_{j,1}^* * w_j \right) - \frac{T-\tau_1+1}{T-\tau_1} \left(\mu_{i,2}^* - \sum_{j \neq i} \mu_{j,2}^* * w_j \right) \\ &= \left(\hat{\sigma}_{i,1}^2 - \sum_{j \neq i} \hat{\sigma}_{j,1}^2 * w_j \right) - \left(\hat{\sigma}_{i,2}^2 - \sum_{j \neq i} \hat{\sigma}_{j,2}^2 * w_j \right) \\ &= \nabla_1 - \nabla_2 = \Delta diff \quad (4) \end{aligned}$$

公式(4)对 μ_a 、 μ_b 乘了系数,使之与 STMC 算法不同,但其余步骤与 STMC 算法相同,因此,要验证 $\Delta diff$ 是否显著大于 0,只需验证 $\frac{\tau_1-1}{\tau_1-2} * a_t$ 与 $\frac{T-\tau_1+1}{T-\tau_1} * b_t$ 的均值差是否显著大于 0,只需对 $x_{i,t}^*$ 使用上面描述的稍作修改后的 STMC 算法验证是否存在异常均值变点即可。

接下来对统计量 $\Delta diff$ 做 Bootstrap 抽样,从而估计其分布,然后做假设检验。注意到,抽样是在 H_0 下进行的,但是 τ_1 之后的数据可能存在异常,对于仪器异常情况下, H_0 不成立无法直接抽样检验,因此我们需要对 τ_1 之后的数据做变换,使得变换后的数据满足原假设。

调整 b_t , 得到 $\tilde{b}_t = b_t + \Delta diff * \frac{T-\tau_1}{T-\tau_1+1}$, 这个调整可以使得异常仪器下的 a_t 、 $\tilde{b}_t$ 尽量接近 H_0 下的分布,注意到,如果仪器是正常的,此时 $\Delta diff$ 小, b_t 和 $\tilde{b}$ 接近,不会影响数据的分布。为了便于书写,记 $\tilde{a}_t = a_t$ 。

然后分别对 $\tilde{a}_t$ 、 $\tilde{b}_t$ 做有放回 Block Bootstrap 抽样,记 k 为块长度, M 为抽样次数,一共做 M 次 Block Bootstrap。第 m ($1 \leq m \leq M$) 次抽样得到 $\tilde{a}_t^m$ 、 $\tilde{b}_t^m$, 计算得到 $\tilde{a}_t^m$ 、 $\tilde{b}_t^m$ 的均值 μ_a^m 、 μ_b^m , 并计算

$$\frac{\tau_1-1}{\tau_1-2} * \mu_a^m - \frac{T-\tau_1+1}{T-\tau_1} * \mu_b^m = \Delta diff^{(m)}$$

根据 M 次 Block Bootstrap 抽样样本得到的统计量 $\Delta diff^{(m)}$ 与原始数据计

算得到的统计量 $\Delta diff$ 比较判断：给定置信水平 α ，对 $\Delta diff^{(m)}$ 按照升序排序得到 $\Delta diff^{*(m)}$ ，并且抽取出第 $\alpha/2$ 和 $1 - \alpha/2$ 位置的数据： $\Delta diff^{*[\alpha/2]}$ 、 $\Delta diff^{*[1-\alpha/2]}$ 。

若 $\Delta diff^{*[\alpha/2]} \leq \Delta diff$ 或 $\Delta diff \geq \Delta diff^{*[1-\alpha/2]}$ 拒绝 H_0 ，否则不拒绝。该算法命名为 STVC（基于 CUSUM 的时空数据异常方差检测方法），以下是步骤：

Algorithm: STVC

Input: 站点空气污染物的时空数据 $X_j = \{x_{j,1}, \dots, x_{j,T}\}$, $j = 1, \dots, n$, Block Bootstrap 块长: k , 置信水平: α , i, j 两站点距离: $d_{i,j}$.

Result: 输出 τ_1 : 拒绝 H_0 , 给出异常均值变点估计值 τ_1 , 输出 0: 不拒绝 H_0 .

1. 利用 CUSUM 方法估计 X_i 的方差单变点时间 τ_1 .
2. 计算 $x_{i,t}^* = \left(x_{i,t} - \text{mean}(x_{i,j} | j < \tau_1) * I(t < \tau_1) - \text{mean}(x_{i,j} | j > \tau_1) * I(t > \tau_1) \right)^2$,
 $\hat{x}_{i,t}^* = \sum_{j \neq i} x_{j,t}^* \frac{d_{i,j}^{-1}}{\sum_{j \neq i} d_{i,j}^{-1}}$,
 $a_i = (x_{i,1} - \hat{x}_{i,1}, \dots, x_{i,\tau_1-1} - \hat{x}_{i,\tau_1-1})$,
 $b_i = (x_{i,\tau_1} - \hat{x}_{i,\tau_1}, \dots, x_{i,T} - \hat{x}_{i,T})$
3. for $l \leftarrow 1$ to M do
 if $l = 1$ then
 计算 $diff_1 = \text{mean}(a_i)$, $diff_2 = \text{mean}(b_i)$,
 $\Delta diff = \frac{\tau_1-1}{\tau_1-2} diff_1 - \frac{T-\tau_1+1}{T-\tau_1} diff_2$,
 $b_i = b_i + \frac{T-\tau_1}{T-\tau_1+1} \Delta diff$
 else
 对 a_i, b_i 做块长度为 k 的 Block Bootstrap 抽样, 得到样本 a_i^{*l}, b_i^{*l} ,
 计算 $diff_1^l = \text{mean}(a_i^{*l})$, $diff_2^l = \text{mean}(b_i^{*l})$,
 $\Delta diff^l = \frac{\tau_1-1}{\tau_1-2} diff_1^l - \frac{T-\tau_1+1}{T-\tau_1} diff_2^l$
 end
 end
- 4. 将 $\Delta diff^1, \dots, \Delta diff^M$ 按照升序排列的到 $\Delta diff^{*1}, \dots, \Delta diff^{*M}$.
- 5. if $\Delta diff < \Delta diff^{*[\alpha/2]}$ | $\Delta diff > \Delta diff^{*[1-\alpha/2]}$ then
 返回 τ_1 .
 else
 返回 0.
 end

4.2.2.2 方差多变点算法

方差多变点检测算法与均值多变点算法类似，先使用 CUSUM 方法检测并返回估计的多个方差变点的时间 $\tau_1, \tau_2, \dots, \tau_n$ ，记 $\tau_0 = 1, \tau_{n+1} = T$ ，再对 $X_i^k = \{x_{i(t)}\}$ 使用方差单变点检测算法即可，其中 x 表示原始数据， $\tau_{k-1} \leq t \leq$

$\tau_{k+1}, k = 1, \dots, n$ 。只要在任何一个 X_i^k 里检测到异常方差变点，则认为 X_i^k 存在异常方差变点。基于以上思路得到方差多情形下的异常方差变点检测算法如下：

Algorithm: 方差多变点-异常方差变点检测算法

Input: 站点空气污染物的时空数据 $X_j = \{x_{j,1}, \dots, x_{j,T}\}, j = 1, \dots, n$, Block Bootstrap 块长: k , 置信水平: α , i, j 两站点距离: $d_{i,j}$.

Result: 输出估计得到的异常均值变点发生时间; 输出 0: 无异常均值变点.

1. 利用 CUSUM 方法检测并返回 X_i 的方差多变点时间 $\tau_1, \dots, \tau_N$, 根据变点时刻切分 X_i , 得:

$$X_i^{\tau_{n-1}, \tau_{n+1}} = (x_{j, \tau_{n-1}}, \dots, x_{j, \tau_{n+1}}), n = 0, \dots, N, \tau_0 = 1, \tau_{N+1} = T,$$
 2. for $n \leftarrow 1$ to N do
 对 $X_i^{\tau_{n-1}, \tau_{n+1}} = (x_{j, \tau_{n-1}}, \dots, x_{j, \tau_{n+1}})$ 应用异常方差单变点检测算法: STVC 算法, 得到返回值 y_{τ_n} .
 if $y_{\tau_n} \neq 0$ then
 返回 τ_n
 end
 end
 end
-

5 数值模拟

这一节使用数值模拟评估第 4 章中提出的异常均值和方差变点检测算法的性能。因本文提出的 STMC 方法、STMC-median 方法与 STVC 方法都是在 CUSUM 方法检测出变点的基础上,利用时空数据的空间信息来检测异常变点的,也就是说,CUSUM 方法本身是无法检测出变点是否异常的。因此,为了分析本文提出的方法对异常变点以及正常变点的检测效果,本节假设(下同):CUSUM 检验只要发现变点就判断该变点是异常变点。第 5.1 节分别模拟均值和方差单个变点的情形:在均值单变点的模拟中,文章比较了 CUSUM 方法、STMC 方法和 STMC-median 方法在正常均值单变点和异常均值单变点情形下的正确率,在方差单变点模拟部分,文章比较了 CUSUM 方法和 STVC 方法在正常方差单变点和异常方差单变点下的检验正确率。在 5.2 节,文章模拟了均值和方差多变点情形,在均值多变点模拟中分析了 STMC-median 方法的检验能力,在方差多变点模拟中分析了 STVC 方法的检测能力。在整个模拟中,假定只有 5 个站点,即站点 1-5,以站点 1 数据作为检测分析的对象,站点 2-5 与站点 1 之间的距离相同,因此逆距离加权重 $w_j = \frac{1}{4} (j = 2, 3, 4, 5)$ 。

5.1 单变点

5.1.1 均值单变点

本节模拟主要考虑数据的均值变点是否正常以及是否跳跃共四种组合,即正常跳跃型均值变点、正常非跳跃型均值变点、异常跳跃型均值变点、异常非跳跃型均值变点。文章在每一种情况下生成模拟数据,以此检验新提出的算法的有效性。为了检验均值单变点检测方法在不同情形下的性能,文章设置了参数 $\Delta\mu$ 来测度变点前后的均值变化程度,本节对参数 $\Delta\mu$ 的每个值都做

1000 次模拟，且给定 STMC 算法、STMC-median 算法中 Block Bootstrap 抽样的块长度 $k = 2$ ，抽样次数 $M = 700$ ，显著性水平为 5%。

5.1.1.1 正常均值单变点

这一部分主要考虑正常均值变点跳跃型和非跳跃型这两种情形，具体见下图，左图是站点 1 的正常跳跃型均值变点，右图是站点 1 的正常非跳跃型均值变点。为便于观察，只在图中展示了站点 1、2、3 数据的基本变化情况。




图 14 正常跳跃型均值单变点与非跳跃型均值单变点模拟数据

在正常均值变点的模拟数据中，正常跳跃型均值变点的数据由以下规则生成：第 1 至 5 个站点的前 50 个模拟数据分别来自于正态分布 $N(50,1)$ ， $N(48,1)$ ， $N(45,1)$ ， $N(42,1)$ ， $N(51,1)$ ，第 1 至 5 个站点的后 50 个模拟数据分别产生于正态分布 $N(50 + \Delta\mu, 1)$ ， $N(48 + \Delta\mu, 1)$ ， $N(45 + \Delta\mu, 1)$ ， $N(42 + \Delta\mu, 1)$ ， $N(51 + \Delta\mu, 1)$ 。在正常非跳跃型均值变点的模拟数据中，第 1 至 5 个站点的前 50 个模拟数据分别来自于正态分布 $N(50,1)$ ， $N(46,1)$ ， $N(48,1)$ ， $N(43,1)$ ， $N(51,1)$ 。为方便描述，记第 i 个站点的数据为 x_i ， $i = 1, 2, 3, 4, 5$ ，这五个站点的前 50 个数据服从的正态分布的均值记为 μ_i ，即 $\mu_1 = 50$ ， $\mu_2 = 46$ ， $\mu_3 = 48$ ， $\mu_4 = 43$ ， $\mu_5 = 51$ 。第 i 个站点的第 51 至 60 个数据 x_{ij} ， $i = 1, 2, 3, 4, 5$ ， $j = 1, 2, \dots, 10$ 通过逻辑(logistic)函数外加服从 $N(0,1.5)$ 分布的随机噪声生成，即 $x_{ij} = \frac{\mu_i + \Delta\mu}{1 + \exp(-l_j)} + \varepsilon$ ，其中 $\varepsilon \sim N(0,1.5)$ ， $l_j = 0.5 * j - 2.5$ ， $i = 1, 2, 3, 4, 5$ ， $j = 1, 2, \dots, 10$ 。第 i 个站点的后 40 个数据来自于正态分布 $N(\mu_i + \Delta\mu, 1)$ ， $i = 1, 2, 3, 4, 5$ 。为了考虑不同的均值变化信号下变点检测方法

的表现，我们设置 $\Delta\mu = -10, -9, \dots, 9, 10$ ，即通过 $\Delta\mu$ 来控制均值变化的程度。

因为本文提出的 STMC 算法与 STMC-median 算法是基于累计和检验 (CUSUM) 算法来设计的，所以下面就比较了 CUSUM 算法、STMC 算法、STMC-median 算法对模拟数据的检测正确率，得到如下所示的图 15。




图 15 CUSUM、STMC 与 STMC-median 方法对不同 $\Delta\mu$ 模拟数据的检验正确率

注：CUSUM、STMC 与 STMC-median 分别为累计和检验、时空均值变点检测方法与时空的稳健的时空均值变点检测方法；左图与右图分别为三种变点检测方法在正常跳跃型均值单变点与正常非跳跃型均值单变点情形下的检测正确率折线图。

上图中的正确率由下式计算所得：

$$\text{正确率} = \frac{\text{检测到正常均值单变点的次数}}{\text{总模拟次数}}$$

从图 15 中可以发现，CUSUM 方法完全无法判断正常均值单变点情形，判断正确率为 0，这是因为 CUSUM 方法一旦检测到均值单变点就判断是异常的均值单变点，但实际上这是数据的正常变化（这要通过所有站点数据共同分析才可以判断），这也是本文提出的方法利用时空数据的空间信息的一个出发点。我们还可以看到，STMC 算法和 STMC-median 算法的检测正确率比 CUSUM 高出了 51%-90% 左右。随着 $\Delta\mu$ 接近 0，STMC 算法与 STMC-median 算法的检测正确率呈下降趋势，在 $\Delta\mu = \pm 1$ 时下降到 0.4-0.6 的正确率。这是因为均值变化不太明显，CUSUM 算法无法检测到均值单变点，STMC 算法与 STMC-median 算法也就无法检测出正常均值单变点。在 $|\Delta\mu| > 3$ 时，随着 $|\Delta\mu|$ 越大，正确率的增加幅度不断减小。通过比较两种新提出的检测方法发现，STMC-median 算法比 STMC 算法在模拟数据上有更高的正确率，这得益于中位数比均值更加稳健。无论是 STMC 算法还是 STMC-median 算法，它们在跳

跃型均值单变点情形下的正确率都比非跳跃情形下更高，这是因为存在非跳跃型均值单变点的数据由三段构成，前后两段的分布稳定，中间段属于变化过渡数据，其方差更大，因此做差过后使用 Bootstrap 方法可能抽取到更多偏离中心的数据，使得估计的均值或者中位数偏离真实值，给检验带来困难，其检验正确率就会比跳跃型均值单变点数据的检测正确率低。

表 1 CUSUM、STMC 与 STMC-median 方法在正常均值单变点数据上的检验正确率

方法	跳跃型	非跳跃型
CUSUM	0.0000	0.0000
STMC	0.8285	0.8000
STMC-median	0.8994	0.8704

注：CUSUM、STMC 与 STMC-median 分别为累计和检验、时空均值变点检测方法与稳健的时空均值变点检测方法（下同）。

表 1 是 CUSUM、STMC、STMC-median 三种方法对 $\Delta\mu$ 所有取值下的变点检测效果，平均来说，STMC 方法对正常均值单变点的识别准确率达到了 81.4%，STMC-median 方法的准确率达到了 88.5%左右。从中可以更加明显地发现，STMC-median 算法比 STMC 算法对正常均值单变点的检验识别率更高，且上述两种算法对跳跃型均值单变点的识别准确率比非跳跃型更高。

5.1.1.2 异常均值单变点

本节比较 CUSUM 方法、时空均值变点检测(STMC)方法与稳健的时空均值变点检测(STMC-median)方法在异常均值单变点情形下的性能。模拟的异常均值单变点分两种情况：异常跳跃型均值单变点（图左）和异常非跳跃型均值单变点（图右）。同样为便于观察，只显示站点 1、2、3 的数据变化情况。




图 16 异常跳跃型均值单变点与非跳跃型均值单变点模拟数据

在异常均值单变点的模拟中, 跳跃型模拟数据通过以下方法生成: 设定站点 1 的异常变点发生时间为 $t = 50$, 用正态分布 $N(50,1)$ 生成前 50 个数据, 正态分布 $N(50 + \Delta\mu, 1)$ 生成后 50 个数据。站点 2-5 的数据分别来自于不同的正态分布 $N(48,1), N(45,1), N(42,1), N(51,1)$ 。非跳跃型均值单变点模拟数据由以下方式生成: 站点 1 的前 50 个数据来自于正态分布 $N(50,1)$; 第 51-60 个数据通过 logistic 函数外加随机噪声生成, 即 $x_{1j} = 50/(1 + \exp(-l_j)) + \varepsilon$, 其中 $\varepsilon \sim N(0,1.5), l_j = 0.5 * j - 2.5, j = 1, 2, \dots, 10$; 后 40 个样本来自于正态分布 $N(50 + \Delta\mu, 1)$ 。站点 2-5 的数据分别来自于正态分布 $N(46,1), N(48,1), N(43,1), N(51,1)$ 。此处, 设计 $\Delta\mu$ 来表示数据中存在不同程度的异常均值单变点: $\Delta\mu = 0$ 代表不存在异常均值单变点 (此时也没有均值变点); $\Delta\mu$ 越大, 均值单变点异常程度就越大。我们设置 $\Delta\mu = -10, -9, \dots, 9, 10$, 通过 $\Delta\mu$ 来控制站点 1 数据的均值变化的程度。经累计和 (CUSUM) 检验算法、STMC 算法、STMC-median 算法检测分析得到的结果如下表所示。

表 2 CUSUM、STMC 与 STMC-median 方法在不同异常程度的数据上的检验正确率

均值差	跳跃均值变点			非跳跃均值变点		
$\Delta\mu$	CUSUM	STMC	STMC-median	CUSUM	STMC	STMC-median
-10	1	1	1	1	1	1
-9	1	1	1	1	1	1
-8	1	1	1	1	1	1
-7	1	1	1	1	1	1
-6	1	1	1	1	1	1
-5	1	1	1	1	1	1
-4	1	1	1	1	1	1
-3	1	1	1	1	1	1
-2	1	1	1	1	1	1
-1	0.726	0.726	0.725	0.731	0.731	0.731
1	0.724	0.724	0.723	0.734	0.734	0.734
2	1	1	1	1	1	1
3	1	1	1	1	1	1
4	1	1	1	1	1	1
5	1	1	1	1	1	1
6	1	1	1	1	1	1
7	1	1	1	1	1	1
8	1	1	1	1	1	1
9	1	1	1	1	1	1
10	1	1	1	1	1	1

此处，CUSUM 方法只要检测出来变点就判断为异常均值单变点，因此其检验正确率在 $\Delta\mu \neq \pm 1$ 时都是 100%，与此同时，STMC 与 STMC-median 方法对异常均值单变点的检测正确率同样是在 $\Delta\mu \neq \pm 1$ 时都达到了 100%。此外还可以看到，只有当 $|\Delta\mu| = 1$ 时，CUSUM、STMC 与 STMC-median 方法的检测正确率都下降到了 72%左右，并且本文提出的方法与 CUSUM 方法十分接近。 $|\Delta\mu| = 1$ 时检测正确率下降是因为均值变化不太明显，CUSUM 算法无法很好地检测到均值单变点。因为 STMC 与 STMC-median 方法是在 CUSUM 方法的基础上，再次对检测出来的变点进行检验判断，因此对异常变点的识别准确率在 $\Delta\mu = \pm 1$ 时没有 CUSUM 方法高。但是 STMC、STMC-median 方法的正确率与 CUSUM 方法十分接近，这就说明本文基于 CUSUM 变点检测方法提出的 STMC 方法、STMC-median 方法也能很好地识别真正异常的均值单变点。值得注意的是，三种算法对异常非跳跃型均值变点数据的识别正确率比异常跳跃型均值变点数据的更高。

表 3 CUSUM、STMC 与 STMC-median 方法在异常均值单变点数据上的检验正确率

方法	跳跃型	非跳跃型
CUSUM	0.9725	0.9733
STMC	0.9725	0.9733
STMC-median	0.9724	0.9733

表 3 是 CUSUM 方法、STMC 方法、STMC-median 方法这三种方法在异常跳跃型均值单变点和异常非跳跃型均值单变点的模拟数据中不区分 $\Delta\mu$ 的检测正确率。从此表可以更加明显地发现：无论是在跳跃型均值单变点情形下还是非跳跃型均值单变点情形下，STMC 算法的正确率都与 CUSUM 方法的相同，STMC-median 的正确率仅比 CUSUM 方法的小 0.005%；并且在跳跃型与非跳跃型数据上，STMC 平均达到了 0.9729 的准确率，STMC-median 平均达到了 0.9728 的准确率，这些都说明本文提出的算法对真实异常均值单变点的检测识别是有效的。

5.1.1.3 小结

为了更加直观地分析本文提出的算法的效果，本节将 5.1.1.1 节和 5.1.1.2 节的结果汇总得到如下所示的表 4。

表 4 CUSUM、STMC 与 STMC-median 方法在均值单变点数据上的检验正确率

方法	CUSUM	STMC	STMC-median
准确率	0.4864	0.8929	0.9239

在上表中, 准确率是某一方法对以上每一种情形的模拟的正确率的均值。从中可以看到, 对于有异常均值单变点和无异常均值单变点情况下的模拟样本 (相同样本量), CUSUM 方法只能达到 0.486 的准确率, 本文提出的 STMC 算法达到了 0.8928 的准确率, STMC-median 因为在无异常均值单变点情况下检验性能更优, 因此总的准确率达到 0.9238。这说明直接利用 CUSUM 方法检测异常变点是不可行的, 而本文基于 CUSUM 方法提出的异常均值单变点检测算法对数据有异常和正常均值单变点的识别是十分准确、有效的。

5.1.2 方差单变点

这一节考虑数据存在正常与异常方差单变点两种情形, 即正常方差单变点和异常方差单变点。文章在这两种情形下分别生成模拟数据, 比较 CUSUM 方法和 STVC 方法的有效性。本节对参数 $\Delta\mu$ 的每个值都做 1000 次模拟, 并设置块 Bootstrap 抽样的块长度 $k = 7$, 抽样次数 $M = 800$, 显著性水平为 5%。

5.1.2.1 正常方差单变点

本节分析 STVC 算法对正常方差单变点的检测能力, 正常方差单变点模拟数据的分布情况如下图 (为便于观察, 只显示站点 1、2、3 的数据) 所示。




图 17 正常方差单变点模拟数据

正常方差单变点情形下的模拟数据通过以下步骤生成：假设站点 1 的方差变点发生时间是 $t = 601$ ，前 600 个样本来自于正态分布 $N(50, \sigma_1^2)$, $\sigma_1 = 1$ ，后 600 个样本来自于正态分布 $N(50, \sigma_2^2)$ ；站点 2-5 同样在第 601 个时刻发生方差变点，前 600 个数据分别来自于正态分布 $N(48, \sigma_1^2)$, $N(45, \sigma_1^2)$, $N(42, \sigma_1^2)$, $N(51, \sigma_1^2)$ ，后 600 个样本分别来自于正态分布 $N(48, \sigma_2^2)$, $N(45, \sigma_2^2)$, $N(42, \sigma_2^2)$, $N(51, \sigma_2^2)$ 。在正常方差单变点情形下，我们考虑所有站点数据的方差一致变化。为了测度不同方法对正常方差单变点的平均检测能力，我们设置 $\Delta\sigma = \sigma_2^2 - \sigma_1^2 = 0.25, 0.5, 1, 2, 3, \dots, 8, 9$ ，根据等式 $\Delta\sigma = \sigma_2^2 - \sigma_1^2$ 计算得到 σ_2^2 的值，并在每个 σ_2^2 下生成模拟数据。最终，CUSUM 算法和 STVC 算法对模拟的正常方差单变点数据的检测结果如下表所示。

表 5 CUSUM 方法与本文提出的 STVC 方法在正常方差单变点数据上的检验正确率

$\Delta\sigma$	0.5	1	2	3	4	5	6	7	8	9
CUSUM	0	0	0	0	0	0	0	0	0	0
STVC	0.926	0.935	0.926	0.931	0.938	0.922	0.907	0.915	0.93	0.925

从上表可看出，CUSUM 方法在正常方差单变点的情况下，完全无法给出正常判断（在 $\Delta\sigma$ 的每个取值下其判断正确率都为 0），这是因为 CUSUM 方法在检测到数据存在方差单变点时就判断该变点是异常方差单变点，但实际上数据是在正常变化。因为传统的 CUSUM 方法没有利用时空数据的空间信息，无法检测出时空数据的变点，基于此，本文研究了时空数据的变点检测，并提出了利用时空数据空间相关特征的时空异常方差变点检测算法——STVC 方法。对于本文提出的 STVC 算法，其不同方差变化程度下的检测正确率均达到了 90%以上，这说明本文提出的异常方差单变点检测算法对正常方差单变点的识别的有效性较强。

5.1.2.2 异常方差单变点

本节比较 CUSUM 与 STVC 算法对异常方差单变点的检测能力，模拟的异常方差单变点数据大致如下（为了便于观察，只显示了站点 1、2、3 的数据）。




图 18 异常方差单变点模拟数据

对于异常方差单变点，文章设置站点 1 方差变点发生的时间是 $t = 601$ ，前 600 个样本来自于正态分布 $N(50, \sigma_1^2)$ ，后 600 个样本来自于正态分布 $N(50, \sigma_2^2)$ ，站点 2-5 不存在方差变点，因此这 4 个站点各自的 1200 个样本分别来自于正态分布 $N(48, \sigma_1^2), N(45, \sigma_1^2), N(42, \sigma_1^2), N(51, \sigma_1^2)$ 。

此外，为便于分析 CUSUM 与 STVC 方法对数据存在不同程度异常方差单变点的检测能力，文章令 $\sigma_1^2 = 1$ ，设置 $\Delta\sigma = \sigma_2^2 - \sigma_1^2 = 0.5, 1, 2, \dots, 8, 9$ 。 $\Delta\sigma = 0$ 时为正常方差单变点， $\Delta\sigma$ 越大，方差单变点的异常程度就越大。CUSUM 算法和 STVC 算法对模拟的异常方差单变点数据的检测结果如下表所示。

表 6 CUSUM 方法与本文提出的 STVC 方法在异常方差单变点数据上的检验正确率

$\Delta\sigma$	0.5	1	2	3	4	5	6	7	8	9
CUSUM	1	1	1	1	1	1	1	1	1	1
STVC	1	1	1	1	1	1	1	1	1	1

异常方差单变点的模拟结果显示，CUSUM 检测算法和 STVC 检测算法对上表中 $\Delta\sigma$ 的每一个取值都达到了 100% 的正确识别率，这就说明上述两种算法对真实异常方差单变点的识别是非常有效的。

5.1.2.3 小结

为便于对比，文章将 5.1.2.1 与 5.1.2.2 节模拟数据分析结果汇总整理如下。

表 7 CUSUM 方法与本文提出的 STVC 方法在方差单变点数据上的检验正确率

方法	CUSUM	STVC
正确率	0.4545	0.9207

上表的检验正确率是检测算法在 $|\sigma_2^2 - \sigma_1^2|$ 的不同取值下得到的检验正确率的均值。由上表可见，在单个异常方差变点的情形下，CUSUM 算法对数据是否存在正常方差变点、异常方差变点的判断正确率仅为 45.45%，但是本文提出的 STVC 方法能达到 92.068%，这充分说明了本文提出的方法对数据是否含有异常方差变点、正常方差变点的检测识别是非常有效的。

5.2 多变点

5.2.1 均值多变点

进行本节分析前，有以下几点需说明。第一，对于均值多变点的数值模拟，本节只考虑双均值变点的情形，因为变点数大于 2 的情形可分解为双变点情形。第二，本节的均值变点只考虑非跳跃型均值变点的情形。之所以考虑非跳跃型变点，是因为非跳跃型均值变点在实际数据中更为常见，而且，从 5.1.1 节均值单变点的模拟可见，STMV 算法和 STMC-median 算法虽然在异常均值单变点检测中对跳跃型均值单变点和非跳跃型均值单变点的检测正确率基本相同，但是在正常均值单变点检测中对非跳跃型均值单变点的检测正确率比跳跃型均值单变点的更低，因此选择检测相对不准确的具有非跳跃型均值变点的数据来进行模拟分析。因为均值双变点在跳跃型和非跳跃型两种情形下的组合方式一共有 32 种，本节只对其中一种情形进行分析，更多情形的数值模拟分析见论文附录部分。本节模拟的均值双变点情形如下图所示。




图 19 非跳跃型均值双多变点的模拟数据

本节模拟的数据是具有非跳跃型均值双变点的,使用与 5.1.1 节类似的方法生成。对于站点 1-5 的前 100 个模拟数据,它们分别来自于正态分布 $N(50,1), N(48,1), N(45,1), N(42,1), N(51,1)$ 。为简便起见,记第 $i(i = 1, 2, \dots, 5)$ 个站点前 100 个数据的分布的均值为 $\mu_i(\mu_1 = 50, \mu_2 = 48, \mu_3 = 45, \mu_4 = 42, \mu_5 = 51)$ 。第 $i(i \neq 1)$ 个站点第 101 至 110 个数据通过 logistic 函数辅以服从正态分布 $N(0,1.5)$ 的随机噪声生成,即

$$x_{ij} = \frac{\mu_i - 10}{1 + \exp(-l_j)} + \varepsilon, \varepsilon \sim N(0,1.5), l_j = 0.5 * j - 2.5, i = 2, 3, 4, 5, j = 1, 2, \dots, 10,$$

后 190 个数据来自于正态分布 $N(\mu_i - 10, 1)$ 。对于站点 1, 其第 101 至 110 个数据通过 logistic 函数辅以服从正态分布 $N(0,1.5)$ 的随机噪声生成, 即

$$x_{ij} = \frac{\mu_1 - 10 + \Delta\mu}{1 + \exp(-l_j)} + \varepsilon, \varepsilon \sim N(0,1.5), l_j = 0.5 * j - 2.5, i = 2, 3, 4, 5, j = 1, 2, \dots, 10,$$

后 190 个数据来自于正态分布 $N(\mu_1 - 10 + \Delta\mu, 1)$ 。剩余的 200 个数据在分布上与前 200 个数据对称, 用相同的方法生成。需要注意的是, 上式中加入变量 $\Delta\mu$ 是用以调节点点 1 与其余站点的数据在谷底 ($100 < t < 200$) 时的均值差异的。在 $t < 100$ 时, 站点 1 与其余站点数据的分布的均值差是 10, 在谷底时 ($100 < t < 200$) 两者分布的均值差是 $10 - \Delta\mu$ 。当 $\Delta\mu = 0$ 时, $t=100$ 前后的均值差异相同, 那么 $t = 100$ 就是正常均值双变点的发生时间, 也就是说, 只要 $\Delta\mu \neq 0$, 站点 1 就存在异常均值双变点。我们通过设置 $\Delta\mu = 0, 0.5, 1, 2, \dots, 7, 8$ 来调节异常的程度, 图 19 就是 $\Delta\mu = 0$ 与 $\Delta\mu = 8$ 时的模拟数据。本节在 $\Delta\mu$ 的每个取值下, 都做 100 次模拟, 并使用本文提出的 STMC-median 方法去检测双变点, 最终得到的检测正确率如下所示。

表 8 本文提出的 STMC-median 方法在 1 种均值多变点数据上的检验正确率

$\Delta\mu$	0	0.5	1	2	3	4	5	6	7	8
正确率	0.83	0.96	1	1	1	1	1	1	1	1

从上表可见, 无异常均值双变点 ($\Delta\mu = 0$) 时, STMC-median 方法在 100 次模拟中有 83 次检测出数据存在正常均值双变点, 检测正确率为 83%。然而在 5.1.1 节的正常非跳跃型均值单变点的模拟实验中, STMC-median 方法的检

测正确率是 87%，这说明数据越复杂、变点个数越多可能会使得 STMC-median 方法的检测正确率越低。本节使用 $\Delta\mu = 0.5$ 来查看算法对不明显的异常均值双变点的检测能力，结果发现 STMC-median 检测判断出数据有异常均值双变点的次数是 96，检测正确率是 96%，这说明本文提出的 STMC-median 算法对不明显的异常均值双变点的检测也很有效。当 $\Delta\mu \geq 1$ 后，STMC-median 算法每一次都正确地检测出了模拟数据的变点，算法的检测正确率均是 100%。

综合以上分析，本文的 STMC-median 算法对正常均值双变点($\Delta\mu = 0$)和异常均值双变点($\Delta\mu > 0$)的识别能力都很好，虽然在正常均值双变点($\Delta\mu = 0$)的模拟数据上只有 83% 的正确率，但是对于异常均值双变点的模拟数据来说，该算法不仅能发现不明显的异常均值双变点，而且检验正确率都在 96% 以上。

5.2.2 方差多变点

对于方差多变点，本节只考虑两个变点的情形，假设站点 1 有两个方差变点，站点 2-5 的方差变点个数可能为 0、1、2 个，在站点 2-5 只有一个方差变点的情形下，本节又将其简单地分为两种情况。于是站点 2-5 的方差变点就有四种情形，站点 1 与站点 2-5 的方差变点组合情形就有四种（如图 20 所示），分别是无异常方差变点（图 20 中的类型 1）、存在一个异常方差变点（图 20 中的类型 2 与类型 3）以及存在两个异常方差变点（图 20 中的类型 4）。




图 20 站点 1 数据存在两方差变点时的异常方差变点具体类型

注：为简明起见，仅绘制站点 1 与站点 2 的数据分布；类型 1 代表站点 1 的数据无异常方差变点，类型 2 代表站点 1 的数据在左半部分存在一个异常方差变点，类型 3 代表站点 1 的数据在右半部分存在一个异常方差变点，类型 4 代表站点 1 的数据存在两个异常方差变点。

由 5.1.2 节的方差单变点检测结果可知, 算法检测正确率随 $|\sigma_2^2 - \sigma_1^2|$ 增加而增加, 因此本节方差多变点的模拟分析就不再探究算法检测性能与方差变化程度之间的关系, 设定 $\sigma_1^2 = 1, \sigma_2^2 = 4$ 。根据图 20 中的四种情形, 文章在每一种情形下做 1000 次模拟, 并使用本文提出的异常方差检测算法 STVC 得到如下结果。

表 9 STVC 方法在方差多变点数据上的检验正确率

组合类型	正确率
类型 1	0.911
类型 2	1
类型 3	1
类型 4	1
均值	0.970

本文提出的异常方差检测算法对真实异常变点的识别率非常高, 在具有一个和两个异常方差变点的数据上的正确识别率都达到了 100%, 对 0 个异常方差变点 (即正常方差变点) 的正确识别率是 91.1%, 这比在 5.2.1 节均值多变点下正常均值变点的识别率更高, 说明本文提出的异常方差检测算法对多变点的检测能力很强, 在多变点的异常变点检测上, 方差变点检测比均值变点检测更加稳定、检测正确率更高。此外, 在以上的模拟中, 不分异常变点个数得到的检测正确率是 97%, 同样说明本文提出的异常方差变点检测算法是非常有效的。

6 实际数据分析

本章使用北京市 11 个气象监测站点 2017 年 11 月 6 日 18 时至 11 月 8 日 12 时之间的 $\text{PM}_{2.5}$ 小时数据进行实际数据分析，11 个站点的 $\text{PM}_{2.5}$ 浓度图见文章 4.1.1 节的图 8。本节选取顺义站点数据作为研究对象，对实际数据使用本文提出的多均值变点下的异常均值检测算法（6.1 节）和多方差变点下的异常方差检测算法（6.2 节）进行检测分析，查看算法对实际数据的检测性能。因为使用的实际数据中并无异常均值和方差变点，所以为了比较检测结果，对实际数据进行修改后再做检测，最后分析比较检测结果。

6.1 均值变点分析

6.1.1 正常均值变点检测

从图 8 可发现，从 11 月 6 日 18 时开始，11 个站点的数据基本在水平线波动，11 月 7 日 9 时左右 $\text{PM}_{2.5}$ 浓度出现明显的均值变化：首先急剧下降，之后在很低水平的浓度上波动。由此可见，每一个站点的 $\text{PM}_{2.5}$ 数据都有均值变点，并且所有站点的 $\text{PM}_{2.5}$ 数据基本都是同向同步以基本相同的幅度在变化，这表明任何一个站点的数据都不存在异常的均值变点。本节选取顺义站点数据作为异常均值变点的检测对象，其余 10 个站点的数据作为辅助数据。

表 10 10 个站点对顺义站点的逆距离权重

站点	逆距离权重
奥体中心	0.0667
昌平	0.0845
东四	0.0606
官园	0.0600
古城	0.0513
怀柔	0.4405

农展馆	0.0646
天坛	0.0565
万柳	0.0606
万寿西宫	0.0542

选取顺义站点数据作为检测是否有异常均值变点的对象，其余 10 个站点数据作为辅助数据。根据站点经纬度，计算得到的顺义与其余 10 个监测站点的逆距离权重 w 如上表所示。

用本文提出的均值多变点检测算法 STMC-median 分析顺义站点的 $PM_{2.5}$ 数据，得到如下结果（为了便于观察，只显示奥体中心、昌平、东四、顺义四个站点的数据）。




图 21 顺义站点 2017 年 11 月 6 日 18 时至 8 日 12 时 $PM_{2.5}$ 数据异常均值检测结果

注：绿色竖线代表检测到的正常均值变点时间，红色竖线代表检测到的异常均值变点时间。

上图中红色与绿色竖线标记的是估计的均值变点发生时间，其中红色竖线代表正常均值变点，绿色竖线代表异常均值变点。我们将 11 月 6 日 18 时至 11 月 8 日 12 时的时间转换为 0-41 小时，并将其作为横轴。使用多均值变点检测算法 STMC-median 检测数据，得到一个均值变点 $t = 19$ （图中绿色竖线标记处）。从 $PM_{2.5}$ 浓度的变化来看，只有一个明显的均值变点，且位置是在 $t = 19$ 附近，可见 CUSUM 方法检测得很准确。因为使用的实际数据是经过严格审核的，因此不存在异常均值变点，而且 STMC-median 将 $t = 19$ 检测为正常方差变点发生时间，说明 STMC-median 方法对实际数据的检验非常准确。

6.1.2 异常均值变点检测

为了查看 STMC-median 对异常均值变点的检测能力,我们修改了顺义站点的数据 $x_t(t \geq 20)$,即 $x_t = x_t + 20, t \geq 20, t \geq 20$ 的数据的均值增加了 20,从而生成了具有异常均值变点的数据。变换前与变换后的顺义站点数据以及 STMC-median 算法对上述两种数据的检测结果对比如下。




图 22 STMC-median 方法对顺义站点原始数据(a)与变换数据(b)的检测结果

注: 绿色竖线表示检测到正常均值变点, 红色竖线表示检测到异常均值变点。

因仅使顺义站点 $t \geq 20$ 的 PM_{2.5} 浓度数据都上移了 20, 所以使得 $x_t(t \geq 20)$ 的均值增加了 20, 而其余 10 个站点数据未变化, 因此 $t = 19$ 的点是异常均值变点, 本文的 STMC-median 方法在变换后的数据上成功将 $t = 19$ 检测为异常均值变点。

STMC-median 既能正确检测数据不存在异常均值变点, 也能在修改后的数据上检测到异常均值变点, 这说明 STMC-median 方法对实际数据的有效性。

6.2 方差变点分析

6.2.1 正常方差变点检测

本节使用本文提出的 STVC 方法对顺义站点数据进行异常方差变点的检测, 记顺义站点的 PM_{2.5} 数据是 $x_t(1 \leq t \leq 43)$ 。从图 8 可以看到, 顺义站点数据在 $t = 19$ 处不仅存在均值变点, 而且 $t < 19$ 和 $t \geq 19$ 两段数据的方差是明显不同的, 因此 $t = 19$ 可能还是方差变点。我们使用能同时检测均值和方差变化的 R 函数 `cpt.meanvar` 对该数据进行检测, 得到 $t = 19$ 是方差变点发生时

间。基于此结果,本文使用提出的 STVC 方法去检测 $t = 19$ 并得到以下结果。图中正常方差变点使用绿色竖线标记,异常方差变点使用红色竖线标记。




图 23 顺义站点 2017 年 11 月 6 日 18 时至 8 日 12 时 PM2.5 数据异常方差检测结果

注: 绿色竖线代表检测到的正常方差变点时间, 红色竖线代表检测到的异常方差变点时间。

6.2.2 异常方差变点检测

因数据经过严格审核, 故不存在异常方差变点。为查看时空变点检测算法 STVC 对真实数据异常方差的检测性能好坏, 我们修改了时间 $t < 19$ 时的数据。具体是通过以下四个步骤修改数据的: (1) $\mu_1 = \sum_{t=1}^{18} x_t / 18$, (2) $x_t = x_t / 2$, (3) $\mu_2 = \sum_{t=1}^{18} x_t / 18$, (4) $x_t = x_t - \mu_2 + \mu_1$ 。该修改能使得 $x_t (t < 19)$ 的方差缩小 4 倍, 偏离修改前的正常方差水平, 但均值不变, 因此 $t < 19$ 就是异常方差发生时间点。修改前后的数据及其经 STVC 检测的结果对比如下。通过分析下图发现, STVC 在修改后的数据上正确将 $t < 19$ 识别为异常方差发生时间。




图 24 STVC 方法对顺义站点原始数据(a)与变换数据(b)的检测结果

注: 绿色竖线表示检测到正常方差变点, 红色竖线表示检测到异常方差变点。

综合上面的内容, STVC 既能正确识别实际数据中的零个异常方差变点, 同时能验证数据修改后存在异常方差变点, 这说明本文提出的时空方差变点检测算法能很好地应用到实际数据中。

7 总结与展望

7.1 工作总结

本文以站点监测收集到的 $\text{PM}_{2.5}$ 浓度数据为研究对象,通过对时空数据分布的分析来探究站点监测仪器是否故障的问题。从现有的变点检测方法文献中发现,变点检测方法能有效地通过对均值、方差等参数的检测,来达到检测数据的分布是否发生变化的目的。但是到目前为止,还没有文献针对空气质量监测数据的质量问题进行相应研究。本文根据数据在监测仪器故障下均值和方差发生变化的不同类型,详细分析了变点个数为单变点、多变点情形下关于均值和方差变点的检测问题,并提出了基于 CUSUM 方法与 Block Bootstrap 方法相结合得到的针对空气质量数据的无监督的时空数据变点检测算法,即时空数据异常均值变点检测算法 STMC、STMC-median,时空数据异常方差变点检测算法 STVC,用以检测是否是仪器故障导致的异常数据。本文主要做了以下几方面的工作:

(1) 针对仪器故障导致收集到的数据产生均值和方差变点的状况,提出了空气质量数据的时空变点检测算法,分别对单变点、多变点下的均值和方差变点情况做了详细分析,并提出了单变点、多变点的异常均值变点检测算法和单变点、多变点的异常方差检测算法。

(2) 分别对单变点、多变点的异常均值变点检测算法和单变点、多变点的异常方差检测算法做数值模拟实验,结果发现,当均值、方差变化越大,算法检测效果越好,算法检测正确率随着变化减小而下降的原因是 CUSUM 算法在均值和方差变化小时无法有效地检测到变化的发生。并且在均值单变点中,STMC 算法和 STMC-median 算法对模拟数据的检测分别达到了 89.35% 和 92.89% 的准确率,分别比 CUSUM 方法高出 40% 和 43.74%,在方差单变点

中, STVC 方法能达到 92.07% 的准确率, 比 CUSUM 方法高出 46.62%。在均值多变点模拟中, STMC-median 方法达到 83.5% 的准确识别率, 在方差多变点的模拟中, STVC 在无异常方差变点情况下达到了 97% 的准确识别率, 在一个和两个异常方差变点情况下的准确率都是 1。

(3) 通过实际数据分析发现, 本文提出的算法对顺义站点的 $\text{PM}_{2.5}$ 监测数据的分析效果很好, STMC 算法很好地检测到了原始数据的 1 个正常均值变点以及稍作修改后存在的 1 个异常均值变点。同样, 在异常方差变点检测上, STVC 算法判断数据不存在异常方差变点, 这与实际情况一致, 并在修改了其中一个正常方差变点之前的数据后, STVC 成功检测到了异常均值变点。

7.2 研究展望

本文以变点检测方法为基础, 利用空气质量时空数据的时间和空间信息, 提出针对个别站点数据分布异常变化的均值单变点、方差单变点、均值多变点以及方差多变点四种检测算法。算法在数值模拟和实证分析上表现出较好的效果, 但是仍然存在不足的地方, 还有一些工作需要进一步地展开与完善。

(1) 本文提出的算法十分依赖变点检测方法, 本文只是基于变点检测方法里的 CUSUM 方法展开个别站点数据分布异常变化的算法设计。对于空气质量这种时空数据, 可以继续收集、分析文献, 寻找更适合的变点检测方法, 这样能够提高本文提出的算法的完整度。

(2) 模拟部分的数据是使用独立的正态分布生成的。现实情况中, 较多的时空数据在空间上是不具有独立性的, 因此下一步可以在模拟部分使用时间序列模型, 比如 ARCH 模型等。

(3) 本文提出的算法, 不能同时对存在均值变点和方差变点的数据单独进行均值和异常方差变点的检测分析。未来可以探索如何自动地在任何情况下都可以对数据进行均值和方差的异常变点检测。

(4) 本文研究的前提假设较简单, 只假设单个站点仪器可能存在异常, 附近站点仪器正常。虽然这种针对一个站点仪器异常的检测也是存在真实案例的, 但是与在所有站点里检测任意仪器是否异常的情况相比, 本文的研究还是太局限, 未来可以深入研究任意多个站点的仪器是否异常的变点检测问题。

参考文献

- [1] Adams, R. P. & MacKay D. J. C.. Bayesian Online Changepoint Detection [J]. *Machine Learning*, 2007: 1-7.
- [2] Chandola, V. & Vatsavai, R.. Scalable Time Series Change Detection for Biomass Monitoring Using Gaussian Process [C]. *Proceedings of the 2010 Conference on Intelligent Data Understanding*, 2010: 69-82.
- [3] Chen, H. & Zhang, N.. Graph-based Change-Point Detection [J]. *Annals of Statistics*, 2014, 43(1): 139–176.
- [4] Chernoff, H. & Zacks, S.. Estimating the Current Mean of a Normal Distribution which is Subjected to Changes in Time [J]. *Annals of Mathematical Statistics*. 1964, 35: 999–1018.
- [5] Cleland, I., Han, M., Nugent, C., Lee, H., McClean S., Zhang, S., Lee, S.. Evaluation of Prompted Annotation of Activity Data Recorded from a Smart Phone [J]. *Sensors*, 2014, 14(9): 15861–15879.
- [6] Desobry, F., Davy, M., Doncarli, C. An Online Kernel Change Detection Algorithm [J]. *IEEE Transactions on Signal Processing*, 2005, 53(8): 2961–2974.
- [7] Feuz, K. D., Cook, D. J., Rosasco, C., Robertson, K., Schmitter-Edgecombe, M.. Automated Detection of Activity Transitions for Prompting [J]. *IEEE Transactions on Human-Machine Systems*, 2014, 45(5): 1–11.
- [8] Harchaoui, Z., Vallet, F., Lung-Yut-Fong, A., Cappe, O.. A regularized kernel-based approach to unsupervised audio segmentation [C]. *Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing*, 2009: 1665–1668.
- [9] Hines, W.. A Simple Monitor of a System with Sudden Parameter Changes [J]. *IEEE Transactions on Information Theory*, 1976, 22(2): 210-216.
- [10] Hines, W.. Improving a Simple Monitor of a System with Sudden Parameter Changes [J]. *IEEE Transactions on Information Theory*, 1976, 22(4):

- 496-499.
- [11] Hinkley, D. V. & Hinkley, E. A..Inference about the Change-Point in a Sequence of Random Variables [J]. *Biometrika*, 1970, 57(1): 1-17.
- [12] Kawahara, Y. & Sugiyama, M. Sequential Change-Point Detection Based on Direct Density-Ratio Estimation [J]. *Statistical Analysis and Data Mining*, 2012, 5(2): 114-127.
- [13] Kawahara, Y., Yairi, T., Machida, K. Change-point Detection in Time-Series Data Based on Subspace Identification [C]. *Proceedings of the 2007 7th IEEE International Conference on Data Mining*, 2007, 1: 559–564.
- [14] Keogh, E. J., Chu, S., Hart, D., Pazzani, M. J.. An Online Algorithm for Segmenting Time Series [C]. *Proceedings of the 2001 IEEE International Conference on Data Mining*, 2001: 289–296.
- [15] Marmasse, N., Schmandt, C., Spectre, D.. WatchMe: Communication and Awareness between Members of a Closely-Knit Group [C]. *Proceedings of the 2004 6th International Conference on Ubiquitous Computing*, 2004: 214–231.
- [16] Moskvina, V. & Zhigljavsky, A. An Algorithm Based on Singular Spectrum Analysis for Change-Point Detection [J]. *Communications in Statistics-Simulation Computation*, 2003, 32(2): 319–352.
- [17] Page, E.S. Continuous Inspection Schemes [J]. *Biometrika*, 1954, 41: 100-115.
- [18] Roberts, S. W.. Control Charts Based on Geometric Moving Averages [J]. *Technometrics*, 2012, 1(3): 239-250.
- [19] Rakthanmanon, T., Keogh, E. J., Lonardi, S., Evans, S.. Time Series Epenthesis: Clustering Time Series Streams Requires Ignoring Some Data [C]. *Proceedings of the 2011 11th International Conference on Data Mining*, 2011: 547–556.
- [20] Reddy, S., Mun, M., Burke, J., Estrin, D., Hansen, M., Srivastava, M.. Using Mobile Phones to Determine Transportation Modes [J]. *ACM Transactions on Sensor Network*, 2010, 6(2): 1–27.
- [21] Tran, D. Automated Change Detection and Reactive Clustering in Multivariate Streaming Data [J]. *Computer Science-Databases*, 2013.
- [22] Wei, L & Keogh, E. Semi-supervised Time Series Classification [C].

- Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2006: 748-753.
- [23] Yamanishi, K. & Takeuchi, J. A Unifying Framework for Detecting Outliers and Change Points from Non-Stationary Time Series Data [J]. *IEEE Transactions on Knowledge and Data Engineering*, 2006, 18(4): 482-492.
- [24] Zakaria, J., Mueen, A., Keogh, E. Clustering Time Series using Unsupervised-shapelets [C]. *Proceedings of the 2012 12th International Conference on Data Mining*, 2012, 785–794.
- [25] Zheng, Y., Liu, L., Wang, L., Xie, X. Learning Transportation Mode from Raw GPS Data for Geographic Applications on the Web [C]. *Proceedings of the 17th International conference on World Wide Web*, 2008: 247-256.
- [26] 陈杰. 变点检测与诊断及其在并行数据流中的应用研究[D]. 中国科学技术大学, 2020.
- [27] 彭娜. 基于行车状态数据的激进型驾驶行为检测[D]. 长安大学, 2019.
- [28] 陈希孺. 变点统计分析简介[J]. *数理统计与管理*, 1991(02): 52-59.
- [29] 陈希孺. 变点统计分析简介(III)极大似然法、累计次数法、Bayes 法[J]. *数理统计与管理*, 1991(03): 52-59.
- [30] 李晶晶, 李光强, 赵地, 肖昕. 基于变点的时空异常模式研究[J]. *测绘科学*, 2009, 34(02): 28-29+32.
- [31] 王慧敏, 贺兴时, 赵文芝. 变点统计分析及实例研究[J]. *电子测试*, 2013(18): 38-40.
- [32] 颜含笑. 整值自回归条件异方差模型的多变点检测问题[D]. 大连理工大学, 2016.
- [33] 许欢, 谭常春. 基于ASAMC算法的气象数据多变点估计[J]. *合肥工业大学学报(自然科学版)*, 2016, 39(12): 1719-1723.
- [34] 赵莎. 关于回归模型变点的在线监测问题研究[D]. 西安科技大学, 2014.

附录

在正文 5.2.1 节中, 文章就均值多变点情况进行了分析, 具体给出了双均值变点情况下的数值模拟, 并使用本文方法和 CUSUM 方法对模拟数据进行分析比较。因为双均值变点在均值变点存在跳跃和非跳跃两种情况下的组合方式很多, 一共有 32 种组合形式, 为了既能够探究文章提出的算法对双均值变点的检测效果, 又使得文章结构的安排相对比较合理, 于是, 5.2.1 节只对凹型的双均值变点情况在参数变化时进行了相应的模拟分析, 并且得到了新的算法对该问题的检测效果。

文章选择将两均值变点共计 32 种组合形式的数值模拟结果放在附录里进行展示, 其检测结果与 5.2.1 节的结论大致相同, 均是: 本文提出的基于 CUSUM 的时空数据异常均值变点检测方法(STMC)异常均值检测算法对异常均值的检测识别率很高, 但是在精确率上就有一定损失, 因为算法可能将正常均值变点识别为异常均值变点, 所以本节的模拟结果就不再总结具体的结论。

对于多变点, 算法检测效果根据均值异常变化程度而变化, 变化情况与单变点相同, 即均值变化差异越大, 算法检测效果越好。因此对于 32 种情形的数值模拟就不再分析均值变化差异的大小对算法的影响, 而只考虑跳跃型和非跳跃型的均值多变点在算法上的效果, 通过固定数据分布的参数, 并在每一种均值变点情形上模拟生成 100 个样本, 使用本文提出的新方法和 CUSUM 方法来共同检验。

根据均值变点的跳跃和非跳跃这两种情况进行组合, 可以得到凹型和阶梯型形状的数据, 如下图所示。具体地, 以站点 1 为例, 其中的凹型数据是指站点 1 的浓度先下降再上升。具有正常均值变点、异常均值变点以及跳跃型变点、非跳跃型变点的站点 1 与周围站点不同的权重和的组合方式一共有 16 种, 需要说明的是, 文章考虑的 16 种情况并不一定只是针对一种空气质量检

测对象浓度的变化。本节主要利用这 16 种基本情况的模拟数据对多变点的 CBI-media 算法进行分析评价，下图中展示的就是这 16 种情形，其中，蓝色实线是站点 1，橙色虚线是站点 2、3、4、5 的加权和。同样地，还是以站点 1 为例，阶梯型数据是指站点 1 的浓度呈阶梯形下降趋势。与凹型数据一样，站点 1 和站点 2、3、4、5 权重和的组合方式也有 16 种。对于阶梯型数据需要说明的是，因为阶梯上升型只是阶梯下降型的上下翻转而已，因此没有对前者进行数值模拟分析，阶梯下降型模拟数据如下图右部分所示。




图 25 两均值变点按形状和变点个数共 32 种组合情形图

对于模拟的 32 种情况，分别在凹型数据和阶梯型数据里设置大类为仅有 0、1、2 个异常变点，在大类别里设置小类，小类根据站点 1 和站点 2、3、4、5 权重和数据的形状来划分，用 $ijkl(i = 1, 2, j = 1, 2, 3, k = 1, 2, l = 1, 2, 3)$ 来代替不同形状的组合。1 代表数据有变点且变点类型为非跳跃类型，2 代表数据有变点且变点类型为跳跃类型，3 代表无变点。 i 、 k 分别代表站点 1 第一个变点段数据类型（跳跃型或者非跳跃型）和第二个变点段数据类型， j 、 l 分别代表站点 2、3、4、5 权重和对应站点 1 所在时间段的数据类型（跳跃型、非跳跃型、无变点）。对于 32 种类型，文章对每一种类型分别模拟 100 次，得到凹型和阶梯型的数值模拟结果如下表所示。

从下表中我们可以清楚地看到，无论是阶梯型数据还是凹型数据的双均值变点情形，本文提出的算法对两者的检测效果基本相同，尤其是对真实存在异常均值变点的情况，算法的检测准确率都是 100%，对于正常均值变点的

情况，算法的错判率在 35%左右，这说明算法对异常均值变点非常敏感，代价就是存在 30%的错判率。

表 11 本文提出的 STMC_median 方法在 32 种均值多变点数据上的检验正确率

大类	小类	小类累计		大类累计	
		检测出有异常变点的次数	正确率	检测出有异常变点的次数	正确率
凹型	0 个异常变点	1111	46	133	0.6675
		1122	32		
		2211	43		
		2222	12		
	1 个异常变点	1113	100	800	1
		1123	100		
		1311	100		
		1322	100		
		2213	100		
		2223	100		
		2311	100		
		2322	100		
	2 个异常变点	1313	100	400	1
		1323	100		
		2313	100		
		2323	100		
阶梯型	0 个异常变点	1111	61	139	0.6525
		1122	29		
		2211	37		
		2222	12		
	1 个异常变点	1113	100	800	1
		1123	100		
		1311	100		
		1322	100		
		2213	100		
		2223	100		
		2311	100		
		2322	100		
	2 个异常变点	1313	100	400	1
		1323	100		
		2313	100		
		2323	100		

致谢

从着手开始写论文，到不停地修改、更正、完善，直至最后论文完成，一回想，才发现自己从没有思路到写完论文，也是断断续续解决了不少问题，再追忆三年的研究生生活，才意识到光阴如梭。研究生期间，自己有过烦恼、失落、气馁、迷茫，有幸身边有良师益友的陪伴、鼓励、解惑。在此向研究生期间给予我指导、帮助、关心的人致以由衷的感谢。

在研究生期间对我在学习和生活方面的帮助最大的是我的导师**老师，我很庆幸能成为老师的学生。生活上，老师会关系我的生活学习状况，并在科研项目中提供生活补贴，减轻了我生活上的负担，能让我安心学习、从事科研项目。老师为人谦虚、平易近人，时常与我分享其为人处事的心得，令我受益匪浅。学习上，老师对我严格要求，当我遇到学习上的问题去寻求老师帮助时，老师也总是耐心指导，老师还给予我从事科研项目的机会，培养了我的科研能力与学习能力，为我论文研究与写作打下了基础。论文从选题、问题归纳、解决问题、到最终成稿，都是在老师精心指导下完成的，这篇论文凝聚着老师大量的心血。在论文完成之际，向恩师致以崇高的敬意和由衷的感谢！

此外，还要感谢科研课题小组的戴雨晴学姐、王博师兄，李雅茜以及孙丹，他们在我学习和生活上给予了很大的帮助，给我分享从事科学研究的经验，为我提供学习的资料与渠道，并耐心解答我的疑惑，让我体会到了团体的力量，使我在学习、生活与科研的过程中不再形单影只，而是越来越有干劲儿。在此，感谢你们的帮助和支持！

感谢我的家人，感谢你们无微不至的关心与时时刻刻的陪伴，因为你们，我能从一次次的困难中再次站起，重拾信心与勇气。感谢我的妈妈，养育了我二十几年，教我学会了乐观、爱、感恩与坚持，让我走到了现在。

最后，向百忙之中评审本论文的专家、老师表示衷心的感谢！



经世济民 孜孜以求

西南财经大学

SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

校址：四川成都温江柳台大道555号

电话：028-87092032 传真：028-87092632

邮编：611130

网址：<http://www.swufe.edu.cn>

Address: Liulin Campus (Main Campus): 555, Liutai Avenue,
Wenjiang District, Chengdu, Sichuan, P. R. China

Tel: 86-28-87092032 Fax: 86-28-87092632 Postcode: 611130