



西南财经大学

SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

硕士学位论文

MASTER'S DISSERTATION

基于自归一化方法的时空变点检测

Spatio-temporal Change Point Detection Based on Self -
Normalization Method

学位申请人 李鑫悦

指导教师 郭斌 副教授

学科专业 统计学

学位类别 理学

分类号 _____ 密级 _____

U.D.C _____

基于自归一化方法的时空变点检测

Spatio-temporal Change Point Detection Based on Self -
Normalization Method

学位申请人: _____ 李鑫悦

学 号: _____ 220071400005

学科专业: _____ 统计学

研究方向: _____ 不区分研究方向

指导教师: _____ 郭斌 副教授

定稿时间: _____ 2023 年 5 月

摘要

随着城市化和工业化进程的不断加快，我国面临严重的环境污染问题，特别是空气污染，近年来越来越受到大众的关注。我国主要通过各地污染物监测站点的数据来判定空气污染情况，因此，监测站点数据的准确性就尤为重要。我们希望对监测数据异常的情况及时发现并排查监测仪器故障，但是当污染物监测数据存在异常时可能是由刮风、下雨等气象因素引起的，所以当污染物监测数据存在异常时，也不一定是由于监测仪器故障引起的，若是气象因素引起的则没必要进行排查，所以我们要区分当监测站点数据出现异常时，是因为气象因素还是人为因素引起的，若为人为因素，则需要及时纠正，保证监测站点数据的准确性。目前广泛采用的核查方法是由专门员工对所有存在数据异常的监测站点进行人工核查，不仅效率低，而且带有明显的主观性。

为了提高效率，本文基于污染物监测数据的时空特性，利用自归一化方法，提出了一种新的时空变点检测方法。首先基于自归一化（Self-Normalization, SN）变点检测方法进行时空序列数据的变点检测，之后利用目标站点与邻近站点数据的空间相关性构建检验统计量，最后利用分块自助法（Block Bootstrap 方法）进行假设检验，判断站点变点的类型。该方法能够有效区分因气象因素引起的正常变点和因人为因素引起的异常变点，并且该方法利用自归一化（SN）方法进行变点检测，避免了累计和方法（CUSUM）在进行变点检测时因存在非单调的性质而影响变点检测结果的情况。

本文根据时空数据变点类型的不同，基于自归一化（SN）方法构建了时空数据均值变点和方差变点的检测算法，利用模拟数据进行了算法有效性检验，并与基于累计和（CUSUM）方法构建的时空变点检测算法进行比较，结果发现:对于均值变点，基于累计和方法（CUSUM）的时空变点检测算法

表现出非单调的性质，而基于自归一化（SN）方法的时空变点检测算法没有表现出非单调的性质，且具有较高的准确率，能有效检验变点；对于方差变点，基于累计和方法（CUSUM）的时空变点检测算法和基于自归一化（SN）方法的时空变点检测算法都具有较高的检验准确率，均能有效检验变点。本文还通过对成都地区的 $PM_{2.5}$ 实际数据建模，发现本文提出的时空数据异常变点检测算法能够准确识别出实际数据中的正常变点与异常变点，为实际应用提供了一定的基础。

关键词：变点检验；自归一化方法；累积和方法；分块自助法；时空数据

Abstract

With the continuous acceleration of urbanization and industrialization, China is facing serious environmental pollution problems, especially air pollution, which has received increasing public attention in recent years. China determines air pollution mainly through data from pollutant monitoring stations around the country, so the accuracy of monitoring station data is particularly important. We hope that the monitoring data abnormalities in time to find and troubleshoot the monitoring instrument, but when the pollutant monitoring data abnormalities may be caused by wind, rain and other meteorological factors, so when the pollutant monitoring data abnormalities, it is not necessarily due to the failure of the monitoring instrument, if it is caused by meteorological factors is not necessary to investigate, so we need to distinguish when the monitoring station data abnormalities. Therefore, we need to distinguish whether the abnormal data at monitoring stations are caused by meteorological factors or human factors, and if they are human factors, they need to be corrected in time to ensure the accuracy of the data at monitoring stations. At present, the widely used verification method is manual verification of all monitoring stations with abnormal data by special employees, which is not only inefficient but also with obvious subjectivity.

In order to improve the efficiency, this paper proposes a new spatio-temporal change point detection method based on the spatio-temporal characteristics of pollutant monitoring data using the Self-Normalization method. Firstly, the change point detection of spatio-temporal series data is performed based on the Self-Normalized variation point detection method, and then the spatial correlation between the target site and the neighboring site data is used to construct the test statistic, and finally the Block Bootstrap method is used to perform hypothesis testing to determine the type of site variation points. The method can effectively distinguish between normal change points caused by meteorological factors and abnormal change points caused by human factors, and the method uses the Self-

Normalization method for change point detection, which avoids the situation that CUSUM affects the variation point detection results due to the existence of non-monotonic power when performing change point detection.

In this paper, according to the different types of spatio-temporal data change points, the algorithm for detecting the mean change point and variance change point of spatio-temporal data is constructed based on the Self-Normalization method, and the validity of the algorithm is tested using simulated data, and compared with the spatio-temporal variation point detection algorithm constructed based on the CUSUM method, and the results are found: For the mean change point, the spatio-temporal variation point detection algorithm based on the CUSUM method exhibits the nonmonotonic power, while the spatio-temporal change point detection algorithm based on the Self-Normalization method does not exhibit the nonmonotonic power and has a high accuracy rate to effectively test the variation points. For the variance change points, both the spatio-temporal change point detection algorithm based on the CUSUM method and the spatio-temporal change point detection algorithm based on the Self-Normalization method have high testing accuracy, and both can effectively test the variation points. By modeling the actual PM_{2.5} data in Chengdu, we also find that the spatio-temporal data anomaly change point detection algorithm proposed in this paper can accurately identify the normal and abnormal change points in the actual data, which provides a certain basis for practical application.

Key words:Change Points Detection; Self-Normalization;CUSUM; Block Bootstrap; Spatio-Temporal Data

目 录

1.绪论.....	1
1.1 研究背景.....	1
1.2 研究内容.....	2
1.3 本文创新点.....	3
2.文献综述.....	5
2.1 变点检测.....	5
2.2 自助法.....	10
3.理论基础.....	12
3.1 变点问题.....	12
3.2 单变点检测方法.....	14
3.2.1 累积和方法.....	14
3.2.2 累积和方法缺陷.....	15
3.2.3 自归一化方法.....	16
3.3 多变点检测方法.....	18
3.4 分块自助法.....	18
4.时空单变点检测	20
4.1 问题背景.....	20
4.2 均值单变点算法.....	24
4.3 方差单变点算法.....	29
5.时空多变点检测	34
5.1 均值多变点算法.....	34
5.2 方差多变点算法.....	36
6.数值模拟.....	38
6.1 单变点模拟.....	38
6.1.1 正常均值单变点	39
6.1.2 异常均值单变点	44
6.1.3 正常方差单变点	47
6.1.4 异常方差单变点	48
6.2 多变点情况.....	49
6.2.1 正常均值多变点	50
6.2.2 异常均值多变点	51
7.实际数据分析	54
7.1 均值变点检测.....	54
7.2 方差变点检测.....	57

8.总结与展望.....	60
8.1 工作总结.....	60
8.2 研究展望.....	61
参考文献.....	63

1.绪论

1.1 研究背景

空气是人类赖以生存的基础，一个城市空气质量的好坏不仅影响着城市居民的生活情况，也影响着一个城市的总体排名，空气质量好的城市能够带给城市居民宜居的环境和健康的体魄，能够吸引更多人来此定居。因此近年来，空气质量越来越受到人们的重视，然而改革开放以来，随着我国城市化和工业化进程的不断加快，虽然我国经济取得了巨大的进步，也面临着严重的环境问题，特别是空气污染问题。空气污染不仅影响生态平衡，而且给人民健康和经济增长造成了显著的不良影响。过去，已经有许多重大的大气污染事件：比利时马斯河河谷的雾霾事件，是 20 世纪第一次有记载的大气污染，仅仅一个星期就造成了数十人的丧生。；1943 年的洛杉矶光化学烟雾事件除造成多人死亡外，还引发了各种事故和农作物的大量死亡等，给当地经济造成了巨大损失，引发群众恐慌；1952 年的伦敦烟雾事件是典型的煤烟型空气污染案例，在仅仅 4 天内造成数千人死亡，对人民的健康和生命安全造成严重威胁。因此，我国十分重视空气质量问题，出台了一系列文件，2022 年，生态环境部颁发了《“十四五”环境健康工作规划》，提出了我国的空气污染问题的整治规划。

我国的空气污染情况主要是由地方监测站点发布的空气污染物数据来判断的，国家根据各地的空气污染情况，制定相应的对策，因此，空气污染物监测数据的准确性尤为重要。然而实际生活中，有很多企业为了一时经济利益不顾长远利益，肆意污染环境，甚至人为干扰检测数据试图隐瞒环境的真实情况。山西省临汾市于 2018 年被环保部门查出，临汾市 6 个由国家控制的大气污染监测点的监测中，相关工作人员对采样口和监测设备进行了多轮

的封堵和喷洒，造成了大气污染监测结果的严重偏差。空气质量数据造假案件绝非个例，类似的情况全国还有很多。我国对监测数据造假问题十分重视，《环境保护法》明确禁止、伪造、伪造或煽动伪造或伪造监测数据，如情况严重且构成犯罪，应依法调查刑事责任。因此，当监测站点的数据存在异常时，则需要对该站点进行排查，查明数据异常原因并及时修正，然而刮风、下雨等自然因素也会使得污染物数据存在异常，而我们只需要对监测仪器故障或人为修改数据等非自然因素引起的数据异常进行处理，及时修理仪器或对修改监测数据的违法行为进行处罚。因此我们需要对监测站点数据异常原因进行判断。实际情况中，这一判断往往是由专人判断的，是由专门员工通过实际情况结合以往的数据判断的，这一判断不仅具有主观性，而且浪费时间和金钱。于是本文试图提出相较于人工审核方法更加高效、准确的一种算法，判断站点监测数据的异常是由自然因素还是非自然因素引起的。

空气污染物数据是时间序列数据，因此我们可以用变点检测方法来判断监测数据是否存在异常，然而，现有的变点检测方法只能检测数据是否存在异常，不能判断引起数据异常的原因，因此无法用现有的变点检测方法直接得出监测数据出现异常的原因。因为邻近站点的污染物浓度数据具有空间相关性，比如片区刮风往往会引起邻近站点的污染物浓度数据均显示相似的变化趋势，因此本文采用相邻站点的污染物浓度数据作为参考数据，利用站点间的空间相关性构建算法来判断监测数据出现异常的原因。本文构建的空气污染物数据异常原因判断算法，相对于传统人工判断方法更加准确、高效，并且在数值模拟和实际数据中都验证了其有效性，为实际站点污染物数据异常原因的判断提供了参考。

1.2 研究内容

本文以经典的变点检测方法为基础，利用站点的空间相关性构建算法来判断污染物数据异常原因，以便对由于监测仪器故障或人为修改数据等非自然因素引起的污染物数据异常的情况及时做出处理。本文使用了两种经典的变点检测方法来判断数据发生异常变化的时间点，分别是累积和方法（CUSUM）和自归一化（SN）方法，然后根据站点间的相关性，利用目标

站点和相邻站点的反距离加权数据在变点前后的差值构建检验统计量，再利用分块自助（Block Bootstrap）抽样方法得到统计量的分布，进行数据异常不是人为因素引起的假设检验。

本文内容主要分为 7 章，各章的主要内容如下：

第 1 章绪论，在文章的开头，介绍本文的研究背景与本文的主要内容以及本文的创新性。第 2 章文献综述，对本文用到的方法——变点检测和自助法的国内外研究现状进行了综述。第 3 章理论基础，对本文使用的变点检测方法——累积和方法（CUSUM）和自归一化（SN）方法以及抽样方法分块自助法（Block Bootstrap）进行了介绍。第 4 章时空单变点检测，利用累积和方法（CUSUM）和自归一化（SN）方法和分块自助法（Block Bootstrap），构建了时空数据单变点的均值和方差检验算法。第 5 章时空多变点检测，在第 4 章的基础上做出扩展，提出了时空数据多变点的均值和方差检验算法。第 6 章数值模拟，生成模拟数据，检验本文提出的时空数据变点检测算法在不同情况下的有效性。第 7 章实际数据分析，利用成都地区污染物监测的实际数据，检验本文提出的时空数据变点检测算法在实际数据上的效能。第 8 章总结与展望，在本文的结尾部分，简要地介绍了本论文所做的工作，同时也提出了本论文所做的工作中的一些缺陷，并提出了今后的研究方向。

1.3 本文创新点

基于以上研究内容，本文的创新点主要有以下三点：

（1）现有的变点检测算法仅能对监测站点数据存在异常的情况进行检测，并不能判断异常原因。本文基于经典变点检测方法自归一化（SN）方法和分块自助法（Block Bootstrap）构建了时空数据异常变点检测算法，能够监测站点数据存在异常的情况进行判断，并且本文提出的时空数据异常变点检测算法在模拟数据与实际数据都有很好的表现。

（2）本文提出的时空数据异常变点检测算法，能够自动判断目标站点数据的站点类型，相对于传统人工审核方法更加高效、准确。

（3）累积和方法（CUSUM）是变点检测最常用的方法，但是累积和方法（CUSUM）的实验中表现出非单调的能力即当结构变化幅度增加到一定

程度时，累积和方法（CUSUM）对变点的检测能力不再加强反而削弱直至为零。本文采用自归一化（SN）方法构建时空数据异常变点检测算法，避免了对长期方差的估计，从而解决了非单调的问题，并且与基于累积和方法（CUSUM）构建的时空数据异常变点检测算法进行了比较，证明了其优越性。

2. 文献综述

2.1 变点检测

变点，就是指在某一位置或时刻，在此前后某个序列或过程突然发生了结构性变化。变点问题是 Page 于 1954 年在研究质量工程问题中首次提出的，此后几十年来，变化问题引起了各种研究领域的广泛关注，广泛应用于金融学、气象学、地质学、医学、信号处理等领域。例如，杨喜寿和杨洪昌（1996）利用气象时间序列的变点检测进行了对气候阶段的划分；Wu 和 Zhao（2007）检测了金融建模的时间序列数据的均值变化；Muggeo 和 Adelfio（2011）通过应用均值变化点检测方法确定了与某些疾病相关的基因。

一般来说，变点的研究往往分为两个方面：变点估计和变点检验，变点估计就是对明确存在变点的序列，对变点的位置、个数和类型进行统计推断，变点检测是指通过对一个序列的检测，来确定它的变点存在与否。根据其所用的方式，可以把变点问题划分成多种类型：根据变点所处的位置，可分为突变点问题和渐近变点问题；从变点个数出发，可分为单变点问题 and 多变点问题；从序列是否相依出发，可分为独立序列变点问题和相依序列变点问题；从变点性质来看，可分为均值变点问题、方差变点问题和持久性变点问题。

均值变点就是在变点前后序列均值发生变化。很多学者对均值变点进行了研究：Sen 和 Srivastava（1975）在方差未知时的情况下，对序列的均值变化进行了检测，Worsley（1986）以指数族随机序列作为研究对象，利用极大似然方法对序列的均值变化进行了检测；Srivastava 和 Worsley（1986）研究了多元正态均值变点的似然比检验；Hawkins 等（1986）研究了基于最小二乘法对独立随机变量序列均值变点的检测；James 等（1987）比较了基于似然比和递归残差等检验方法对序列均值变点的检验效能；Han 和 Tian（2006）

讨论了厚尾相依序列中的均值变点问题，提出了一种通过截断初始过程来估计序列均值变点的方法；Horváth 等（2008）研究了短记忆过程中的均值变点问题；Wang（2008）研究了长记忆过程中的均值变点问题；Han 和 Wang（2008）选择了重尾相依序列的均值变点问题作为主要研究内容，利用 CUSUM 估计给出其相容性，并分析其收敛性；Zhou 等（2010）提出了一种检测和估计非参数回归模型均值变点的小波方法；王丹等（2011）基于 Wilcoxon 秩和统计量，研究了重尾序列的均值变点的非参数检验问题；赵文芝等（2016）利用 Ratio 统计量，完成了对长相依序列均值变点的检测；金浩和张思（2017）利用残量平方累计和统计量，检验了基于稳定分布的 ARCH 模型的均值变点。

方差变点就是在变点前后序列方差发生变化，很多学者也对方差变点进行了研究：Hsu（1977）在最初方差水平未知的情况下，给出了两种检验独立正态随机变量序列中方差结构化变化的检验方法；Gombay 等（1996）研究了对独立随机变量序列方差变点的检测；Wang 和 Bhatti（1998）研究了只有一个变点的正态分布序列的方差变点检验；Chen 等（2005）提出了一种结合最小二乘法和非参数方法的混合估计方法，对相依观测序列的方差变点进行了估计；Oh 等（2005）先利用人工神经网络对序列数据进行了分割，在进行方差变点的检测；Wang 和 Wang（2006）研究了长记忆线性过程的方差变化问题；袁芳等（2010）研究了独立同分布序列的方差变点的累积和估计；赵文芝等（2009）对线性过程中方差的结构性变化进行了研究，并给出了检验统计量；Harchaoui 和 Lévy-Leduc（2010）在变量选择上施加惩罚项，提出了检验金融时间序列方差变化点位置估计的方法；张学新（2014）提出了基于随机排列方法对时间序列方法变点的检验统计量，并对其检验性能进行了比较；张笛等（2020）提出了大样本数据中方差变点的两阶段估计方法，在保证估计良好的情况下节省了估计时间。

变点研究按检测方法可以分为很多类别，许多学者对其进行了讨论，主要有以下几种常用方法，适用于不同的变点形式：极大似然比方法（MLR）是变点理论中比较早的一种方法，主要用于研究正态均值分布的变点情况。最小二乘法（LSM）不用对随机误差的分布做特定假设，以观测值和理论值的平方和之差作为目标函数，在变点问题中也有很多应用。累计和方法

(CUSUM) 计算简单, 且渐近分布是 Brown 桥, 是变点研究中的常见方法, 广泛运用于工业质量控制、自动故障监测、经济、金融等方面。一般对变点的参数估计采用的是极大似然法, 贝叶斯方法与其他检测变点的方法相比, 贝叶斯方法可以提供一个位置位置的概率分布, 因此在变点的一些领域得到广泛运用。因为小波系数能够反映原函数的绝对性质, 其在光滑点绝对值较小而在不连续点绝对值较大, 因此小波方法也是研究变点问题的有利工具。LASSO 方法是最小二乘法的一个扩展, 其基本原理是在最小二乘法的基础上引入惩罚项以达到减少模型复杂度的目的, LASSO 方法的优点在于在变点估计时可以同时进行参数估计和变量选择, 能够达到较好的变点估计效果。接下来将详细介绍极大似然比方法 (MLR), 最小二乘法 (LSM)、累计和方法 (CUSUM)、贝叶斯方法、小波方法和 LASSO 方法的检测方法和对应的文献。

似然比测试是一种利用两个相反的似然函数的比值, 即似然比, 来判断一个假设的是否正确的一种测试方法。运用到变点检验上, 就是通过目标点前后的数据, 构建似然比统计量, 判断目标点是否是变点。Hinkley (1970) 使用随机游走结果, 以可计算的形式导出正态分布变点的极大似然估计的渐近分布, 并且给出了单侧和双侧情况下变点的似然比检验统计量; 当利用似然比检验检验线性过程的变点时, 会由于参数不稳定性导致检验不一致, 因此 Banerjee 和 Lumsdaine (1992) 提出了通过截尾似然比统计量来检验线性过程中的结构性变化; Gupta 和 Ramanayake (2001) 利用广义似然比检验的思想, 给出了指数独立随机变量序列变点的检测方法和检验统计量并讨论了其性质。

最小二乘法是一种被广泛用于各种数据处理领域的数学方法, 如误差估计, 不确定性, 系统辨识, 预测和预报等。Bai (1994) 研究了线性过程中的单变点问题, 并采用最小二乘法估计了变点, 并给出了参数的渐近分布; Chen 等 (2005) 提出了一种估计方法, 融合了最小二乘法和非参数方法, 用以对时间序列模型中波动的结构性变化进行检测, 在此基础上给出了估计量的渐近性质。

累计和方法 (CUSUM) 最早是由 Page (1954) 发表在 *Biometrika* 杂志, 它是 Page 在研究如何在自动生产线上检验产品品质时提出的, 他希望, 当

产品品质超过产品品质控制警戒线时，可以及时报警，让工厂及时发现，停止生产，避免生产过多不合格产品，损害工厂的经济效益。这个产品品质超过产品品质控制警戒线的时刻为变点。为找到变点，Page（1954）提出了累计和方法（CUSUM）并给出了 CUSUM 方法的双侧检验统计量，CUSUM 方法的原理是通过计算样本值与目标值的偏差的累积和，将过程的微小偏移累积起来以达到放大的效果，然后构建 CUSUM 统计量来检测变点。自 Page 于 1954 提出 CUSUM 方法以来，很多学者都对 CUSUM 进行了研究并提出了一些改进，CUSUM 方法由门限值 h 和信念值 h 决定，传统 CUSUM 方法在检测较小漂移和较大漂移上效果并不理想，因此濮晓龙（2003）基于 CUSUM 统计量给出了两个新的检验统计量 PCUSUM 和 DCUSUM，对较小漂移和较大漂移进行了检验，这两个新的检验统计量较传统 CUSUM 统计量在检测上更有优势；Lee 等（2003）研究了基于 CUSUM 检验的时间序列模型参数变化的检验问题；Berkas 等（2009）利用加权 CUSUM 方法，对线性过程中的协方差的结构性变化进行了检测；Shi 等（2009）研究了 CUSUM 统计量的强收敛性；Perron (1991), Vogelsang (1999), Deng 和 Perron (2007) 等均发现 CUSUM 方法具有非单调的性质，即当结构变化幅度增加到一定程度时，CUSUM 方法对变点的检测能力不再加强反而削弱直至为零，影响对变点的检测，因此 Shao 和 Zhang (2010) 将自归一化(SN)方法扩展到变化点测试问题，提出一个变点检验新的统计量——SN 统计量，新提出的 SN 统计量避免了对长期方差的直接估计，因此不存在非单调的性质；Robbins 等（2011）提出了提出了一个调整后的 CUSUM 统计量，它与 LR 检验密切相关，调整后的 CUSUM 统计量相对于经典 CUSUM 统计量具有更好的检测效果；Li 等（2015）提出了基于 CUSUM 统计量的面板数据模型方差变点的检验新方法，推导了其在零假设下的渐近分布，并证明了其在备择假设下检验的一致性；秦瑞兵和郭娟（2017）基于最小二乘残差构造了 CUSUM 统计量，以检测平稳过程趋势项的变点；吉毛加等（2019）基于最小二乘拟合残差构造了一种新的 CUSUM 型检验统计量，对长记忆时间序列趋势项的进行了变点检测；谭常春和江敏（2020）通过不同参数的测试，研究了不同参数对 CUSUM 型统计量变点估计的有效性，并且基于数据驱动，对不同参数的筛选进行了阐述；Holmes 和 Kojadinovic（2021）研究了基于 m -渐近几乎负相

关(m-AANA)序列的均值变点模型的CUSUM型估计,并在一些弱条件下,得到了一些收敛速度。

贝叶斯方法是一种常用的变点检测方法,通过建立贝叶斯统计数据来检测变化点。与其他检测变化点的方法相比,贝叶斯方法可以提供一个位置位置的概率分布。Carlin等(1992)基于迭代采样的方法即吉布斯采样的方法构建了层次贝叶斯变化点模型;Perreault等(2000)年提出了一种贝叶斯方法来估计水文气象时间序列中变点;周影辉等(2010)提出了一个贝叶斯变点检测方法检测伯努利序列中的变点问题,即用二分法将伯努利序列转换为没有变点和仅有一个变点的两种形式,然后通过贝叶斯方法进行检验;汤银才等(2015)在变点的先验分布为 β -二项分布和幂先验的条件下,研究了带一个变点的线性模型的贝叶斯统计推断问题;李强等(2016)基于贝叶斯方法,提出了一种广义ARCH模型变点检测新方法,并利用股票数据进行了实证分析,证明了其所提出的变点检测方法的有效性。

小波方法是基于小波分析检验变点的非参数方法,小波分析能够将频率不相同的时间序列分解为频率不相同的子序列,当时间序列出现变点时,变点前后时间频率特性出现明显改变,因此可以用小波方法来检测变点。李订芳等(2005)基于小波分析能够将频率不相同的时间序列拆解为频率不相同的子序列的原理,设计了基于小波分析的变点探测算法,并以此来研究时间序列的变点;齐培艳和田铮(2008)利用小波方法研究了无穷方差厚尾过程中的变点;傅强等(2009)通过分析时间序列样本点对应小波变换模极大值线的小波系数特征,提出了一种检测金融时间序列变点的小波模极大线方法,并以GARCH模型为例进行仿真,证明了该小波检验方法的有效性;Zhou等(2010)提出了一种检测和估计非参数回归模型均值函数中的跳跃和尖点的小波方法,其方法的特征是它允许序列中存在条件异方差。

LASSO是一种变量选择方法,它通过施加一些惩罚项,使回归参数变小甚至直接为零。Levy-Leduc和Harchaoui(2007)提出了利用LASSO方法来估计白噪声中一维分段常数信号中变化点位置;Bleakley和Vert(2011)将一维情况扩展到了多维情况,把变点的估计问题转化成了基于LASSO方法的变量选择问题;Angelosante和Giannakis(2010)研究了时变自回归系数逐段常数过程中变点的Group LASSO估计方法;Zhong(2012)研究了分

位数回归模型中基于 LASSO、SCAD、Adaptive LASSO 的变点估计和变量选择方法；龙振环等（2017）利用 LASSO 方法和广义贝叶斯信息准则对具有多个变点的分段连续线性分位数回归模型的变点进行了估计和检验。刘杰等（2020）提出了一种基于两阶段 LASSO 的算法，用于非平稳时间序列中一类分段平稳自回归过程的变点估计和模型选择。

2.2 自助法

自助法（Bootstrap），是一种统计学研究方法，最早是由美国统计学家 Efron（1979）提出的，其基本思想就是简单有放回抽样，利用重抽样技术，来估计样本的分布、标准误差、置信区间和偏差等统计性质，自助法（Bootstrap）不需要过多的样本，也不需要事先知道样本的分布，因此被广泛使用。自 Efron 于 1979 年提出 Bootstrap 方法以后，国内外很多学者都对 Bootstrap 方法进行了研究，独立同分布的 Bootstrap 方法是 Bootstrap 方法理论中最基础的部分，Bickel 和 Freedman（1981）首先给出了 Bootstrap 对独立同分布随机变量样本均值的有限方差近似；Singh（1981）证明了 Bootstrap 逼近的收敛速度比传统的正态逼近快；Arlot（2010）利用广义加权独立随机分布 Bootstrap 方法构造了非渐近置信区间样本均值高斯向量的多维独立随机置信区间。。实际情况中，我们的样本数据并不都是独立同分布的，因此许多学者对独立同分布的 Bootstrap 方法进行扩展，衍生出了分块自助法（Block Bootstrap）和 Sieve Bootstrap 方法。Liu 和 Singh（1992）提出了处理相依结构数据的分块自助法（Block Bootstrap），其基本思想是因为数据之间具有相依性，因此不能像独立同分布数据那样在数据内部对单个数据进行抽样，所以在抽样的时候我们应该保证某按每“块”（Block）数据进行抽样。分块自助法（Block Bootstrap）最重要的思想就是将数据分块进行抽样，所以块的长度划分很重要，Hall 和 Horowitz（1995）对分块自助法（Block Bootstrap）中块的长度的选择进行了讨论。很多学者运用了分块自助法（Block Bootstrap）来解决实际问题，秦瑞兵和郭娟（2017）基于正则方法构造了 CUSUM 型统计量，对无穷方差重尾相依序列的均值变点进行检测，并采用分块自助法（Block Bootstrap）方法检验该方法的有效性；刘久

彪（2017）利用分块自助法（Block Bootstrap）对样本进行了扩充，对银行内部评级系统区分力度进行了度量，并与未扩充的样本进行了比较；William 和 Dimitris（2018）提出了一种新的重采样非齐次泊松标记点过程的局部分块自助法，对 d 维有标记点过程样本均值进行估计。Sieve Bootstrap 方法最初是由 Bühlmann（1997）提出的，其基本思想是用拟合序列后的残差的有序有放回抽样结果代替原模型的残差序列，并从被代替的残差序列中得到一个新的序列，重复多次后得到所需的统计量，很多学者运用了 Sieve Bootstrap 方法来解决实际问题，Andre'es 和 Daniel（2002）提出了构造一般线性过程的非参数预测区间的 Sieve Bootstrap 方法；Webber 和 Gupta（2007）本文提出了一种非参数 Sieve Bootstrap 方法，用于估计脉冲响应系数的方差和通过相关分析确定的过程稳态增益；严方笠和吴建鑫（2017）利用 Sieve Bootstrap 方法，对季节性时间序列模型的单位根进行了检验。

3.理论基础

本文以经典的变点检测方法为基础，探究时空数据的变点问题，本章主要介绍本文使用的经典的变点检测方法，作为第4、5章探究时空变点检测方法的理论基础。

3.1 变点问题

假设时间序列数据 $\{X_t\}_{t=1}^n$ 存在变点，变点发生时间为 k ，则以变点发生时间划分时间序列，前后样本序列的分布不同，即：

$$\begin{aligned} x_i &\in F(x, \theta_1), \quad 1 < i < k. \\ x_i &\in F(x, \theta_2), \quad k < i < T, \theta_1 \neq \theta_2, \end{aligned}$$

其中 θ_1 和 θ_2 是不同的参数。

变点问题一般由变点检测和变点估计两部分组成。变点检测是指通过对一个序列的检测，来确定它的变点存在与否，变点估计就是对已知存在变点的序列，对变点的位置、个数和类型进行统计推断。根据分类的方式，可以把变点问题划分成多种类型：由变点数量出发，可分为单变点问题 and 多变点问题。若序列只存在一个变点，则为单变点问题，设序列 $\{X_t\}_{t=1}^n$ 在 $t = k$ 处存在变点，即 $\{x_1, \dots, x_k\}$ 和 $\{x_{k+1}, \dots, x_n\}$ 属于不同的分布。若变点数量 $m \geq 2$ ，则为多变点问题，设 m 个变点的位置分别为 $k_1, \dots, k_m$ ，则 $\{x_1, \dots, x_{k_1}\}, \dots, \{x_{k_{m-1}}, \dots, x_{k_m}\}$ 的分布不同。由变点性质出发，又可分为均值变点和方差变点。本文仅讨论变点前后序列仅均值发生变化的均值变点和在变点前后序列仅方差发生变化的方差变点，均值与方差同时变化的变点暂不做讨论。下图分别是变点时刻为 k 的均值变点（变点 $t = k$ 前后数据服从均值不同方差相同的正态分布）和变点时刻为 k 的方差变点（变点 $t = k$ 前后数据服从均值相同方差

不同的正态分布)。




图 1 均值变点




图 2 方差变点

首先是单变点问题的变点检测，假设时间序列数据 $\{X_t\}_{t=1}^n$ 的分布为 $F(x, \theta_1)$, $\theta \in \Theta$, Θ 是参数空间, 则检测单变点问题的假设检验如下:

$$H_0: (X_t)_{t=1}^n \in F(x, \theta_1).$$

$$H_1: (X_t)_{t=1}^k \in F(x, \theta_1), (X_t)_{t=k+1}^n \in F(x, \theta_2), \theta_1 \neq \theta_2.$$

原假设 H_0 表示序列 $\{X_t\}_{t=1}^n$ 来自同一分布 $F(x, \theta_1)$, 即没有变点, 备择假设 H_1 表示序列 $\{X_t\}_{t=1}^k$ 和 $\{X_t\}_{t=k+1}^n$ 来自参数不同的分布 $F(x, \theta_1)$ 、 $F(x, \theta_2)$, $\theta_1 \neq \theta_2$, 即存在一个变点, 变点位置为 k , $1 \leq k \leq n-1$ 。变点检测就是在给定显著性水平的情况下, 根据不同的变点检测方法计算相应的拒绝域, 判断 H_0 的显著性, 若存在变点, 再进行参数的估计, 其中参数的估计包括分布函数的参数估计和变点时间的估计。

接着讨论多变点问题的变点检测, 假设序列 $\{X_t\}_{t=1}^n$ 存在 m 个变点, 变点时间记为 $k_1, \dots, k_m$ 其中 $k_i < k_j$ 当且仅当 $i < j$, 并假定 $k = 0, k_{m+1} = n$ 。多变点问题是单变点问题的一个扩展, 我们可以通过划分数据将多变点问题变为单变点问题, 例如, 序列 $\{X_t\}_{t=1}^n$ 我们可以划分为 $m + 1$ 段序列 $(x_{i,1}, \dots, x_{i,k_1})$ 、 $\dots$ 、 $(x_{i,k^N}, \dots, x_{i,k_m})$, 每个序列可以用单变点问题的检验方法去检验, 则多变点问题的假设检验如下:

$$\begin{aligned} H_0: (X_t)_{t=1}^n &\in F(x, \theta_1), \\ H_1: (X_t)_{t=k_{i-1}}^{k_i} &\in F(x, \theta_i), 1 < i < n, \end{aligned}$$

其中当 $i \neq j$ 时, $\theta_i \neq \theta_j$ 。

3.2 单变点检测方法

3.2.1 累积和方法

累积和检验 (Cumulative Sum, CUSUM) 是一种时间加权控制图, CUSUM 控制图一般可分为参数和非参数两类, 但在实际应用中, 由于参数估计困难, 特别是信号的概率分布难以获得, 一般采用非参数控制图。在变点检测方面, 本文的研究重点是对有无变化点进行检测, 并对出现的时间进行估算。CUSUM 方法是 Page (1954) 首次提出的一种基于序列分析的序列概率比检验 (Sequential probability Ratio Test, SPRT) 方法, 该方法通过对目标数据的累计误差进行统计, 实现对目标数据的放大, 进而实现对目标数据的有效处理。由于 CUSUM 方法具有简便、判定准则简便、便于操作等优点, 因此在工业质量控制, 自动化故障监控, 经济金融等领域得到了广泛的运用。

假设 $\{X_t\}_{t=1}^n$ 为一段的时间序列观测数据, 则检验其是否存在变点的假设检验如下

$$\begin{aligned} H_0: \{X_t\}_{t=1}^n &\in F(x, \theta_1) \\ H_1: \{X_t\}_{t=1}^{k^*} &\in F(x, \theta_1), (X_t)_{t=k^*+1}^n \in F(x, \theta_2), \theta_1 \neq \theta_2, \end{aligned}$$

其中变点位置 $1 \leq k^* \leq n - 1$ 未知, 累积和方法(CUSUM)的变点检测方法定义如下:

$$T_n(k) = n^{-1/2} \sum_{t=1}^k (X_t - \bar{X}_n),$$

其中 $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$, 则基于累积和方法(CUSUM)的变点检验统计量定义如下:

$$KS_n = \sup_{k=1, \dots, n-1} |T_n(k)|/s_n,$$

其中 $s_n^2 = \sum_{k=1-n}^{n-1} K\left(\frac{k}{l_n}\right) \hat{r}_n(k)$, s_n^2 是一致的长期方差估计量, $K(\cdot)$ 是一个核函数, 常见的核函数有 Bartlett 核, $K(x) = (1 - |x|)1(|x| \leq 1)$, l_n 是带宽参数, l_n 满足 $1/l_n + \frac{l_n}{n} \rightarrow 0$ 当 $n \rightarrow \infty$ 以保证长期方差估计量 s_n^2 的一致性, $\hat{r}_n(k) = n^{-1} \sum_{t=1}^n (X_t - \bar{X}_n)(X_{t-|k|} - \bar{X}_n)$ 是滞后 k 阶的样本自协方差。基于累积和方法(CUSUM)的变点检测就是根据时间序列观测数据计算出相应的 KS_n 值, 比较其与给定显著性水平 α 对应的临界值的大小, 当 $KS_n >$ 临界值, 拒绝原假设, 即观测数据存在变点, 相应的 KS_n 值对应的 x_k 即是变点所在位置, 不同显著性水平 α 对应的临界值如下表所示:

表 1 CUSUM 方法临界值

α	10%	5%	1%
临界值	1.22	1.36	1.63

3.2.2 累积和方法缺陷

累积和(CUSUM)方法简单、易于实现, 所以常常用于变点检测。然而, 累积和(CUSUM)方法存在一些缺陷, Perron (1991), Vogelsang (1999), Deng 和 Perron (2007)等均发现一些累积和(CUSUM)的实验中表现出非单调的能力 (nonmonotonic power), 也就是说, 随着结构变化幅度的增长, 测试的威力实际上会降低。图 3 展示了在显著性水平 $\alpha = 5\%$ 的条件下, 进行 2000 次模拟后, CUSUM 变点检测的能力随着结构变化幅度的增长的变化。我们可以看出, 最开始随着结构变化幅度的增长, CUSUM 方法的变点检测能力逐渐增长, 但是结构变化幅度增长到一定程度后, CUSUM 方法的变点检测能力逐渐削弱直至为零。




图 3 CUSUM 变点检测能力图

注：CUSUM 的实验中表现出非单调的能力即随着结构变化幅度的增长，CUSUM 方法的变点检测能力逐渐增长，当结构变化幅度增加到一定程度时，CUSUM 方法对变点的检测能力不再加强反而削弱直至为零

累积和方法（CUSUM）在进行变点检测时表现出非单调的能力的原因是：在利用累积和方法（CUSUM）检验变点时，需要计算长期方差的一致估计量 s_n^2 ，其中需要涉及到带宽参数 l_n 的选择，通常情况下，带宽参数涉及一致估计，其选择将极大地影响有限样本的性能。查阅相关文献发现，与数据相关的带宽可能导致非单调功率问题，也就是说当样本结构变化程度增加时，检验功率反而降低，理论和实证研究都表明，累积和方法（CUSUM）在变点检测时表现出非单调的能力的是由于与数据相关的带宽，该带宽是在原假设条件下设计的，因此在备择假设下可能会出现严重的偏差，影响检验效能。非单调功率是检验统计量的一个不可取的特征，因此需要采取一些方法来避免出现这一特征。本文采用了 Shao 和 Zhang 在 2010 年提出的一个方法来克服累积和方法(CUSUM)的缺陷，具体方法将在 3.2.3 节做详细阐述。

3.2.3 自归一化方法

Shao 和 Zhang (2010)提出了一个新的检验统计量，它避免了对长期方差 s_n^2 的直接估计，从而避免了对带宽参数 l_n 的选择，因此消除了非单调的问题。其基本思想是将自归一化(Self-Normalization, SN)思想扩展到变点检验问题，因此称其为自归一化(SN)变点检测，自归一化(SN)方法定义如下：

$$T_n(k) = n^{-1/2} \sum_{t=1}^k (X_t - \bar{X}_n),$$

$$V_n(k) = n^{-2} \left[\sum_{t=1}^k \{S_{1,t} - (t/k)S_{1,k}\}^2 + \sum_{t=k+1}^n \left\{ S_{t,n} - \frac{n-t+1}{n-kS_{k+1,n}} \right\}^2 \right],$$

其中 $S_{i,j} = \sum_{t=i}^j X_t$ 当 $i \leq j$ 时, 则基于自归一化 (SN) 方法的变点检验统计量定义如下:

$$KS'_n = \sup_{k=1, \dots, n-1} T_n(k)' V_n^{-1}(k) T_n(k).$$

基于自归一化 (SN) 的变点检测就是根据给定的时间序列观测数据计算出相应的 KS'_n 值, 比较其与给定显著性水平 α 对应的临界值的大小, 当 $KS'_n >$ 临界值, 拒绝原假设, 即观测数据存在变点, Shao 和 Zhang (2010) 通过模拟得出了不同显著性水平 α 对应的临界值, 具体临界值如下表所示:

表 2 SN 方法临界值

α	10%	5%	2.5%	1%	0.5%	0.1%
临界值	29.6	40.1	52.2	68.6	84.6	121.9

自归一化 (SN) 变点检测方法避免了 CUSUM 变点检测中表现出的非单调的能力 (nonmonotonic power), 图 4 展示了在显著性水平 $\alpha = 5\%$ 的条件下, 进行 2000 次模拟后, 自归一化 (SN) 变点检测的能力随着结构变化幅度的增长的变化。我们可以看出, 随着结构变化幅度的增长, 自归一化 (SN) 方法的变点检测能力逐渐增长, 结构变化幅度增长到一定程度后, 自归一化 (SN) 方法的变点检测能力基本保持不变。




图 4 SN 变点检测能力

注：SN 方法的变点检测能力随结构变化幅度的增长逐渐增强

3.3 多变点检测方法

在 3.2 节里，我们介绍了单变点检测方法累积和 (CUSUM) 方法和自归一化 (SN) 方法，实际情况中，一段时间序列可能有多个变点。实际上，多变点问题是单变点问题的一个扩展，因此我们在这一节基于单变点检测方法提出了多变点检测方法。

对于累积和(CUSUM)方法的多变点检测方法，首先根据时间序列观测数据计算累积和(CUSUM)方法的变点检验统计量，比较其与给定显著性水平 α 对应的临界值的大小，若检验统计量大于临界值，则该序列存在变点，并找出变点位置，之后将剩下的数据重复单变点检测，直到找出所有变点。

同理，自归一化(SN)方法的多变点检测方法，也是根据时间序列观测数据计算出相应的变点检验统计量，比较其与给定显著性水平 α 对应的临界值的大小，若检验统计量大于临界值，则该序列存在变点，并找出变点位置，之后将剩下的数据重复单变点检测，直到找出所有变点。

3.4 分块自助法

自助法 (Bootstrap) 最初是由 Efron (1979) 提出的，其基本思想就是简单有放回抽样。如果数据是独立同分布数据，进行足够多的有放回抽样，根据每次 Bootstrap 抽样样本计算相应的统计量。但是实际情况中数据往往不是独立同分布的，因此，需要将 Bootstrap 进行各种延伸和扩展。本文数据是小时数据，数据间具有相依性，Künsch (1989)、Liu 和 Singh (1992) 分别提出了处理相依结构数据的分块自助法 (Block Bootstrap)。其基本思想是：因为数据之间具有相依性，因此不能像独立同分布数据那样在数据内部对单个数据进行抽样，所以在抽样时候我们应该保证某按每“块”(Block) 数据进行抽样。分块自助法 (Block Bootstrap) 的具体步骤如下：

假设有一个长度为 n 的时间序列数据 $(X_1, \dots, X_n)$ ，首先按照样本的原始

顺序划分为 N 个区块，每块数据长度为 l ，划分“块”（Block）时有重叠和非重叠两种划分方式，若为重叠划分方式，则划分为 $B_1 = (X_1, \dots, X_l)$ ， $B_2 = (X_2, \dots, X_{l+1})$ ， $\dots$ ， $B_N = (X_N, \dots, X_n)$ ，其中 $N = n - l + 1$ 。若为非重叠划分方式，则划分为 $B_1 = (X_1, \dots, X_l)$ ， $B_2 = (X_{l+1}, \dots, X_{2l})$ ， $\dots$ ， $B_N = (X_{n-(N-1)l+1}, \dots, X_n)$ ，其中 $n = Nl$ 。因此，抽样样本就由 n 个数据变成 N 个数据块中。然后我们进行有放回抽样，因为每个数据块长度为 l ，因此我们抽取 n/l （假设 n 可以整除 l ）个数据块，我们就得到了样本长度为仍为 n 的重抽样数据，之后我们就可以用独立同分布数据的 Bootstrap 抽样方式计算原始数据的分布、统计量等。在序列长度 n 保持不变的情况下，因为采用有放回的抽样，因此采用非重叠方式划分的数据的某一区块没有抽到的概率较大，重抽样数据有可能不能展示原始数据的所有特征，所以一般我们采用重叠方式划分区块。

4.时空单变点检测

4.1 问题背景

近年来,随着工业化、城镇化的加速,我国的经济得到了迅速发展,但大气环境质量问题也日益突出。我国使用的是当地气象监测站点发布的空气质量数据,来了解当地的空气质量状况。空气质量数据中反应空气污染程度的是空气中的 $PM_{2.5}$ 、 PM_{10} 、 O_3 等污染物浓度数据,由此政府可以根据当地监测的污染情况,制定相应的措施。但是,实际情况中,可能会存在监测仪器故障或者基于一些原因人为修改数据,就会使监测到的污染物浓度数据出现异常,如污染物浓度突然的升高或是降低。监测到的污染物浓度数据出现异常,可能是因为刮风、下雨等气象因素,也有可能是监测仪器故障或者人工修改等人为因素,若是因为人为因素引起的污染物浓度监测数据异常,会影响我们对当地空气质量的判定,因此我们需要实时监测各个站点污染物浓度数据,对异常数据进行判定。实际生活中,这种判定往往是人工完成的,这种判断不但具有主观性,而且效率不高。在以往的研究中,很多学者提出了很多算法,来检测时间序列数据中出现的结构性变化即变点,因此我们可以通过变点检测方法找到污染物监测站点的污染物监测数据出现异常的时间点,但是这些变点中包含因气象因素形成的变点和因人为因素形成的变点,我们需要检测的变点仅是因为人为因素形成的变点,然而经典的变点检测方法无法区分这两种变点,因此本文试图提出一种算法,以以往提出的经典时间序列变点检测方法为基础,利用监测站点相邻站点的数据为辅助,来判定实际情况中因人为因素而形成的变点。在本文中,我们将因为刮风、下雨等气象因素形成的变点称为正常变点,因为监测仪器故障或者人工修改等人为因素形成的变点称为异常变点。

空气污染物浓度监测数据形成的变点有均值变点和方差变点两种情况。均值变点有两种情况：跳跃均值变点和非跳跃均值变点，具体如图 5 所示：




图 5 跳跃均值变点（左图）和非跳跃均值变点（右图）

注：红色线条代表在 $t = k$ 时刻出现均值变点

由图 5 可知，跳跃均值变点的数据在变点之后迅速变化，而非跳跃均值变点的数据在变点之后缓慢变化，在实际情况中，这两种变点都可以利用经典变点检测方法检测到，其中比较常见的是非跳跃均值变点，因为刮风、下雨等气象因素引起的污染物浓度变化，污染物浓度往往是缓慢下降的，但是也不排除有污染物浓度骤降的极端现象。检测到均值变点后，需要判断该均值变点是异常均值变点还是正常均值变点。本文采用了目标站点相邻站点的污染物浓度数据作为参考数据，来判断该均值变点是异常均值变点还是正常均值变点，因为目标站点与相邻站点的空间相近，污染物监测数据表现出空间相关性，因此各个站点因刮风、下雨等气象因素引起的污染物浓度变化往往是同步的，而仪器故障或者人工修改数据等人为因素引起的变点，因为仅有人为因素影响的站点数据发生异常变化，其他站点数据正常，因此各站点因人为因素引起的污染物浓度数据变化不是同步的。本文模拟了正常均值变点（非跳跃）和异常均值变点（非跳跃），具体由下图所示：




图 6 正常均值变点（左图）和异常均值变点（右图）

注：红色线条代表站点 1 在 $t = k'$ 时刻存在异常均值变点，绿色线条表示站点 1 在 $t = k$ 时刻存在正常均值变点

站点 1 为目标监测站点，站点 2、3 是站点 1 的邻近站点，记均值变点发生时刻为 t ，由图 6 可以看出，若为刮风、下雨等气象因素引起的变点，如片区刮风，站点 1 因刮风导致污染物浓度数据在 $t = k$ 时刻发生变化，因为站点 2、3 在空间上与站点 1 临近，所以站点 2、3 的污染物浓度数据与站点 1 数据变化类似，此时站点 1 的变点为正常均值变点，此时站点 1 的污染物监测数据是准确的，无需对站点 1 的污染物监测仪器进行排查。若为仪器故障或者人工修改数据等人为因素引起的变点，站点 1 的污染物浓度数据在 $t = k'$ 时刻发生变化，而与站点 1 相邻的站点 2、3 的污染物浓度数据在 $t = k'$ 时刻前后保持稳定，没有与站点 1 数据发生相似的变化，此时站点 1 的变点为异常均值变点，此时站点 1 的污染物监测数据是存在误差的，需要对站点 1 污染物监测仪器进行排查，查明故障原因，及时修正数据。

空气污染物浓度监测数据形成的变点也有可能是方差变点，与均值变点类似，方差变点也存在因为刮风、下雨等气象因素引起的正常方差变点和因为仪器故障或者人工修改数据等人为因素引起的异常方差变点。具体如下图所示：




图7 正常方差变点（左图）和异常方差变点（右图）

注：红色线条代表站点1在 $t = k'$ 时刻存在异常方差变点，绿色线条表示站点1在 $t = k$ 时刻存在正常方差变点

站点1为目标监测站点，站点2、3是站点1的邻近站点，记方差变点发生时刻为 t ，由图6可以看出，对于因气象因素引起的方差变点，站点1的空气污染物浓度在 $t = k$ 时刻发生变化，空气污染物浓度在 $t = k$ 时刻之后的波动幅度明显增大，因为站点2、3在空间上与站点1相邻，所以三个站点的空气污染物浓度数据保持着很强的相关性，因此站点2、3的空气污染物浓度数据也在 $t = k$ 时刻发生变化，且波动增长幅度基本与站点1一致，此时站点1的变点为正常方差变点，说明此时站点1的污染物监测数据是准确的，无需对站点1的污染物监测仪器进行排查。对于因人为因素引起的方差变点，站点1的空气污染物浓度在 $t = k'$ 时刻发生变化，空气污染物浓度在 $t = k'$ 时刻之后的波动幅度明显增大，而站点2、3的空气污染物数据并未发生同步改变，因此此时站点1的变点为异常方差变点，说明此时站点1的污染物监测数据是存在误差的，需要对站点1污染物监测仪器进行排查，查明故障原因，及时修正数据。

以上提出了借助站点间的空间相关性，来判定目标站点数据异常原因的方法，具体算法将在4.2节进行详细阐述。

4.2 均值单变点算法

本文采用的检测目标站点的变点是否为异常变点的方法是利用相邻站点的反距离加权数据（Inverse Distance Weight, IDW）作为参考数据，来判断目标站点的数据变化的异常与否。例如，假设有 3 个站点，站点 1-3，站点 1 为目标站点，站点 2、3 为站点 1 的相邻站点，我们利用站点 2、3 的反距离加权数据与站点 1 数据进行比较。图 8、图 9 是展示单变点情况下，异常与正常均值变点的情况。由图 8 我们可以看出，站点 1 的数据在变点 $t = k^*$ 前后出现巨大变化，而站点 2、3 的反距离加权数据在变点前后没有出现变化，所以可以认为站点 1 存在异常均值变点。由图 9 我们可以看出，站点 1 的数据在变点 $t = k^*$ 前后出现巨大变化，并且站点 2、3 的反距离加权数据在变点前后也出现巨大变化，所以我们可以认为站点 1 存在正常均值变点。站点 2、3 的反距离加权数据在变点 $t = k^*$ 前后是否和站点 1 一样出现同步变化，可以通过计算站点 1 和站点 2、3 在变点 $t = k^*$ 前后的反距离加权数据的差值来判断，若差值发生巨大变化，则认为站点 1 在 $t = k^*$ 处存在异常均值变点，若差值基本稳定，则认为站点 1 在 $t = k^*$ 处的均值变点是正常变点。因此，可以利用邻近站点的反距离加权数据去判断目标站点的性质。




图 8 异常跳跃均值变点（左图）和异常非跳跃均值变点（右图）

注：红色线条代表站点 1 在 $t = k^*$ 时刻存在异常均值变点




图 9 正常跳跃均值变点（左图）和正常非跳跃均值变点（右图）

注：绿色线条代表站点 1 在 $t = k^*$ 时刻存在正常均值变点

本节提出了基于以上思想的检验单变点异常均值的算法，具体算法如下：

假设一共有 n 个站点 $(X_1, \dots, X_n)$ ，记站点 i 时间长度为 T 的观测数据为 $X_i = (x_{i,1}, x_{i,2}, \dots, x_{i,T})$ ，其中 $x_{i,t}$ 代表站点 i 在 t 时刻的观测值。站点 i 为目标站点，为了检验站点 i 是否存在异常均值变点，我们做出以下假设：

H_0 : 该站点不存在异常均值变点

H_1 : 该站点存在一个异常均值变点

第 1 步我们根据自归一化方法(SN)求出该站点的均值变点位置。假设站点 i 在 $t = k^*$ 处存在变点，其他站点不存在异常变点，假设站点 i 周围一共存在 K 个站点。

第 2 步计算站点 i 周围 K 个站点在 t 时刻的反距离加权平均和为：

$$\hat{x}_{i,t} = \sum_{j \neq i} x_{j,t} * w_j, \quad (1)$$

其中 w_j ， $w_j > 0$ 且 $\sum_j w_j = 1$ 为反距离加权的权重，反距离加权的权重是由站点之间的空间距离决定的，距离越近，相关性越强，权重也越大，相反，权重越小，相关性越弱。则站点 j 的相对于站点 i 的权重 w_j 与站点 j 到站点 i 的距离成反比，即：

$$w_j = \frac{\frac{1}{d_{ij}}}{\sum_{k \neq i} \frac{1}{d_{ik}}}, \quad (2)$$

其中， d_{ij} 表示站点 i 到站点 j 的距离， $\hat{x}_{i,t}$ 表示站点 i 周围站点在 t 时刻对站点 i 的反距离加权数据，可以用其与站点 i 在 t 时刻的观测值 $x_{i,t}$ 的差值来判断站点 i 与

周围站点数据是否出现同步变化。

第 3 步我们计算实际观测值 x_{it} 与反距离加权数据 $\hat{x}_{it}$ 的差值:

$$\Delta x_{it} = x_{it} - \hat{x}_{it}. \quad (3)$$

若站点 i 不存在异常均值变点, 则差值 Δx_{it} 在变点 $t = k^*$ 前后基本没有变化, 若站点 i 存在一个异常均值变点, 则差值 Δx_{it} 在变点 $t = k^*$ 前后出现巨大变化(具体可见图 8、图 9)。

记站点 i 在变点 $t = k^*$ 前后的数据为:

$$\begin{cases} \alpha_t = x_{it} - \hat{x}_{it}, & 1 \leq t \leq k^* \\ \beta_t = x_{it+k^*-1} - \hat{x}_{it+k^*-1}, & 1 \leq t \leq T - k^* + 1 \end{cases} \quad (4)$$

由于此算法是检测目标站点的均值变点是否为异常变点, 所以分别计算变点前后数据 α_t 、 β_t 的均值:

$$\begin{cases} u_1 = \bar{\alpha}_t \\ u_2 = \bar{\beta}_t \end{cases} \quad (6)$$

取前后数据的均值的差值 $\Delta u = u_1 - u_2$ 作为统计量, 若 Δu 较大, 即:

$$\Delta u \gg 0,$$

则可以认为存在异常均值变点。

第 4 步进行假设检验, 假设检验需要假设原假设 H_0 成立, 即该站点不存在异常均值变点, 但是 $t = k^*$ 之后的数据可能存在异常, 即存在异常均值变点, 所以我们需要对 $t = k^*$ 之后的数据进行处理, 使其满足原假设。具体处理方式如下:

记 $\Delta = \bar{\alpha}_t - \bar{\beta}_t$, 对 β_t 做变化:

$$\beta_t^* = \beta_t + \Delta. \quad (8)$$

数据处理后 α_t 、 β_t^* 满足原假设 H_0 下的分布。当 H_0 成立时, Δ 约等于 0, 此时 β_t^* 基本不变, 不会影响数据的分布。由于数据是小时数据, 在时间上具有相依性, 所以采用处理相依序列的分块自助法(Block Bootstrap)进行抽样, 每次抽样数据块长度为 l , 重复 M 次, 记第 m 次得到的分布 $\alpha_t^{(m)}$ 和 $\beta_t^{*(m)}$, 之后对 $\alpha_t^{(m)}$ 和 $\beta_t^{*(m)}$ 分别计算均值 $u_1^{(m)}, u_2^{(m)}$, 最后计算 $\Delta u^{(m)} = u_1^{(m)} - u_2^{(m)}$ 。给定假设检验的置信水平为 α , 记经过 M 次有放回分块自助法(Block Bootstrap)抽样得到的统计量 $\{\Delta u^{(m)}\}$ 的上 $([\alpha/2])$ 和下 $([1 - \alpha/2])$ 分位点数据为 $\Delta u^{[\alpha/2]}$ 和 $\Delta u^{[1-\alpha/2]}$ 。如果 $\Delta u \leq \Delta u^{[\alpha/2]}$ 或者 $\Delta u \geq \Delta u^{[1-\alpha/2]}$, 则拒绝原假设 H_0 ,

即该站点存在一个异常均值变点。通过此算法我们可以对时空数据的异常均值变点进行检测，所以我们将这个算法取名为 STMSN(基于 SN 方法的时空数据异常均值变点检测)，STMSN 算法流程图如下图所示：

Algorithm STMSN 算法

Input: 给定 $X_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,T}\}, i = 1, 2, \dots, n$, Block Bootstrap 块长为: K , 假设检验置信水平为 α , 站点 i, j 之间距离为: $d_{i,j}$

Result: 输出 1, 拒绝 H_0 , 输出 0, 接受 H_0

利用 SN 方法估计站点 X_i 的均值单变点时间, $t = k^*$

计算 $w_j = \frac{\frac{1}{d_{i,j}}}{\sum_{l \neq i} \frac{1}{d_{i,l}}}, \widehat{x}_{i,t} = \sum_{j \neq i} x_{j,t} * w_j$

$\alpha_t = (x_{i,1} - \widehat{x}_{i,t}, \dots, x_{i,k^*-1} - \widehat{x}_{i,k^*-1})$

$\beta_t = (x_{i,k^*} - \widehat{x}_{i,k^*}, \dots, x_{i,T} - \widehat{x}_{i,T})$

for $l \leftarrow 0$ **to** M **do**

if $l = 0$ **then**

 计算 $u_1 = \text{mean}(\alpha_t), u_2 = \text{mean}(\beta_t)$,

$\Delta u = u_1 - u_2$,

$\Delta = \text{mean}(\alpha_t) - \text{mean}(\beta_t)$,

$\beta_t = \beta_t + \Delta$

else

 对 α_t, β_t 做块长度为 k 的 Block Bootstrap 抽样, 得到

 样本 $\alpha_t^{(m)}, \beta_t^{(m)}$

 计算 $u_1^{(m)} = \text{mean}(\alpha_t^{(m)}), u_2^{(m)} = \text{mean}(\beta_t^{(m)})$,

$\Delta u^{(m)} = u_1^{(m)} - u_2^{(m)}$

end if

end for

将 $\Delta u^{(1)}, \dots, \Delta u^{(M)}$ 升序排列得到 $\Delta u^{*(1)}, \dots, \Delta u^{*(M)}$

if $\Delta u < \Delta u^{*(\alpha/2)} \vee \Delta u > \Delta u^{*(1-(\alpha/2))}$ **then**

 返回 1

else

 返回 0

end if

图 10 STMSN 算法流程图

STMSN 是基于均值构建的统计量来判断均值单变点的异常状况。实际情况中, 统计量的构建我们还可以采取分位数来构建统计量, 分位数, 又叫做分位点, 是以概率将一批数据进行分割的数值点。常见的分位数有二分位数即中位数、四分位数和百分位数。记 $x^{(q)}$ 为样本的 q 分位数, 则:

$$x^{(q)} = \begin{cases} x^{(\lfloor nq \rfloor + 1)} & , nq \text{ 不为整数} \\ \frac{[x^{(nq)} + x^{(nq+1)}]}{2} & , nq \text{ 为整数} \end{cases},$$

其中 $x^{1/2}$ 为二分位数即中位数, $x^{1/4}$ 为第一四分位数。基于分位数构建的具

体算法与 STMSN 类似，只需要对统计量的构建进行修改，对公式 (6)、(7) 进行修改，分别计算变点前后数据 α_t 、 β_t 的 q 分位数：

$$\begin{cases} Q_1 = (\alpha_t)^{(q)} & (9) \\ Q_2 = (\beta_t)^{(q)} & (10) \end{cases}$$

取变点前后分位数数据的差值 $\Delta Q = Q_1 - Q_2$ 作为统计量。因为此算法是在 STMSN 的基础上，通过修改统计量的构建方式实现的，所以我们将这个算法取名为 STMSN-分位数。STMSN-分位数算法流程图如下图所示：

Algorithm STMSN-分位数算法

Input: 给定 $X_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,T}\}, i = 1, 2, \dots, n$, Block Bootstrap 块长为: K , 假设检验置信水平为 α , 站点 i, j 之间距离为: $d_{i,j}$

Result: 输出 1, 拒绝 H_0 , 输出 0, 接受 H_0

利用 SN 方法估计站点 X_i 的均值单变点时间, $t = k^*$

计算 $w_j = \frac{1}{\sum_{l \neq i} d_{i,j}}$, $\widehat{x}_{i,t} = \sum_{j \neq i} x_{j,t} * w_j$

$\alpha_t = (x_{i,1} - \widehat{x}_{i,t}, \dots, x_{i,k^*-1} - \widehat{x}_{i,k^*-1})$

$\beta_t = (x_{i,k^*} - \widehat{x}_{i,k^*}, \dots, x_{i,T} - \widehat{x}_{i,T})$

for $l \leftarrow 0$ **to** M **do**

if $l = 0$ **then**

 计算 $Q_1 = (\alpha_t)^{(q)}, Q_2 = (\beta_t)^{(q)}$,

$\Delta Q = Q_1 - Q_2$,

$\Delta = (\alpha_t)^{(q)} - (\beta_t)^{(q)}$,

$\beta_t = \beta_t + \Delta$

else

 对 α_t, β_t 做块长度为 k 的 Block Bootstrap 抽样, 得到样本 $\alpha_t^{(m)}, \beta_t^{(m)}$

 计算 $Q_1^{(m)} = (\alpha_t^{(m)})^{(q)}, Q_2^{(m)} = (\beta_t^{(m)})^{(q)}$,

$\Delta Q^{(m)} = Q_1^{(m)} - Q_2^{(m)}$

end if

end for

将 $\Delta Q^{(1)}, \dots, \Delta Q^{(M)}$ 升序排列得到 $\Delta Q^{*(1)}, \dots, \Delta Q^{*(M)}$

if $\Delta Q < \Delta Q^{*(\alpha/2)} \vee \Delta Q > \Delta Q^{*(1-(\alpha/2))}$ **then**

 返回 1

else

 返回 0

end if

图 11 STMSN-分位数算法流程图

STMSN、STMSN-分位数基于自归一化(SN)方法来估计站点的变点，因为自归一化(SN)方法是为了克服使用累积和(CUSUM)方法进行变点检测时出现的非单调问题，因此本文还基于相似方法构建了基于累积和(CUSUM)方法

的时空数据异常均值变点检测，取名为 STMC、STMC-分位数，用来与本文提出的基于自归一化(SN)方法提出的 STMSN、STMSN-分位数算法进行比较。

4.3 方差单变点算法

异常方差单变点方法与异常均值单变点方法类似，也是利用相邻站点的反距离加权数据为参考，来判断目标站点的数据变化的异常与否。例如，假如有 3 个站点，记为站点 1-3，其中站点 1 为目标站点，站点 2、3 为站点 1 的相邻站点，我们利用站点 2、3 加权数据与站点 1 数据进行比较。由图 12 所示，若站点 1 数据在变点 $t = k^*$ 前后的变化幅度与站点 2、3 加权数据在变点前后的方差变化幅度不同，则站点 1 在 $t = k^*$ 处存在异常方差变点。由图 13 所示，若站点 1 数据在变点 $t = k^*$ 前后的变化幅度与站点 2、3 加权数据在变点前后的方差变化幅度基本相同，则站点 1 在 $t = k^*$ 处存在正常方差变点。变点前后的变化幅度是否相同，可以通过计算站点 1 与站点 2、3 加权数据在变点 $t = k^*$ 前后的方差变化的差值来判断，若差值不为零，则站点 1 在 $t = k^*$ 处存在异常变点，若差值约等于零，则站点 1 在 $t = k^*$ 处存在正常变点。




图 12 异常方差变点

注：红色线条代表站点 1 在 $t = k^*$ 时刻存在异常方差变点




图 13 正常方差变点

注：绿色线条代表站点 1 在 $t = k^*$ 时刻存在正常方差变点

假设一共有 n 个站点 $(X_1, \dots, X_n)$ ，记站点 i 时间长度为 T 的观测数据为 $X_i = (x_{i1}, x_{i2}, \dots, x_{iT})$ ，其中 x_{it} 代表站点 i 在 t 时刻的观测值。为了检测站点 i 是否存在异常方差变点，我们做出以下假设：

H_0 : 该站点不存在异常方差变点

H_1 : 该站点存在一个异常方差变点

假设站点 i 在 $t = k^*$ 处存在方差变点，站点 i 周围 K 个站点均不存在方差变点。记 $\sigma_{k,1}^2, \sigma_{k,2}^2$ 分别为站点 k 在变点 $t = k^*$ 前后的方差，则 $\Delta\sigma_k^2 = \sigma_{k,1}^2 - \sigma_{k,2}^2, 1 \leq k \leq K$ 为站点 k 在变点 $t = k^*$ 前后的方差差值。计算站点 i 周围 K 个站点在变点前后方差差值的反距离加权平均和为：

$$\Delta\hat{\sigma}_i^2 = \sum_{j \neq i} \Delta\sigma_j^2 * w_j,$$

其中 $w_j, w_j > 0$ 且 $\sum_j w_j = 1$ 为反距离加权的权重，权重 w_j 的计算方式如下：

$$w_j = \frac{\frac{1}{d_{ij}}}{\sum_{k \neq i} \frac{1}{d_{ik}}},$$

其中 d_{ij} 表示站点 i 到站点 j 的距离。

欲判断站点 i 是否存在异常方差变点，需要判断站点 i 数据与相邻站点数据在变点前后是否发生同步变化，因此计算站点 i 在变点 $t = k^*$ 前后的方差差值 $\Delta\sigma_i^2$ 与站点 i 周围 K 个站点在变点前后方差差值的反距离加权平均和 $\Delta\hat{\sigma}_i^2$ 的差值 $\Delta\sigma^2$ ：

$$\Delta\sigma^2 = \Delta\sigma_i^2 - \Delta\hat{\sigma}_i^2$$

$$\begin{aligned}
&= (\sigma_{i,1}^2 - \sigma_{i,2}^2) - \sum_{i \neq j} (\sigma_{j,1}^2 - \sigma_{j,2}^2) * w_j \\
&= (\sigma_{i,1}^2 - \sum_{i \neq j} \sigma_{j,1}^2 * w_j) - \left(\sigma_{i,2}^2 - \sum_{i \neq j} \sigma_{j,2}^2 * w_j \right) \\
&= \Delta_1^2 - \Delta_2^2.
\end{aligned} \tag{11}$$

若 H_0 为真, 即该站点不存在异常方差变点, 那么站点 i 在变点前后的方差变化幅度与站点 i 相邻站点在变点前后的方差变化幅度基本相同, 即 $\Delta\sigma^2 = \Delta_1^2 - \Delta_2^2 \cong 0$ 。若 H_0 为假, 即该站点存在异常方差变点, 那么站点 i 在变点前后的方差变化幅度与站点 i 相邻站点在变点前后的方差变化幅度不一致, 即 $\Delta\sigma^2 = \Delta_1^2 - \Delta_2^2 \gg 0$ 。因此可以用 Δ_1^2 与 Δ_2^2 的差值 $\Delta\sigma^2$ 作为异常方差单变点的检测统计量, 其中 $\sigma_{i,1}^2$ 与 $\sigma_{i,2}^2$ 可以用样本方差估计值 $\hat{\sigma}_{i,1}^2$ 与 $\hat{\sigma}_{i,2}^2$ 代替。

为计算方便, 对样本数据做如下变换:

$$x_{i,t}^* = \begin{cases} (x_{i,t} - \hat{u}_{i,1})^2, & t < k^* \\ (x_{i,t} - \hat{u}_{i,2})^2, & t \geq k^* \end{cases} \tag{12}$$

其中 $\hat{u}_{i,1} = \frac{\sum_{t=1}^{k^*-1} x_{i,t}}{k^*-1}$, $\hat{u}_{i,2} = \frac{\sum_{t=k^*}^T x_{i,t}}{T-k^*+1}$, $1 \leq i \leq K$ 分别为站点数据 $x_{i,t}$ 在变点 $t = k^*$ 前后的样本均值。计算站点 i 在变点 $t = k^*$ 前后的样本方差为:

$$\hat{\sigma}_{i,1}^2 = \frac{\sum_{t=1}^{k^*-1} (x_{i,t} - \hat{u}_{i,1})^2}{k^*-2} = \frac{k^*-1}{k^*-2} * \frac{\sum_{t=1}^{k^*-1} x_{i,t}^*}{k^*-1} = \frac{k^*-1}{k^*-2} * u_{i,1}^*, \tag{14}$$

$$\hat{\sigma}_{i,2}^2 = \frac{\sum_{t=k^*}^T (x_{i,t} - \hat{u}_{i,2})^2}{T-k^*} = \frac{T-k^*+1}{T-k^*} * \frac{\sum_{t=k^*}^T x_{i,t}^*}{T-k^*+1} = \frac{T-k^*+1}{T-k^*} * u_{i,2}^*, \tag{15}$$

其中 $u_{i,1}^* = \frac{\sum_{t=1}^{k^*-1} x_{i,t}^*}{k^*-1}$, $u_{i,2}^* = \frac{\sum_{t=k^*}^T x_{i,t}^*}{T-k^*+1}$, $1 \leq i \leq K$ 分别为站点变换数据 $x_{i,t}^*$ 在变点前后的样本均值, 可以看出样本方差 $\hat{\sigma}_{i,1}^2$ 、 $\hat{\sigma}_{i,2}^2$ 与变化后的样本均值 $u_{i,1}^*$ 、 $u_{i,2}^*$ 仅相差一个常数倍数 $\frac{k^*-1}{k^*-2}$ 、 $\frac{T-k^*+1}{T-k^*}$, 因此我们可以将检验异常均值变点的算法做变换来检测异常方差变点。因此我们将 STMSN 算法做变换, 得到时空数据异常方差变点的检验算法, 具体算法如下:

第 1 步我们根据自归一化(SN)方法求出该站点的方差变点位置。假设站点 i 在 $t = k^*$ 处存在变点, 其他站点不存在异常变点, 假设站点 i 周围一共存在 K 个站点。

第 2 步计算站点 i 周围 K 个站点变换数据 $x_{i,t}^*$ 的反距离加权平均和:

$$\hat{x}_{i,t}^* = \sum_{j \neq i} x_{j,t}^* * w_j.$$

第 3 步计算 $x_{i,t}^*$ 与 $\hat{x}_{i,t}^*$ 的差值:

$$\Delta x_{i,t} = x_{i,t}^* - \hat{x}_{i,t}^*.$$

记 $\Delta x_{i,t}$ 在变点 $t = k^*$ 前后的数据分别为 α_t 、 β_t 。

$$\begin{cases} \alpha_t = x_{i,t}^* - \hat{x}_{i,t}^*, & 1 \leq t \leq k^* \\ \beta_t = x_{i,t+k^*-1}^* - \hat{x}_{i,t+k^*-1}^*, & 1 \leq t \leq T - k^* + 1 \end{cases}$$

再分别计算变点前后数据 α_t 、 β_t 的均值:

$$\begin{cases} u_\alpha = \frac{\sum_{t=1}^{k^*} \alpha_t}{k^* - 1} \\ u_\beta = \frac{\sum_{t=k^*}^T \beta_t}{T - k^* + 1} \end{cases}.$$

计算 $\frac{k^*-1}{k^*-2} * u_\alpha$ 与 $\frac{T-k^*+1}{T-k^*} * u_\beta$ 的差值作为检验统计量 $\Delta\sigma^2$:

$$\begin{aligned} \Delta\sigma^2 &= \frac{k^* - 1}{k^* - 2} * u_\alpha - \frac{T - k^* + 1}{T - k^*} * u_\beta \\ &= \frac{k^* - 1}{k^* - 2} * \frac{\sum_{t=1}^{k^*} \alpha_t}{k^* - 1} - \frac{T - k^* + 1}{T - k^*} * \frac{\sum_{t=k^*}^T \beta_t}{T - k^* + 1} \\ &= \frac{k^* - 1}{k^* - 2} * \left(\mu_{i,1}^* - \sum_{j \neq i} \mu_{j,1}^* * w_j \right) - \frac{T - k^* + 1}{T - k^*} * \left(\mu_{i,2}^* - \sum_{j \neq i} \mu_{j,2}^* * w_j \right) \\ &= (\sigma_{i,1}^2 - \sum_{j \neq i} \sigma_{j,1}^2 * w_j) - (\sigma_{i,2}^2 - \sum_{j \neq i} \sigma_{j,2}^2 * w_j). \end{aligned} \quad (16)$$

第 4 步进行假设检验。检验站点 i 是否存在异常方差变点，只需要判断检验统计量 $\Delta\sigma^2$ 是否为 0，若 $\Delta\sigma^2$ 约等于零，则站点 i 不存在异常方差变点，反之则站点 i 存在异常方差变点。与 STMSN 类似，因为假设检验需要假设原假设 H_0 成立，所以我们依然要对变点 $t = k^*$ 后的数据做变换，具体变化如下:

$$\beta_t^* = \beta_t + \frac{T-k^*+1}{T-k^*} * \Delta\sigma^2. \quad (17)$$

然后对 α_t 和 β_t^* 使用块长度为 l ，抽样次数为 M 的分块自助法 (Block Bootstrap) 抽样得到 α_t 和 β_t^* 的分布，记第 m 次抽样得到的分布为 $\tilde{\alpha}_t^{(m)}$ 和 $\tilde{\beta}_t^{*(m)}$ ，则:

$$(\Delta\sigma^2)^{(m)} = \frac{k^*-1}{k^*-2} * \frac{\sum_{t=1}^{k^*} \tilde{\alpha}_t^{(m)}}{k^*-1} - \frac{T-k^*+1}{T-k^*} * \frac{\sum_{t=k^*}^T \tilde{\beta}_t^{*(m)}}{T-k^*+1}. \quad (18)$$

根据 M 次分块自助法 (Block Bootstrap) 抽样得到检验统计量 $\{(\Delta\sigma^2)^{(m)}\}$,

记其上 ($\lfloor \alpha/2 \rfloor$) 和下 ($\lfloor 1-\alpha/2 \rfloor$) 分位点数据为 $(\Delta\sigma^2)^{\lfloor \alpha/2 \rfloor}$ 和 $(\Delta\sigma^2)^{\lfloor 1-\alpha/2 \rfloor}$ 。如果 $\Delta\sigma^2 \leq (\Delta\sigma^2)^{\lfloor \alpha/2 \rfloor}$ 或者 $\Delta\sigma^2 \geq (\Delta\sigma^2)^{\lfloor 1-\alpha/2 \rfloor}$, 则拒绝原假设 H_0 , 即该站点存在一个异常均值变点。通过此算法我们可以对时空数据的异常方差变点进行检测, 所以我们将这个算法取名为 STVSN(基于 SN 方法的时空数据异常方差变点检测), STVSN 算法流程图如下图所示:

Algorithm STVSN 算法

Input: 给定 $X_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,T}\}, i = 1, 2, \dots, n$, Block Bootstrap 块长为: K , 假设检验置信水平为 α , 站点 i, j 之间距离为: $d_{i,j}$

Result: 输出 1, 拒绝 H_0 , 输出 0, 接受 H_0

利用 SN 方法估计站点 X_i 的方差单变点时间, $t = k^*$

计算 $x_{i,t}^* = (x_{i,t} - \text{mean}(x_{i,j}|j < k^*) * I(t < \widehat{k^*}) - \text{mean}(x_{i,j}|j \geq k^*) * I(t \geq \widehat{k^*})) * w_j$

$w_j = \frac{\frac{1}{d_{i,j}}}{\sum_{l \neq i} \frac{1}{d_{i,l}}}, \widehat{x}_{i,t}^* = \sum_{j \neq i} x_{j,t}^* * w_j$

$\alpha_t = (x_{i,1}^* - \widehat{x}_{i,t}^*, \dots, x_{i,k^*-1}^* - \widehat{x}_{i,k^*-1}^*)$

$\beta_t = (x_{i,k^*}^* - \widehat{x}_{i,k^*}^*, \dots, x_{i,T}^* - \widehat{x}_{i,T}^*)$

for $l \leftarrow 0$ **to** M **do**

if $l = 0$ **then**

 计算 $\sigma_1 = \text{mean}(\alpha_t), \sigma_2 = \text{mean}(\beta_t)$,

$\Delta\sigma = \frac{k^*-1}{k^*-2}\sigma_1 - \frac{T-k^*+1}{T-k^*}\sigma_2$,

$\beta_t = \beta_t + \frac{T-k^*+1}{T-k^*}\Delta\sigma$

else

 对 α_t, β_t 做块长度为 k 的 Block Bootstrap 抽样, 得到

 样本 $\alpha_t^{(m)}, \beta_t^{(m)}$

 计算 $\sigma_1^{(m)} = \text{mean}(\alpha_t^{(m)}), \sigma_2^{(m)} = \text{mean}(\beta_t^{(m)})$,

$\Delta\sigma^{(m)} = \sigma_1^{(m)} - \sigma_2^{(m)}$

end if

end for

将 $\Delta\sigma^{(1)}, \dots, \Delta\sigma^{(M)}$ 升序排列得到 $\Delta\sigma^{*(1)}, \dots, \Delta\sigma^{*(M)}$

if $\Delta\sigma < \Delta\sigma^{*(\alpha/2)} \vee \Delta\sigma > \Delta\sigma^{*(1-(\alpha/2))}$ **then**

 返回 1

else

 返回 0

end if

图 14 STVSN 算法流程图

与异常均值检测方法类似, 本文还考虑了基于累积和(CUSUM)方法的时空数据异常方差变点检测, 取名为 STVC, 与基于自归一化(SN)方法提出的 STVSN 算法进行比较。

5. 时空多变点检测

在第 4 节里，我们讨论了时空数据单变点的检测方法，实际情况中，一个站点可能同时受到多种因素的影响，变点数不等于 1，所以我们在第 4 节的基础上做出扩展，提出了时空数据多变点的检测方法。

5.1 均值多变点算法

与检验单变点是否为异常变点类似，检验多个变点是否为异常变点的方法是也是利用相邻站点的反距离加权数据为参考，来判断目标站点的数据变化的异常与否。图 15、图 16 展示双变点情况下，异常与正常均值多变点的情况。由图 15 我们可以看出，站点 1 存在两个变点，并且其数据在变点前后出现巨大变化，而站点 2、3 的反距离加权数据并没有发生较大改变，所以站点 1 的两个变点均为异常均值变点，由图 16 我们可以看出，在变点前后，站点 1 数据和站点 2、3 加权数据发生同步变化，所以站点 1 的两个变点均为正常均值变点。因为多变点问题是单变点问题的一个扩展，我们可以通过划分数据将多变点问题变为单变点问题，因此我们也可以通过划分数据，将异常均值多变点问题转换为异常均值单变点问题，并采用第 4 节提出的异常均值单变点算法来判断变点是否为异常变点。




图 15 异常跳跃均值多变点（左图）和异常非跳跃均值（右图）




图 16 正常跳跃均值多变点（左图）和正常非跳跃均值多变点（右图）

基于以上思路，本文提出了检测时空数据异常均值多变点算法，具体算法如下：

假设一共有 n 个站点 $(X_1, \dots, X_n)$ ，站点 i 时间长度为 T 的观测数据记为 $X_i = (x_{i,1}, x_{i,2}, \dots, x_{i,T})$ ，其中 $x_{i,t}$ 代表站点 i 在 t 时刻的观测值。

第 1 步我们根据自归一化 (SN) 方法求出该站点的所有均值变点位置。假设站点 i 一共有 N ($N > 1$) 个变点，变点位置由小到大分别为 $k^1, k^2, \dots, k^N$ ， $1 < k^1 < \dots < k^N < T$ ，其中 $k^0 = 0$ ， $k^{N+1} = T$ 。

第 2 步我们根据变点位置划分 n 个站点的数据，站点 i 观测数据 $X_i = (x_{i,1}, x_{i,2}, \dots, x_{i,T})$ 划分为 $N + 1$ 段数据 $(x_{i,1}, \dots, x_{i,k^1})$ 、 $\dots$ 、 $(x_{i,k^N}, \dots, x_{i,k^{N+1}})$ 。多变点问题就转换成单变点问题。每一段数据只存在一个变点，因此我们可以

采用第4节提出的异常均值单变点算法，分别检测每一段数据的变点是否为异常变点。时空数据异常均值多变点检测算法流程图具体如下图所示：




图 17 异常均值多变点检测算法流程图

5.2 方差多变点算法

检验多个变点是否为异常方差变点的方法也是利用相邻站点的反距离加权数据为参考，来判断目标站点的数据变化的异常与否。图 17 展示双变点情况下，异常方差变点与正常方差变点的情况。由图 17 可以看出，异常方差变点的数据在变点前后的方差变化幅度与相邻站点 2、3 加权数据在变点前后的方差变化幅度不同，而正常方差变点的数据和相邻站点 2、3 加权数据在变点前后的方差变化幅度相同。在解决异常均值多变点问题时，我们采用了划分数据将多变点问题转换为单变点问题，因此在解决异常方差多变点问题时，我们也可以采用划分数据将异常方差多变点问题转换为异常方差单变点问题。




图 18 异常方差多变点

正常方差多变点




图 19 正常方差多变点

与异常均值多变点算法类似，异常方差多变点算法也是先根据自归一化 (SN)方法求出该站点的所有方差变点位置，再根据变点位置划分站点数据，最后采用异常方差单变点算法检测每一段数据的变点是否为异常变点。时空数据异常方差多变点检测算法流程图具体如下图所示：




图 20 异常方差多变点算法流程图

6.数值模拟

第5章中,我们提出了基于自归一化(SN)方法的变点检测算法,用以检测时空数据中的变点。因为自归一化(SN)方法是为了克服使用累积和(CUSUM)方法进行变点检测时出现的非单调问题,因此本文还基于相似方法构建了基于累积和(CUSUM)方法的变点检测算法,为了检验本文提出算法的有效性以及相较于累积和(CUSUM)算法的优越性,在本节中,我们分别模拟了均值变点和方差变点,来检验我们提出的检验异常变点算法的正确率。

假设一共存在5个站点,以站点1作为目标监测站点,其余4个站点到站点1的距离一致,因此辅助站点的反距离加权重为 $\omega_j = \frac{1}{4}$, $j = 1, 2, 3, 4$ 。

6.1 单变点模拟

当变点数量 $K = 1$ 时,为单变点问题。首先模拟均值单变点,本文均值变点模拟考虑了正常跳跃均值变点、异常跳跃均值变点、正常非跳跃均值变点和异常非跳跃均值变点四种情况。分别在四种情况下生成模拟数据,检验本文提出的均值单变点算法的有效性。因为本文提出的均值单变点算法是基于SN方法(CUSUM)提出的,SN方法(CUSUM)能检验是否存在变点,并不能检验变点是否异常,因此本文假设SN方法(CUSUM)检验发现的所有变点都为异常变点。并且为了验证均值单变点方法在不同均值变化幅度下的有效性,我们引入了参数 $\Delta\mu$ 来代表均值变化幅度,对每一个 $\Delta\mu$ 进行了1000次模拟,检验在不同均值变化幅度下的均值单变点方法的有效性。并且给定累积和(CUSUM)方法、自归一化(SN)方法的检验显著性水平为5%,给定STMC方法、STMC-分位数方法、STMSN方法、STMSN-分位数方法中分块自助法(Block Bootstrap)抽样时每个数据块长度为 $l=2$,抽取 $M=700$ 次,抽

样显著性水平为 5%。

6.1.1 正常均值单变点

每个站点模拟 100 个数据，假设在 $t = 51$ 处出现变点，对于正常跳跃均值变点，模拟方式如下：站点 1-5 的前 50 个数据分别由正态分布 $N(50,1)$ ， $N(47,1)$ ， $N(46,1)$ ， $N(53,1)$ ， $N(51,1)$ 生成，后 50 个数据分别由正态分布 $N(50+\Delta u,1)$ ， $N(47+\Delta u,1)$ ， $N(46+\Delta u,1)$ ， $N(53+\Delta u,1)$ ， $N(51+\Delta u,1)$ 生成。对于正常跳跃均值变点，模拟方式如下：站点 1-5 的前 50 个数据分别由正态分布 $N(50,1)$ ， $N(47,1)$ ， $N(46,1)$ ， $N(53,1)$ ， $N(51,1)$ 生成，记 x_{ij} 为站点 i 第 j 个数据，站点 1-5 的后 50 个数据 $x_{ij} = \frac{u_i + \Delta u}{1 + \exp(-l_j)} + \varepsilon_{ij}$ ， $i = 1, 2, \dots, 5$ ， $j = 1, 2, \dots, 10$ ，其中 u_i 为站点 i 在变点出现前的均值， $l_j = 0.5 * j - 2.5$ ， $\varepsilon \sim N(0, 1.5)$ 为随机白噪声序列， Δu 为均值变化幅度，为了检验在不同均值变化幅度下算法的有效性，我们设置 $\Delta u = -10, -9, \dots, 9, 10$ 。为了便于展示，只展示 3 个站点的数据（下同）。模拟数据由下图所示：




图 21 正常跳跃均值单变点模拟数据（左图）和正常非跳跃均值单变点模拟数据（右图）

本文利用准确率来表示不同均值变化幅度下算法的有效性，检验准确率的计算如下所示：

$$\text{Accuracy} = \frac{N}{K},$$

其中 N 代表检验出正常均值变点的次数， K 代表模拟次数（1000 次）。

本文提出了基于均值构建的检验统计量对时空数据的异常均值变点进行检测的算法 STMSN 和 STMC，模拟好正常均值单变点数据后，分别比较 STMSN、STMC、SN 和 CUSUM 算法的检验准确率如下图所示：




图 22 STMSN、STMC、SN 和 CUSUM 算法对正常跳跃均值变点数据的检验准确率

注：STMSN 代表基于本文提出的自归一化方法的时空变点检测算法，STMC 代表基于累计和方法的时空变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法




图 23 STMSN、STMC、SN 和 CUSUM 算法对正常非跳跃均值变点数据的检验准确率

注：STMSN 代表基于本文提出的自归一化方法的时空均值变点检测算法，STMC 代表基于累计和方法的时空均值变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法

由图 22、图 23 我们可以看出，不管是正常跳跃均值变点还是正常非跳跃均值变点，SN、CUSUM 方法的检验准确率均为零，这是因为本文假设

SN、CUSUM 方法的检验的所有变点都为异常变点，实际上本节模拟的变点均是由于刮风、下雨等自然因素导致的正常变点。基于 SN 方法的时空数据异常均值变点检测算法（STMSN）和基于 CUSUM 方法的时空数据异常均值变点检测算法（STMC）均能有效检验该变点是否为异常变点，其中 STMSN 算法的检验正确率在 76%-90% 之间，基本保持稳定，而 STMC 算法的检验正确率在均值变化幅度较小即 $\Delta u \in [-3, 3]$ 之间保持在 81%-88% 之间，与 STMSN 算法基本一致，但是随着均值变化幅度的增加，STMC 算法的检验正确率逐渐下降直至为零，这是因为使用 CUSUM 方法进行变点检测时会表现出非单调的能力（nonmonotonic power），即随着均值变化幅度的增长，检测到变点的能力会降低，因为本文提出的算法前提是能检测到变点，所以 STMC 算法也表现出非单调的能力。对于 STMSN 算法和 STMC 算法，随着均值变化幅度的减小，两种算法的检验正确率呈现一个下降趋势，在均值变化幅度 $|\Delta u| = 1$ 时下降趋势更加明显这是因为均值变化幅度较小，SN 方法和 CUSUM 方法容易检测不到变点。并且不管是 STMSN 算法还是 STMC 算法，模拟正常跳跃均值变点的准确率均比正常非跳跃均值变点的准确率高，这是因为正常跳跃均值数据变化较大，而非跳跃均值数据存在过渡数据，使用自助法进行抽样时可能会抽到较多过渡数据，使得构建的统计量出现偏差。

本文还提出了基于分位数构建的检验统计量对时空数据的异常均值变点进行检测的算法 STMSN-分位数和 STMC-分位数，以下展示了基于二分位数即中位数构建的统计量来判断均值单变点的异常状况，中位数和均值一样，都可以反应数据的变化，当数据量足够大时，分布的中位数与均值相似。如果数据是来自对称未知分布时，则估计均值和估计中位数是基本相同的，但如果数据具有极值，则中位数比均值更加稳健，特别是本文采用有放回分块自助法（Block Bootstrap）抽样估计分布时，容易抽到极端数据影响均值，中位数相对更加稳健，所以采取中位数构建的统计量是合理的，记基于中位数构建的检验统计量为 STMSN-MID 和 STMC-MID，模拟好正常均值单变点数据后，分别比较 STMSN-MID、STMC-MID、SN 和 CUSUM 算法的检验准确率如下图所示：




图 24 STMSN-MID、STMC-MID、SN 和 CUSUM 对正常跳跃均值变点数据的检验准确率

注：STMSN-MID 代表基于本文提出的自归一化方法的中位数时空均值变点检测算法，STMC-MID 代表基于累积和方法的中位数时空均值变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法




图 25 STMSN-MID、STMC-MID、SN 和 CUSUM 对正常非跳跃均值变点数据检验准确率

注：STMSN-MID 代表基于本文提出的自归一化方法的中位数时空均值变点检测算法，STMC-MID 代表基于累积和方法的中位数时空均值变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法

由图 24、图 25 可以看出，与基于均值统计量构建的算法类似，SN、CUSUM 方法不能检验均值变点是否为异常变点，STMSN-MID 算法的检验准确率对于不同的均值变化幅度基本保持稳定，STMC-MID 算法表现出非单调的能力，并且随着均值变化幅度的减小，STMSN-MID 和 STMC-MID 算法的检验正确率也呈现一个下降趋势，特别是均值变化幅度 $|\Delta u| = 1$ 时下降趋势更加明显。基于中位数统计量构建的 STMSN-MID 和 STMC-MID 算法的

检验准确率均高于均值构建的 STMSN 和 STMC 算法，这是因为均值容易受到极值的干扰，中位数相对于均值更加稳健，因此基于中位数的检验方法具有较高的检验准确率。

因为单纯的 SN、CUSUM 方法无法有效检验均值变点是否异常，因此对比正常均值单变点检测的四个方法，具体如表 3 所示，我们可以看出，在均值变化幅度较小时，STMSN 与 STMC、STMSN-50%与 STMC-50%的检验准确率基本一致，但是随着均值变化幅度的增加，STMC 和 STMC-50%因为 CUSUM 检验方法的非单调的能力，检验正确率逐渐下降，STMSN-50%和 STMC-50%的检验准确率均高于 STMSN 与 STMC 的检验准确率。

表 3 正常均值变点检验准确率

变化幅度	正常跳跃均值变点				正常非跳跃均值变点			
Δu	STMSN	STMC	STMSN-MID	STMC-MID	STMSN	STMC	STMSN-MID	STMC-MID
-10	0.853	0	0.920	0	0.844	0	0.905	0
-9	0.864	0	0.927	0	0.839	0	0.895	0
-8	0.869	0	0.940	0	0.862	0	0.913	0
-7	0.875	0	0.921	0	0.857	0	0.902	0
-6	0.874	0.008	0.924	0.012	0.869	0.003	0.913	0.003
-5	0.849	0.195	0.906	0.029	0.84	0.141	0.902	0.149
-4	0.856	0.740	0.921	0.793	0.858	0.714	0.914	0.761
-3	0.882	0.878	0.932	0.931	0.853	0.832	0.912	0.907
-2	0.861	0.853	0.915	0.912	0.839	0.813	0.899	0.899
-1	0.806	0.827	0.867	0.902	0.760	0.771	0.842	0.870
1	0.804	0.840	0.858	0.899	0.793	0.793	0.845	0.859
2	0.851	0.847	0.923	0.924	0.835	0.797	0.916	0.899
3	0.850	0.848	0.914	0.915	0.828	0.813	0.900	0.897
4	0.852	0.739	0.920	0.796	0.854	0.713	0.906	0.752
5	0.872	0.222	0.921	0.232	0.839	0.149	0.900	0.156
6	0.885	0.010	0.928	0.010	0.856	0.002	0.908	0.002
7	0.889	0	0.941	0	0.860	0	0.922	0
8	0.863	0	0.923	0	0.862	0	0.910	0
9	0.864	0	0.939	0	0.865	0	0.920	0
10	0.865	0	0.930	0	0.879	0	0.920	0

注：STMSN 代表基于本文提出的自归一化方法的时空均值变点检测算法，STMC 代表基于累计和方法的时空均值变点检测算法，STMSN-MID 代表基于本文提出的自归一化方法的中位数时空均值变点检测算法，STMC-MID 代表基于累计和方法的中位数时空均值变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法。

6.1.2 异常均值单变点

每个站点模拟 100 个数据，假设在 $t = 51$ 处出现变点，对于异常跳跃均值变点，模拟方式如下：站点 1 的前 50 个数据由正态分布 $N(50,1)$ 生成，站点 1 的后 50 个数据由正态分布 $N(50+\Delta u,1)$ 生成，站点 2-5 的 100 个数据由 $N(47,1)$ ， $N(46,1)$ ， $N(53,1)$ ， $N(51,1)$ 生成。对于异常跳跃均值变点，模拟方式如下：站点 1 的前 50 个数据由正态分布 $N(50,1)$ 生成，站点 1 的后 50 个数据 $x_{1j} = \frac{u_1 + \Delta u}{1 + \exp(-l_j)} + \varepsilon_j$ ， $j = 1, 2, \dots, 10$ ，其中 u_1 为站点 1 在变点出现前的均值， $l_j = 0.5 * j - 2.5$ ， $\varepsilon \sim N(0,1.5)$ 为随机白噪声序列， Δu 为均值变化幅度，站点 2-5 的 100 个数据由 $N(47,1)$ ， $N(46,1)$ ， $N(53,1)$ ， $N(51,1)$ 产生，模拟数据由下图所示：




图 26 异常跳跃均值单变点模拟数据（左图）和异常非跳跃均值单变点模拟数据（右图）

同样利用准确率来表示不同均值变化幅度下算法的有效性，检验准确率的计算如下所示：

$$\text{Accuracy} = \frac{N}{K},$$

其中 N 代表检验出正常均值变点的次数， K 代表模拟次数（1000 次）。

利用模拟的异常均值单变点数据，分别比较 STMSN、STMC、SN 和 CUSUM 算法的检验准确率如下表所示：

表 4 STMSN、STMC、SN 和 CUSUM 算法对异常均值变点数据的检验准确率

变化幅度	异常跳跃均值变点				异常非跳跃均值变点			
Δu	SN	CUSUM	STMSN	STMC	SN	CUSUM	STMSN	STMC
-10	1	0	1	0	1	0	1	0
-9	1	0	1	0	1	0	1	0
-8	1	0	1	0	1	0	1	0
-7	1	0	1	0	1	0	1	0
-6	1	0.013	1	0.013	1	0.003	1	0.003
-5	1	0.235	1	0.235	1	0.164	1	0.164
-4	1	0.856	1	0.856	1	0.828	1	0.828
-3	1	0.999	1	0.999	1	1	1	1
-2	1	1	1	1	1	1	1	1
-1	0.950	0.992	0.950	0.992	0.914	0.991	0.914	0.991
1	0.940	0.990	0.940	0.990	0.927	0.988	0.927	0.988
2	1	1	1	1	1	1	1	1
3	1	0.999	1	0.999	1	0.999	1	0.999
4	1	0.855	1	0.855	1	0.829	1	0.829
5	1	0.251	1	0.251	1	0.169	1	0.169
6	1	0.011	1	0.011	1	0.002	1	0.002
7	1	0	1	0	1	0	1	0
8	1	0	1	0	1	0	1	0
9	1	0	1	0	1	0	1	0
10	1	0	1	0	1	0	1	0

注：STMSN 代表基于本文提出的自归一化方法的时空均值变点检测算法，STMC 代表基于累计和方法的时空均值变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法。

由表 4 可知，因为本文假设 SN、CUSUM 方法的检验的所有变点都为异常变点，因此 SN、CUSUM 方法的检验正确率就是检验变点的准确率。可以看出，不管是跳跃均值变点还是非跳跃均值变点，SN 方法的检验准确率在除均值变化幅度 $|\Delta u| = 1$ 均为 100%，而 CUSUM 方法的检验准确率表现出明显的非单调的能力，在均值变化幅度较小时，检验准确率较高，随着均值变化幅度的增加，检验准确率逐渐减小最后为零，SN 方法与 CUSUM 方法在均值变化幅度 $|\Delta u| = 1$ 时没有达到 100%，这是因为均值变化幅度较小，SN 方法与 CUSUM 方法不能有效识别变点。SN 方法和基于 SN 方法的时空数据异常均值变点检测算法 STMSN、CUSUM 方法和基于 CUSUM 方法的时空数据异常均值变点检测算法 STMC 的检验准确率基本一致，我们可以认为，只要能识别到变点，我们提出的异常均值变点检测算法 STMSN 和 STMC 就能识别出异常变点，因此我们可以认为 STMSN 和 STMC 算法能有效识别异常均值单变点。并且 SN 方法、CUSUM 方法、STMSN 和 STMC 算法，模拟正常跳跃均值变点的准确率均比正常非跳跃均值变点的准确率高，

这是因为非跳跃均值数据存在过渡数据，使用自助法方法进行抽样时可能会抽到较多过渡数据，使得构建的统计量出现偏差。

与正常均值变点检测类似，本文也采用了基于二分位数即中位数构建的统计量的 STMSN-MID 算法和 STMC-MID 算法来检验异常均值单变点的准确率，SN、CUSUM、STMSN-MID 和 STMC-MID 算法的检验准确率如下表所示：

表 5 STMSN-MID、STMC-MID、SN 和 CUSUM 算法对异常均值变点数据的检验准确率

变化幅度	异常跳跃均值变点				异常非跳跃均值变点			
Δu	SN	CUSUM	STMSN-MID	STMC-MID	SN	CUSUM	STMSN-MID	STMC-MID
-10	1	0	1	0	1	0	1	0
-9	1	0	1	0	1	0	1	0
-8	1	0	1	0	1	0	1	0
-7	1	0	1	0	1	0	1	0
-6	1	0.013	1	0.013	1	0.003	1	0.003
-5	1	0.235	1	0.235	1	0.164	1	0.164
-4	1	0.856	1	0.856	1	0.828	1	0.828
-3	1	0.999	1	0.999	1	1	1	1
-2	1	1	1	1	1	1	1	1
-1	0.950	0.992	0.936	0.983	0.914	0.991	0.914	0.979
1	0.940	0.990	0.927	0.981	0.927	0.988	0.927	0.984
2	1	1	1	1	1	1	1	1
3	1	0.999	1	0.999	1	0.999	1	0.999
4	1	0.855	1	0.855	1	0.829	1	0.829
5	1	0.251	1	0.251	1	0.169	1	0.169
6	1	0.011	1	0.011	1	0.002	1	0.002
7	1	0	1	0	1	0	1	0
8	1	0	1	0	1	0	1	0
9	1	0	1	0	1	0	1	0
10	1	0	1	0	1	0	1	0

注：STMSN-MID 代表基于本文提出的自归一化方法的中位数时空均值变点检测算法，STMC-MID 代表基于累计和方法的中位数时空均值变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法。

由表 5 可以看出，与基于均值构建的统计量的 STMSN 和 STMC 算法类似，STMSN-50%和 STMC-50%算法检验准确率分别和 SN 方法和 CUSUM 方法的检验准确率基本一致，并且对正常跳跃均值变点的准确率均比正常非跳跃均值变点的准确率高。

结合表 4、表 5 我们可以看出，本文提出的基于均值构建的统计量 STMSN、STMC 和基于分位数构建的统计量 STMSN-50%、STMC-50%均能有效识别异常均值单变点。

接着考虑方差变点，本文方差变点模拟考虑了正常方差变点、异常方差

变点两种情况，分别生成模拟数据，使用本文提出的方差单变点算法进行检验，计算检验正确率来验证该算法的有效性。本文假设 SN 方法/CUSUM 检验发现的所有变点都为异常方差变点，并且为了验证方差单变点方法在不同方差变化幅度下的有效性，我们引入了参数 $\Delta\sigma$ 来代表方差变化幅度，对每一个 $\Delta\sigma$ 进行了 100 次模拟，检验在不同方差变化幅度下的方差单变点方法的有效性。并且给定累积和（CUSUM）方法、自归一化（SN）方法的检验显著性水平为 5%，给定 STVSN 方法、STVC 方法中分块自助法（Block Bootstrap）抽样时每个数据块长度为 $l=2$ ，抽取 $M=700$ 次，抽样显著性水平为 5%。

6.1.3 正常方差单变点

每个站点模拟 1000 个数据，假设在 $t = 501$ 处出现方差变点，对于正常方差变点，模拟方式如下：站点 1-5 的前 500 个数据分别由正态分布 $N(0,1)$ ， $N(0,1)$ ， $N(0,1)$ ， $N(0,1)$ ， $N(0,1)$ 产生，后 500 个数据分别由正态分布 $N(0,1+\Delta\sigma^2)$ ， $N(0,1+\Delta\sigma^2)$ ， $N(0,1+\Delta\sigma^2)$ ， $N(0,1+\Delta\sigma^2)$ ， $N(0,1+\Delta\sigma^2)$ 产生。 $\Delta\sigma^2$ 为方差变化幅度，为了检验在不同方差变化幅度下算法的有效性，我们设置 $\Delta\sigma^2 = 1, 2, \dots, 9$ 。模拟数据如下图所示（为了便于观测，对模拟的数据进行了平移处理）：




图 27 正常方差单变点模拟数据

依旧利用准确率来判断本文提出的均值单变点算法的有效性。本文提出

了检验时空数据的异常方差变点的算法 STVSN 和 STVC，模拟正常方差单变点数据后，分别比较 SN、CUSUM、STVSN、STVC 算法的检验准确率如下表所示：

表 6 SN、CUSUM、STVSN 和 STVC 算法对正常方差变点数据的检验正确率

变化幅度	1	2	3	4	5	6	7	8	9
SN	0	0	0	0	0	0	0	0	0
CUSUM	0	0	0	0	0	0	0	0	0
STVSN	0.92	0.95	0.93	0.92	0.93	0.93	0.91	0.93	0.90
STVC	0.92	0.92	0.91	0.92	0.93	0.92	0.91	0.93	0.91

注：STVSN 代表基于本文提出的自归一化方法的时空方差变点检测算法，STVC 代表基于累计和方法的时空方差变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法。

由表 7 可知，因为本文假设 SN/ CUSUM 检验发现的所有变点都为异常方差变点，但是本节模拟的所有变点均为正常方差变点，所以 SN /CUSUM 方法的检验正确率为 0。经典的变点检测算法只能检测变点，并不能判断变点异常与否，本文提出的基于经典变点检测算法提出了异常方差单变点检测的 STVSN 和 STMC 算法，利用了站点间的空间邻近性来判断变点的性质，由上表可以看出，两种算法的检验正确率均在 90%-95%之间，检验正确率较高，因此可以认为本文提出的检验异常方差单变点的 STVSN、STVC 算法均能有效识别正常方差单变点。

6.1.4 异常方差单变点

每个站点模拟 1000 个数据，假设在 $t = 501$ 处出现方差变点，对于异常方差变点，模拟方式如下：站点 1 的前 500 个数据由正态分布 $N(0,1)$ 产生，后 500 个数据由正态分布 $N(0,1+\Delta\sigma^2)$ 产生，站点 2-5 的 1000 个数据由 $N(0,1)$ ， $N(0,1)$ ， $N(0,1)$ ， $N(0,1)$ 产生， $\Delta\sigma^2$ 为方差变化幅度，为了检验在不同方差变化幅度下算法的有效性，我们设置 $\Delta\sigma = 1, 2, \dots, 9$ 。模拟数据如下图所示（为了便于观测，对模拟的数据进行了平移处理）：




图 28 异常方差单变点模拟数据

模拟异常方差单变点数据后，分别比较 SN、CUSUM、STVSN、STVC 算法的检验准确率如下表所示：

表 7 SN、CUSUM、STVSN 和 STVC 算法对异常方差变点数据的检验正确率

变化幅度	1	2	3	4	5	6	7	8	9
SN	1	1	1	1	1	1	1	1	1
CUSUM	1	1	1	1	1	1	1	1	1
STVSN	1	1	1	1	1	1	1	1	1
STVC	1	1	1	1	1	1	1	1	1

注：STVSN 代表基于本文提出的自归一化方法的时空方差变点检测算法，STVC 代表基于累积和方法的时空方差变点检测算法，SN 代表自归一化方法，CUSUM 代表累积和方法。

由表 7 可知，因为本文假设 SN/CUSUM 检验发现的所有变点都为异常变点，因此 SN/CUSUM 方法的对异常变点检验正确率就是检验变点的正确率，因为本节模拟的所有变点均为异常方差变点，所以 SN/CUSUM 方法的检验正确率为 1。并且对于不同的方差变化幅度，本文提出的检验异常方差单变点的 STVSN 和 STVC 算法的没有出现误判，因此可以认为本文提出的异常方差单变点检测算法 STVSN、STVC 均能有效识别异常方差单变点。

6.2 多变点情况

当变点数量 $K \in \{2, 3, \dots, n-1\}$ 时，为多变点问题。进行多变点数据模拟时，有几点需要提前说明：第一，因为多变点问题可以通过拆分数据将多变

点问题转换为单变点问题，所以在本节模拟中只考虑两个变点的情况，大于两个变点的问题也可以通过拆分数据转换为双变点问题。第二，因为本文提出的方差变点算法 STVSN、STVC 是在均值变点算法 STMSN、STMC 基础上修改后提出的，与均值变点检测类似，所以在多变点模拟中只模拟了均值变点。第三，均值变点存在跳跃均值变点和非跳跃均值变点 2 种情况，两个均值变点就有 4 种情况，因为实际数据中数据往往是缓慢变化的，非跳跃均值变点比较常见，因此本节模拟中只考虑两个变点均为非跳跃均值变点的情况。第四，由 6.1 节的单变点模拟可以知道，基于二分位点构建的 STMSN-MID 与 STMC-MID 算法的检验正确率均高于基于均值构建的 STMSN 与 STMC 算法，因此本节模拟中采用 STMC-MID 与 STMSN-MID 算法来判断均值多变点算法的准确率。第五，因为本文提出的多变点算法首先根据 SN 方法求出该站点的所有均值变点位置，Shao 和 Zhang (2010) 提出了基于 SN 方法的多变点检测，但是并没有给出临界值，因此本节模拟采用二分法划分数据，分别求出变点后在按照变点划分数据。与均值单变点模拟类似，我们引入了参数 $\Delta\mu$ 来代表均值变化幅度，对每一个 $\Delta\mu$ 进行了 100 次模拟，检验在不同均值变化幅度下的均值多变点方法的有效性。

6.1.1 正常均值多变点

每个站点模拟 200 个数据，假设在假设在 $t = 51$ 和 $t = 151$ 处出现变点，对于正常均值双变点，模拟方式如下：站点 1-5 前 50 个数据分别由正态分布 $N(50,1)$, $N(47,1)$, $N(46,1)$, $N(53,1)$, $N(51,1)$ 生成，记 x_{ij} 为站点 i 第 j 个数据，站点 1-5 的第 51-60 个数据 $x_{ij} = \frac{u_i - \Delta u}{1 + \exp(-l_j)} + \varepsilon_{ij}$, $j = 1, 2, \dots, 10$ ，其中 u_i 为站点 i 在变点出现前的均值， $l_j = 0.5 * j - 2.5$ ， $\varepsilon_{ij} \sim N(0, 1.5)$ 为随机白噪声序列， Δu 为均值变化幅度。站点 1-5 的第 61-100 个数据分别由正态分布 $N(50 - \Delta u, 1)$, $N(47 - \Delta u, 1)$, $N(46 - \Delta u, 1)$, $N(53 - \Delta u, 1)$, $N(51 - \Delta u, 1)$ 生成，第 101-200 个数据由前 100 个数据对称生成。模拟数据如下图所示：




图 29 正常均值双变点模拟数据

利用模拟的正常均值双变点数据，分别采用 STMC-MID、STMSN-MID 算法的检验准确率为：

表 8 STMC-MID、STMSN-MID 算法对正常均值双变点数据的检验准确率

变化幅度	1	2	3	4	5	6	7	8	9	10
STMC-MID	0.74	0.80	0.87	0.88	0	0	0	0	0	0
STMSN-MID	0.78	0.83	0.85	0.87	0.81	0.85	0.84	0.85	0.80	0.84

注：STMSN-MID 代表基于本文提出的自归一化方法的时空均值多变点检测算法，STMC-MID 代表基于累计和方法的时空均值多变点检测算法。

由表 8 可以看出，STMC-MID 与 STMSN-MID 算法在均值变化幅度较小时即 $\Delta u \in [1,4]$ 之间的检验准确率基本相同，但是 STMC-MID 算法在 $\Delta u > 4$ 之后与均值单变点的检测类似，表现出非单调的能力，不能有效检验均值双变点。STMSN-MID 算法对正常均值双变点数据的检验准确率在 78%-87% 之间，而 STMSN-MID 算法对正常均值单变点数据的检验准确率在 84%-92% 之间，可以认为随着变点数量的增加，本文提出的异常变点检测方法的正确率有一定程度的下降，但是 STMSN-MID 算法对正常均值双变点数据的检验准确率仍然保持较高水平，因此可以认为 STMSN-MID 算法能够有效识别正常均值多变点。

6.1.2 异常均值多变点

每个站点模拟 200 个数据，假设在假设在 $t = 51$ 和 $t = 151$ 处出现变点，

对于异常均值双变点，模拟方式如下：站点 1 前 50 个数据由正态分布 $N(50,1)$ 生成，记 x_{1j} 为站点 1 第 j 个数据，站点 1 的第 51-60 个数据 $x_{1j} = \frac{u_1 - \Delta u}{1 + \exp(-l_j)} + \varepsilon_j$, $j = 1, 2, \dots, 10$ ，其中 u_1 为站点 1 在变点出现前的均值， $l_j = 0.5 * j - 2.5$ ， $\varepsilon_j \sim N(0, 1.5)$ 为随机白噪声序列， Δu 为均值变化幅度。站点 1 的第 61-100 个数据由正态分布 $N(50 - \Delta u, 1)$ 生成，第 101-200 个数据由前 100 个数据的对称生成。站点 2-5 的数据分别由 $N(47, 1)$ ， $N(46, 1)$ ， $N(53, 1)$ ， $N(51, 1)$ 生成。模拟数据由下图所示：




图 30 异常均值双变点模拟数据

利用模拟的异常均值双变点数据，分别采用 STMC-MID、STMSN-MID 算法的检验准确率为：

表 9 STMC-MID、STMSN-MID 算法对异常均值双变点数据的检验准确率

变化幅度	1	2	3	4	5	6	7	8	9	10
STMC-MID	1	1	1	1	0	0	0	0	0	0
STMSN-MID	0.98	1	1	1	1	1	1	1	1	1

注：STMSN-MID 代表基于本文提出的自归一化方法的时空均值多变点检测方法，STMC-MID 代表基于累和方法的时空均值多变点检测方法

由表 9 可以看出，STMC-MID 算法在在均值变化幅度较小时即 $\Delta u \in [1, 4]$ 能够有效检验异常均值双变点，在均值变化幅度较大时表现出非单调的能力，无法有效检验异常均值双变点，当 $\Delta u \neq 1$ 时，STMSN-MID 算法对异常均值双变点数据的检验正确率均为 100%，当 $\Delta u = 1$ 时，准确率为 98%，这是因为在均值变化幅度较小时，自归一化(SN)方法可能检测不到变点，因

此无法判定变点是否为异常变点。由于对于不同的均值变化幅度，STMSN-MID 算法检验异常均值双变点检验正确率均较高，因此可以认为 STMSN-MID 算法能够有效识别异常均值多变点。

7. 实际数据分析

7.1 均值变点检测

本文使用的实际数据来源于成都地区 2013 年~2022 年的监测数据。成都地区一共有 32 个空气质量监测站点，我们选取监测站点 $\text{PM}_{2.5}$ 的小时数据作为研究数据。首先进行数据处理，计算数据缺失值比例，发现成都地区数据缺失较多，很多站点数据存在大量缺失，因此选取数据缺失比例相对较少的 2018 年 2 月数据作为研究对象，使用向后填充法对数据缺失值进行填充。对于站点的选择，综合站点距离和数据缺失，选择了三瓦窑、大石西路、沙河铺、十里店、军平街、金泉两河 6 个相邻站点作为研究站点，成都地区所有站点及选择站点的分布如图 31 所示，以十里店站点作为目标站点，检验本文提出的异常变点检测算法对实际数据变点检测的有效性。对于算法选择，由第 6 章数值模拟的结果可以看出，本文提出的基于自归一化（SN）方法的异常均值多变点检测算法检验准确率较高，且避免了基于累计和（CUSUM）方法的异常均值多变点检测算法的非单调性，因此本文采用基于自归一化（SN）方法的异常均值多变点检测算法来检验实际数据中的异常均值变点。




图 31 成都地区空气质量监测站点分布


注：其中红色圆点代表本文选中的研究站点，黄色圆点代表未被选中的研究站点

以 2018 年 2 月 17 日 0 点至 2018 年 2 月 18 日 12 时共 37 个小时的 $\text{PM}_{2.5}$ 浓度数据作为实验数据。以十里店站点作为目标站点，三瓦窑、大石西路、沙河铺、君平街和金泉两河 5 个相邻站点作为辅助站点，判断本文提出的变点检测方法对实际数据检测的有效性。以十里店站点作为目标站点，分别计算其余 5 个站点对十里店站点的反距离加权重，权重如表 10 所示：

表 10 所有辅助站点对十里店的反距离加权重

站点名称	反距离加权重
三瓦窑	0.16738
大石西路	0.17816
沙河铺	0.30075
君平街	0.21962
金泉两河	0.13408

以 6 个站点从 2018 年 2 月 17 日 0 点至 2018 年 2 月 18 日 12 时的 $\text{PM}_{2.5}$ 浓度数据作图，如下图所示：

图 32 监测站点 2018 年 2 月 17 日 0 时至 2 月 18 日 12 时 $\text{PM}_{2.5}$ 浓度数据图

由图 32 可以看出, 从 2018 年 2 月 17 日 0 时开始的一段时间内, 全部 6 个站点的 $\text{PM}_{2.5}$ 浓度比较稳定, 大致在一个较高范围内波动, 在 2 月 17 日 15 时 $\text{PM}_{2.5}$ 浓度出现明显的下降, 之后下降到一定浓度后在一个较低的范围内稳定波动, 可以明显看出在 2 月 17 日 15 时 $\text{PM}_{2.5}$ 浓度数据存在均值变点, 又因为所有站点 $\text{PM}_{2.5}$ 浓度数据在变点前后发生了同向变化, 可以初步认为在 2 月 17 日 15 时存在正常均值变点。采用本文提出的异常均值变点检测算法检测十里店站点的变点的性质, 结果如下图所示:




图 33 十里店站点 2 月 17 日 0 时至 2 月 18 日 12 时 $\text{PM}_{2.5}$ 浓度均值变点检测结果

注: 绿色线条代表在该时间点检测出正常均值变点, 红色线条代表在该时间点检测出异常均值变点

由图 33 可以看出, 本文提出的异常均值变点检测算法在 2018 年 2 月 17 日 15 时检测出 1 个正常均值变点, 因为本文采用的数据是严格筛查后的数据, 不存在异常均值变点, 因此可以认为我们提出的异常均值变点检测算法能够有效判别实际数据中的正常均值变点。

由于本文使用的数据是完全真实的, 所以数据中存在的均值变点均为因刮风、下雨等自然现象产生的。为判定异常均值变点检测算法对实际数据中异常均值变点检测的效能, 我们对目标站点十里店的数据进行修改, 具体修改方式如下:

$$x'_t = x_t + 30, t \geq 17.$$

即将 2018 年 2 月 17 日 16 时至 2 月 18 日 12 时的所有 $PM_{2.5}$ 浓度数据均增加 30，其余站点数据 $PM_{2.5}$ 浓度数据保持不变，因为进行了人为修改数据，因此在 2 月 17 日 15 时存在异常均值变点，采用本文提出的检测算法 STMSN-MID 验证修改数据后十里店站点的变点的性质，结果如下图所示：




图 34 十里店站点 2 月 17 日 0 时至 2 月 18 日 12 时修改后 $PM_{2.5}$ 浓度均值变点检测结果

注：绿色线条代表在该时间点检测出正常均值变点，红色线条代表在该时间点检测出异常均值变点

由图 34 可以看出，异常均值变点检测算法 STMSN-MID 在 2018 年 2 月 17 日 15 时检测出 1 个异常均值变点，因此可以认为我们提出的异常均值变点检测算法 STMSN-MID 能够有效判别实际数据中的异常均值变点。

综上所述，本文提出的异常均值检测算法 STMSN-MID 能够有效识别实际数据中的正常均值变点，也能有效识别修改数据后实际数据中的异常均值变点，所以可以认为本文提出的异常均值变点检测算法在实际数据中能够有效的运用。

7.2 方差变点检测

依然以 2018 年 2 月 17 日 0 点至 2018 年 2 月 18 日 12 时共 37 个小时的 $PM_{2.5}$ 浓度数据作为实验数据，检测本文提出的异常方差变点检测的性能。

与实际数据均值变点检测类似，采用采用基于自归一化（SN）方法的异常方差多变点检测算法来检验实际数据中的异常方差变点。由图 22 可以看出，PM_{2.5} 浓度数据在 2 月 17 日 15 时存在均值变点，并且在均值变点两侧数据变化幅度也存在明显差异，因此可以判定在 2 月 17 日 15 时也存在方差变点，采用本文提出的检测算法 STVSN 检测该方差变点的性质，结果如下图所示：




图 35 十里店站点 2 月 17 日 0 时至 2 月 18 日 12 时 PM_{2.5} 浓度方差变点检测结果

注：绿色线条代表在该时间点检测出正常均值变点，红色线条代表在该时间点检测出异常均值变点

由图 35 可以看出，本文提出的异常方差检测算法 STVSN 在 2018 年 2 月 17 日 15 时检测出 1 个正常方差变点，因此可以认为本文提出的异常方差检验算法能够有效识别实际数据中的正常方差变点。

由于本文使用的数据是完全真实的，所以数据中存在的方差变点均为因刮风、下雨等自然现象产生的。为了验证本文提出的异常方差变点检测算法在实际数据中的效能，与异常均值变点检测类似，我们对目标站点十里店的 PM_{2.5} 浓度数据 x_t 进行修改，具体修改方式如下：

- 1) 计算站点 2017 年 2 月 17 日 15 时前 PM_{2.5} 浓度数据 x_t 的均值 $u_1 = \sum_{t < 16} x_t$,
- 2) 变换数据 $x_t^* = x_t/2$,
- 3) 重新计算数据 x_t 的均值 $u_2 = \sum_{t < 16} x_t^*$,

4) 令 $x'_t = x_t^* - u_2 + u_1$ 得到修改后的数据。

修改后十里店的数据，在 2017 年 2 月 17 日 15 时前均值不变，方差扩大为原来的 4 倍，因为人为修改了数据，所以在 2017 年 2 月 17 日 15 时存在异常方差变点。采用本文提出的异常方差变点检测算法 STVSN 验证修改数据后十里店站点的变点的性质，结果如下图所示：




图 36 十里店站点 2 月 17 日 0 时至 2 月 18 日 12 时修改后 $PM_{2.5}$ 浓度方差变点检测结果

注：绿色线条代表在该时间点检测出正常均值变点，红色线条代表在该时间点检测出异常均值变点

由图 36 可以看出，本文提出的异常方差检测算法 STVSN 在 2017 年 2 月 17 日 15 时检测出 1 个异常方差变点，因此可以认为本文提出的异常方差检验算法能够有效识别实际数据中的异常方差变点。

综上所述，本文提出的异常方差检测算法能够有效识别实际数据中的正常方差变点，也能有效识别修改数据后实际数据中的异常方差变点，所以可以认为本文提出的异常方差变点检测算法在实际数据中能够有效的运用。

8. 总结与展望

8.1 工作总结

本文基于污染物监测数据的时空特性，利用自归一化(SN)方法，提出了一种新的时空变点检测方法，用以检验污染物监测数据的异常原因。本文具体做了以下几项工作：

1. 实际情况中，污染物监测数据可能存在异常，发生异常可能是由于刮风、下雨等气象因素引起的，也有可能是由于监测仪器故障、人工修改数据等人为因素引起的，对于人为因素引起的数据异常应及时修正，保证监测数据的准确性。监测数据的异常可以用变点检测方法检验，但是经典变点检测方法无法判断引起数据异常的原因，因此本文利用检测站点污染物监测数据的空间相关性，基于经典变点检测方法自归一化(SN)方法，提出了针对时空数据单变点检测的均值单变点检测算法 STMSN、STMSN-分位数和方差单变点检测方法 STVSN，并在单变点基础上提出了针对时空数据多变点检测的均值和方差检验算法。

2. 利用本文提出的基于自归一化(SN)方法的时空数据变点检测算法，分别对单变点和多变点情况下的正常均值变点、异常均值变点、正常方差变点和异常方差变点情况进行了检验，并与基于累积和(CUSUM)方法的时空数据变点检测算法的结果进行比较，结果如下：对于均值变点，基于累积和(CUSUM)方法的时空变点检测算法表现出非单调的性质，而基于自归一化(SN)方法的时空变点检测算法没有表现出非单调的性质，检验准确率保持在80%-94%之间，能够有效检验变点；对于方差变点，基于累积和方法(CUSUM)的时空变点检测算法和基于自归一化方法(SN)的时空变点检测算法的检验准确率保持在90%-95%，均能有效检验变点。

3. 本文还利用成都地区 2018 年 2 月 17 日 0 点至 2018 年 2 月 18 日 12 时共 37 个小时的 $PM_{2.5}$ 浓度数据作为实验数据, 检验本文提出的基于自归一化(SN)方法的时空数据变点检测算法在实际数据上的应用。结果如下: 本文提出的时空数据变点检测算法能够有效检测目标站点十里店站点中的正常均值和方差变点, 并且也能够有效检测十里店站点修改数据后产生的异常均值和方差变点。

8.2 研究展望

本文基于自归一化(SN)变点检测方法, 利用监测站点数据的空间相关性, 构建了时空数据异常变点的均值和方差检验算法, 并利用模拟数据和实际数据, 验证了本文提出算法的有效性, 但是仍然存在一些不足, 有一些地方可以进一步深入研究:

1. 本文基于自归一化(SN)进行变点检测, 避免了基于累积和(CUSUM)方法进行变点检测时存在的非单调的性质, 但是自归一化(SN)方法因为对数据进行了自归一化处理, 运算量增加, 运算时间较长。接下来的研究可以考虑查阅相关文献, 选出更适合的变点检测方法, 既避免非单调的性质, 也能节约运算时间。

2. 本文的模拟数据仅考虑了站点数据全部为独立的正态分布数据的情况, 实际情况中, 大部分的站点数据并不是独立分布或者正态分布, 在接下来的研究中可以考虑用其他时间序列模型(例如 ARCH、GARCH 模型等)进行数值模拟, 检验本文提出算法的效能。并且本文在构建算法时, 只考虑了一个站点数据异常, 相邻站点数据正常的情况, 实际情况中, 可能会存在多个站点数据都存在异常的情况, 在接下来的研究中可以考虑对多个站点数据异常的情况进行检测。

3. 本文构建了对站点时空异常数据的均值和方差检验算法, 但是本文提出的算法只能检验一种变点, 当一个站点既存在均值变点也存在方差变点时, 我们的算法无法有效检验。因此在接下来的研究中可以考虑构建一个算法, 能够同时检验时空序列中的均值和方差变点。

4. 本文主要重视变点检测方法的应用, 即研究利用经典变点检测方法和

站点间的空间相关性构建算法，来检验实际站点中的变点问题，没有对算法的理论性质进行研究，因此在接下来的研究中可以考虑对站点的理论性质进一步研究。

参考文献

- [1] Andre'es M A, Pena D, Romo J. Forecasting time series with sieve bootstrap[J]. Journal of Statistical Planning and Inference, 2002, 100(1): 1-11.
- [2] Angelosante D, Giannakis G B. Group lassoing change-points in piecewise-stationary ar signals[C]//2011 17th International Conference on Digital Signal Processing (DSP). IEEE, 2011: 1-8.
- [3] Arlot S, Blanchard G, Roquain E. Some nonasymptotic results on resampling in high dimension, I: confidence regions[J]. The Annals of Statistics, 2010, 38(1): 51-82.
- [4] Aue A, Horváth L. Structural breaks in time series[J]. Journal of Time Series Analysis, 2013, 34(1): 1-16.
- [5] Bai J. Least squares estimation of a shift in linear processes[J]. Journal of Time Series Analysis, 1994, 15(5): 453-472.
- [6] Banerjee A, Lumsdaine R L, Stock J H. Recursive and sequential tests of the unit-root and trend-break hypotheses: theory and international evidence[J]. Journal of Business & Economic Statistics, 1992, 10(3): 271-287.
- [7] Berkes I, Gombay E, Horváth L. Testing for changes in the covariance structure of linear processes[J]. Journal of Statistical Planning and Inference, 2009, 139(6): 2044-2063.
- [8] Bickel P J, Freedman D A. Some asymptotic theory for the bootstrap[J]. The annals of statistics, 1981, 9(6): 1196-1217.
- [9] Bleakley K, Vert J P. The group fused lasso for multiple change-point detection[J]. arXiv preprint arXiv:1106.4199, 2011.
- [10] Bühlmann P. Sieve bootstrap for time series[J]. Bernoulli, 1997: 123-148.
- [11] Chen G, Choi Y K, Zhou Y. Nonparametric estimation of structural change points in volatility models for time series[J]. Journal of Econometrics, 2005, 126(1): 79-114.

- [12]Deng A, Perron P. A non-local perspective on the power properties of the CUSUM and CUSUM of squares tests for structural change[J]. Journal of Econometrics, 2008, 142(1): 212-240.
- [13]Efron B. Bootstrap methods: another look at the jackknife[J]. The Annals of Statistics, 1979, 7: 1-26.
- [14]Carlin B P, Gelfand A E, Smith A F M. Hierarchical Bayesian analysis of changepoint problems[J]. Journal of the royal statistical society: series C (applied statistics), 1992, 41(2): 389-405.
- [15]Gombay E, Horváth L, Husková M. Estimators and tests for change in variances[J]. Statistics & Risk Modeling, 1996, 14(2): 145-160.
- [16]Gupta A K, Ramanayake A. Change points with linear trend for the exponential distribution[J]. Journal of statistical planning and inference, 2001, 93(1-2): 181-195.
- [17]Hall P, Horowitz J L, Jing B Y. On blocking rules for the bootstrap with dependent data[J]. Biometrika, 1995, 82(3): 561-574.
- [18]Han S , Wang H . Change-Point in the Mean of Heavy-Tailed Dependent Observations[J]. Chinese Journal of Applied Probability and Statistics, 2008, 24(4):337-344.
- [19]Han S, Tian Z. Truncating estimation for the mean change-point in heavy-tailed dependent observations[J]. Communications in Statistics—Theory and Methods, 2006, 35(1): 43-52.
- [20]Harchaoui Z, Lévy-Leduc C. Multiple change-point estimation with a total variation penalty[J]. Journal of the American Statistical Association, 2010, 105(492): 1480-1493.
- [21]Hawkins D L, Gallant A R, Fuller W. A simple least squares method for estimating a change in mean[J]. Communications in Statistics-Simulation and Computation, 1986, 15(3): 523-530.
- [22]Hinkley D V. Inference about the change-point in a sequence of random variables[J]. 1970.
- [23]Holmes Mark,Kojadinovic Ivan. Open-end nonparametric sequential change-point detection based on the retrospective CUSUM statistic[J]. ELECTRONIC JOURNAL OF STATISTICS,2021,15(1).
- [24]Horváth L, Horváth Z, Hušková M. Ratio tests for change point detection[J].

- Beyond parametrics in interdisciplinary research: Festschrift in honor of Professor Pranab K. Sen, 2008, 1: 293-304.
- [25]Hsu D A. Tests for variance shift at an unknown time point[J]. Journal of the Royal Statistical Society: Series C (Applied Statistics), 1977, 26(3): 279-284.
- [26]Hušková M, Slabý A. Permutation tests for multiple changes[J]. Kybernetika, 2001, 37(5): [605]-622.
- [27]James B, James K L, Siegmund D. Tests for a change-point[J]. Biometrika, 1987, 74(1): 71-83.
- [28]Juhl T, Xiao Z. Tests for changing mean with monotonic power[J]. Journal of Econometrics, 2009, 148(1): 14-24.
- [29]Kunsch H R. The jackknife and the bootstrap for general stationary observations[J]. The annals of Statistics, 1989: 1217-1241.
- [30]Lahiri S N. Theoretical comparisons of block bootstrap methods[J]. Annals of Statistics, 1999: 386-404.
- [31]Lee S, Ha J, Na O, et al. The cusum test for parameter change in time series models[J]. Scandinavian Journal of Statistics, 2003, 30(4): 781-796.
- [32]Levy-Leduc C, Harchaoui Z. Catching change-points with lasso[J]. Advances in neural information processing systems, 2007, 20.
- [33]Li F, Tian Z, Xiao Y, et al. Variance change-point detection in panel data models[J]. Economics Letters, 2015, 126: 140-143.
- [34]Liu R Y , Singh K . Moving Blocks Jackknife and Bootstrap Capture Weak Dependence. 1992.
- [35]Muggeo, Vito, M, et al. Efficient change point detection for genomic sequences of continuous measurements.[J]. Bioinformatics, 2011.
- [36]Oh K J, Moon M S, Kim T Y. Variance change point detection via artificial neural networks for data separation[J]. Neurocomputing, 2005, 68: 239-250.
- [37]Page E S. Continuous inspection schemes[J]. Biometrika, 1954, 41(1/2): 100-115.
- [38]Perreault L, Bernier J, Bobée B, et al. Bayesian change-point analysis in hydrometeorological time series. Part 1. The normal model revisited[J]. Journal of Hydrology, 2000, 235(3-4): 221-241.
- [39]Perron P. Dealing with structural breaks[J]. Palgrave handbook of econometrics, 2006, 1(2): 278-352.

- [40]Ploberger W, Krämer W. The CUSUM test with OLS residuals[J]. *Econometrica: Journal of the Econometric Society*, 1992: 271-285.
- [41]Robbins M, Gallagher C, Lund R, et al. Mean shift testing in correlated data[J]. *Journal of Time Series Analysis*, 2011, 32(5): 498-511.
- [42]Ross G J, Adams N M. Two nonparametric control charts for detecting arbitrary distribution changes[J]. *Journal of Quality Technology*, 2012, 44(2): 102-116.
- [43]Sen A, Srivastava S. On tests for detecting change in mean when variance is unknown[J]. *Annals of the Institute of Statistical Mathematics*, 1975, 27(1): 479-486.
- [44]Shao X. Self-normalization for time series: a review of recent developments[J]. *Journal of the American Statistical Association*, 2015, 110(512): 1797-1817.
- [45]Shao X, Zhang X. Testing for change points in time series[J]. *Journal of the American Statistical Association*, 2010, 105(491): 1228-1240.
- [46]Singh K. On the asymptotic accuracy of Efron's bootstrap[J]. *The Annals of Statistics*, 1981: 1187-1195.
- [47]Shi X, Wu Y, Miao B. Strong convergence rate of estimators of change point and its application[J]. *Computational statistics & data analysis*, 2009, 53(4): 990-998.
- [48]Srivastava M S, Worsley K J. Likelihood ratio tests for a change in the multivariate normal mean[J]. *Journal of the American Statistical Association*, 1986, 81(393): 199-204.
- [49]Vogelsang T J. Sources of nonmonotonic power when testing for a shift in mean of a dynamic time series[J]. *Journal of Econometrics*, 1999, 88(2): 283-299.
- [50]Wang L. Change-in-mean problem for long memory time series models with applications[J]. *Journal of Statistical Computation and Simulation*, 2008, 78(7): 653-668.
- [51]Wang J L, Bhatti M I. Three test for a change-point in variance of normal distribution[J]. *Chinese J of Appl Probab and Statist*, 1998, 14(2): 113-121.
- [52]Wang L, Wang J. Change-of-variance problem for linear processes with long memory[J]. *Statistical Papers*, 2006, 47(2): 279.
- [53]Webber J R, Gupta Y P. A sieve bootstrap method for correlation analysis[J].

- IEEE transactions on automatic control, 2007, 52(6): 1079-1081.
- [54] Garner W, Politis D N. Local block bootstrap for inhomogeneous Poisson marked point processes[J]. 2018.
- [55] Worsley K J. Confidence regions and tests for a change-point in a sequence of exponential family random variables[J]. Biometrika, 1986, 73(1): 91-104.
- [56] Wu W B, Zhao Z. Inference of trends in time series[J]. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2007, 69(3): 391-410.
- [57] Zhao W, Zhu X, Zhu L. Detecting multiple change points: a PULSE criterion[J]. arXiv preprint arXiv:2003.01280, 2020.
- [58] Zhong M. Break Point Estimation and Variable Selection in Quantile Regressions[M]. University of California, Davis, 2012.
- [59] Zhou Y, Wan A T K, Xie S, et al. Wavelet analysis of change-points in a non-parametric regression with heteroscedastic variance[J]. Journal of Econometrics, 2010, 159(1): 183-201.
- [60] 傅强, 彭选华, 毛一波. 金融时间序列变点探测的小波模极大值线方法[J]. 重庆大学学报(自然科学版), 2007(08): 140-144.
- [61] 吉毛加, 陈占寿, 栗慧妮. 长记忆时间序列趋势项变点的 CUSUM 检验[J]. 青海师范大学学报: 自然科学版, 2019, 35(1): 14-20.
- [62] 金浩, 张思. 基于稳定分布的 ARCH 模型均值检验变点[J]. 宝鸡文理学院学报: 自然科学版, 2017, 37(3): 1-6.
- [63] 李订芳, 胡文超, 章文. 基于小波包的时间序列变点探测算法[J]. 控制与决策, 2005, 20(5): 521-524.
- [64] 李强, 王黎明, 邱菲. 中国股指收益率序列 GARCH 模型中变点的 Bayes 识别[J]. 统计与决策, 2016 (5): 148-151.
- [65] 刘杰, 陈啸远, 吴遵. 分段平稳自回归过程的变点估计与模型选择——基于改进的自适应 LASSO 方法[J]. 中国科学技术大学学报, 2020, 50(6): 744.
- [66] 刘久彪. 基于 Block-Bootstrap 的银行内部评级系统区分力度量[J]. 预测, 2017, 36(6): 37-42.
- [67] 龙振环, 张飞鹏, 周小英. 带多个变点的逐段连续线性分位数回归模型及应用[J]. 数量经济技术经济研究, 2017, 34(8): 150-160.
- [68] 濮晓龙. 关于累积和 (CUSUM) 检验的改进[J]. 应用数学学报, 2003, 26(2):

225-241.

- [69]齐培艳, 田铮. 无穷方差厚尾过程变点的小波估计[J]. 数学的实践与认识, 2008, 38(11): 115-124.
- [70]秦瑞兵, 郭娟. 平稳过程趋势项变点的 CUSUM 检验[J]. 纺织高校基础科学学报, 2017 (2): 226-229.
- [71]谭常春, 江敏. CUSUM 型统计量中调节参数对变点估计效果的影响分析[J]. 中国科学技术大学学报, 2020, 50(7): 920.
- [72]汤银才, 王平平, 陈惠. 线性模型变点问题的贝叶斯分析 (英文)[J]. 应用概率统计, 2015, 31(1): 89-102.
- [73]王丹, 郭鹏江, 夏志明, 等. 厚尾序列均值变点的非参数检验[J]. 西北大学学报: 自然科学版, 2011, 41(5): 761-763.
- [74]谢益辉, 朱钰. Bootstrap 方法的历史发展和前沿研究[J]. 统计与信息论坛, 2008, 23(2): 90-96.
- [75]严方笠, 吴建奎. 基于 SieveBootstrap 方法的季节时间序列模型检验问题研究[J]. 数量经济技术经济研究, 2017, 34(7): 124-144.
- [76]杨喜寿, 杨洪昌. 气候时间序列变点的推断[J]. 大气科学, 1996, 20(1): 47-53.
- [77]袁芳, 田铮, 苏晓丽, 等. 独立序列均值与方差变点的累积和估计及应用[J]. 控制理论与应用, 2010, 27(3): 395-399.
- [78]袁芳, 田铮, 苏晓丽, 等. 独立序列均值与方差变点的累积和估计及应用[J]. 控制理论与应用, 2010, 27(3): 395-399.
- [79]张学新. 随机排列方法检验方差变点[J]. 数理统计与管理, 2014 (3): 416-422.
- [80]赵文芝, 田铮, 夏志明. 线性过程方差变点的估计[J]. 工程数学学报, 2009, 26(2): 273-277.
- [81]赵文芝, 夏志明, 贺飞跃. 长相依序列均值变点检测[J]. 数学的实践与认识, 2016 (3): 204-208.
- [82]周影辉, 倪中新, 杨爱军. 0-1 序列中变点的贝叶斯分析[J]. 数理统计与管理, 2014, 33(6): 1001-1009.



经世济民 孜孜以求

西南财经大学

SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

校址：四川成都温江柳台大道555号

电话：028-87092032 传真：028-87092632

邮编：611130

网址：<http://www.swufe.edu.cn>

Address: Liulin Campus (Main Campus): 555, Liutai Avenue,
Wenjiang District, Chengdu, Sichuan, P. R. China

Tel: 86-28-87092032 Fax: 86-28-87092632 Postcode: 611130